

中国图书分类号\_\_\_\_\_

密级\_\_\_\_\_公开\_\_\_\_\_

国际图书分类号\_\_\_\_\_

单位代码\_\_\_\_\_10613\_\_\_\_\_

西南交通大学  
硕士学位论文

基于变系数自回归的时空数据插补模型

学 科 专 业\_\_\_\_\_统计学\_\_\_\_\_

学 号\_\_\_\_\_2023201614\_\_\_\_\_

作 者 姓 名\_\_\_\_\_向凌霄\_\_\_\_\_

指 导 老 师\_\_\_\_\_郑海涛\_\_\_\_\_

学 院\_\_\_\_\_数学学院\_\_\_\_\_

2026 年 03 月 15 日

**A Thesis Submitted to**  
**Southwest Jiaotong University for Master Degree**

**Imputation Models based on Variable-  
Coefficient Autoregression for Spatio-Temporal  
Data**

Discipline Statistics

Student ID 2023201614

Author Xiang Lingxiao

Supervisor Zheng Haitao

School School of Mathematics

Mar. 15, 2026

# 西南交通大学

## 学位论文独创性声明

本人郑重声明：所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得西南交通大学或其它教育机构的学位或证书而使用过的材料。其他人员对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

本学位论文的主要创新点如下：

作者签名：\_\_\_\_\_

日期：      年    月    日

# 西南交通大学

## 学位论文使用授权

本学位论文作者完全了解西南交通大学有关保留、使用学位论文的规定，同意学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅。本人授权西南交通大学可以将学位论文的全部或部分内容编入有关数据库进行检索及下载，可以采用影印、缩印、扫描等复制手段保存、汇编本学位论文。

本学位论文属于

1. 保密□，在     年解密后适用本授权书；
2. 不保密☑，使用本授权书。

（请在以上方框内打“√”）

作者签名：\_\_\_\_\_ 导师签名：\_\_\_\_\_

日期：     年     月     日

## 摘 要

时空监测数据在环境治理与气象预报等领域发挥着核心作用，但受限于设备故障与传输中断，数据缺失现象普遍存在。针对现有时空插补方法在捕捉数据非平稳演化特征及融合物理一致性约束方面的不足，本文以变系数自回归理论为核心，开展了从基础统计建模到物理感知智能建模的深度探索，提出了两种适用不同复杂度的时空数据插补模型。

首先，针对稀疏空间点采样场景下时空序列的非平稳性难题，提出了一种基于变系数自回归的对抗插补网络（VCAAN）。该模型利用 B 样条基函数逼近自回归方程的时变系数，以局部适应性策略刻画时空动态依赖；同时，引入卷积判别网络并结合对抗训练机制，在一定程度上增强了生成数据的分布真实性与时空一致性。基于北京市 PM<sub>2.5</sub> 实测数据的多场景实验表明，在五种复杂缺失机制及高缺失率条件下，VCAAN 的整体性能优于选定的七种主流基准方法，中位误差改进率达到 38.40%，验证了变系数结构与对抗约束协同优化的有效性。

其次，针对复杂地理环境下气象要素传播所面临的空间各向异性与高维非线性建模挑战，提出了一种基于时空注意力的自回归插补网络（STAAN）。该模型设计了物理引导的时空对齐机制，通过显式约束风向一致性、地形迎风增益及物理平流时延，将流体力学先验知识嵌入统计方程，缓解了三维地貌阻断造成的推断偏差；在此基础上，结合时空注意力超网络，在多源异构高维协变量驱动下实现了动态系数的生成与全局拓扑依赖的特征提取。基于瑞士高山气象数据集的实验证实，STAAN 在区域空间相关缺失等场景下表现稳健，相较于对比算法其插补精度得到了显著提升，体现了物理先验与注意力机制相融合的建模优势。

综上所述，本文提出的两种模型不仅对时空序列非平稳建模的理论框架进行了有益补充，也为复杂物理环境下的缺失数据恢复提供了一种兼顾数理逻辑与数据驱动的新途径，为实际业务系统的可靠运行提供了技术支撑。

**关键词：**时空数据插补，变系数模型，生成对抗网络，注意力机制，物理先验

## ABSTRACT

Spatiotemporal monitoring data plays a core role in fields such as environmental management and meteorological forecasting, but data missingness is prevalent due to equipment failures and transmission interruptions. Addressing the limitations of existing imputation methods in capturing non-stationary evolution characteristics and integrating physical consistency constraints, this thesis conducts a deep exploration from fundamental statistical modeling to physics-aware intelligent modeling, centered on the theory of varying-coefficient autoregression, and proposes two spatiotemporal data imputation models applicable to different complexity scenarios. First, targeting the non-stationarity of spatiotemporal sequences under sparse spatial point sampling scenarios, a Varying-Coefficient Autoregressive Adversarial Network (VCAAN) is proposed. This model utilizes B-spline basis functions to approximate the time-varying coefficients of the autoregressive equation, thereby characterizing spatiotemporal dynamic dependencies with a locally adaptive strategy. Meanwhile, a convolutional discriminative network combined with an adversarial training mechanism is introduced to enhance the distribution authenticity and spatiotemporal consistency of the generated data. Multi-scenario experiments based on measured PM2.5 data in Beijing demonstrate that under five complex missing mechanisms and high missing rates, the overall performance of VCAAN is superior to seven selected mainstream baseline methods, achieving a median error improvement rate of 38.40%. This validates the effectiveness of the synergistic optimization between varying-coefficient structures and adversarial constraints. Second, addressing the spatial anisotropy and high-dimensional nonlinear modeling challenges faced by the propagation of meteorological elements in complex geographical environments, a Spatio-Temporal Attention-based Autoregressive Network (STAAN) is proposed. This model designs a physics-guided spatial alignment mechanism, which mitigates inference deviations caused by 3D geomorphological blocking by explicitly constraining wind direction consistency, topographic windward gain, and physical advection delay, effectively embedding fluid mechanics priors into statistical equations. On this basis, combined with a spatio-temporal attention hypernetwork, it realizes the dynamic generation of coefficients and the extraction of global topological dependencies

driven by multi-source heterogeneous high-dimensional covariates. Experiments based on the Swiss PeakWeather alpine meteorological dataset confirm that STAAN performs robustly in highly challenging scenarios such as regional spatially correlated missingness. Compared with contrast algorithms, its imputation accuracy is significantly improved, demonstrating the modeling advantages of fusing physical priors with attention mechanisms. In conclusion, the two models proposed in this thesis not only provide a beneficial supplement to the theoretical framework of non-stationary modeling for spatiotemporal sequences but also offer a new approach that balances mathematical logic and data-driven methods for missing data recovery in complex physical environments, providing technical support for the reliable operation of practical business systems.

**Keywords:** Spatiotemporal Data Imputation, Variable-Coefficient Model, Generative Adversarial Network, Attention Mechanism, Physical Priors

## 目 录

|                       |    |
|-----------------------|----|
| 第1章 绪论                | 1  |
| 1.1 研究背景及意义           | 1  |
| 1.2 国内外研究现状           | 2  |
| 1.2.1 统计方法插补研究现状      | 2  |
| 1.2.2 深度学习插补研究现状      | 3  |
| 1.2.3 时空数据缺失机制研究      | 4  |
| 1.3 本文研究内容与结构安排       | 5  |
| 1.3.1 本文研究内容          | 5  |
| 1.3.2 本文结构安排          | 6  |
| 第2章 相关理论概述            | 7  |
| 2.1 变系数模型理论基础         | 7  |
| 2.1.1 基于 B 样条的基函数逼近方法 | 7  |
| 2.1.2 基于超网络的参数生成方法    | 8  |
| 2.2 生成对抗网络            | 9  |
| 2.3 Transformer       | 10 |
| 2.4 本章小结              | 11 |
| 第3章 基于稀疏空间点采样的对抗插补网络  | 12 |
| 3.1 问题描述              | 12 |
| 3.2 算法框架              | 13 |
| 3.3 变系数自回归模型          | 14 |
| 3.4 判别器：卷积判别网络        | 16 |
| 3.5 对抗训练              | 18 |
| 3.6 实验与分析             | 20 |
| 3.6.1 研究数据            | 20 |
| 3.6.2 实验设置            | 21 |
| 3.6.3 结果分析            | 22 |
| 3.6.4 消融实验            | 23 |
| 3.7 本章小结              | 26 |
| 第4章 基于时空注意力的自回归插补网络   | 27 |



---

|                          |    |
|--------------------------|----|
| 4.1 问题描述 .....           | 27 |
| 4.2 算法框架 .....           | 30 |
| 4.3 时空对齐自回归模型 .....      | 31 |
| 4.4 时空注意力超网络 .....       | 33 |
| 4.5 实验与分析 .....          | 34 |
| 4.5.1 研究数据 .....         | 34 |
| 4.5.2 实验设置 .....         | 36 |
| 4.5.3 结果分析 .....         | 37 |
| 4.6 本章小结 .....           | 39 |
| 第5章 结论                   | 41 |
| 致 谢 .....                | 43 |
| 参考文献 .....               | 44 |
| 攻读博士/硕士学位期间取得的研究成果 ..... | 48 |

## 主要符号表

| 符号                    | 意义                                              | 单位/维度                              |
|-----------------------|-------------------------------------------------|------------------------------------|
| $\mathcal{S}$         | 站点集合, $s \in \{1, \dots, S\}$                   |                                    |
| $t$                   | 时间索引, $t \in \{1, \dots, T\}$                   |                                    |
| $l$                   | 滞后/超前阶数, $l \in \{-L, \dots, -1, 1, \dots, L\}$ |                                    |
| $\mathbf{Y}$          | 含缺失值的观测矩阵                                       | $\mathbb{R}^{S \times T}$          |
| $\tilde{\mathbf{Y}}$  | 完整真实矩阵 (ground truth)                           | $\mathbb{R}^{S \times T}$          |
| $\hat{\mathbf{Y}}$    | 最终插补结果                                          | $\mathbb{R}^{S \times T}$          |
| $\mathbf{R}$          | 观测指示矩阵 (观测为 1, 缺失为 0)                           | $\{0, 1\}^{S \times T}$            |
| $\mathbf{M}$          | 缺失指示矩阵 (缺失为 1, 观测为 0)                           | $\{0, 1\}^{S \times T}$            |
| $\mathbf{X}$          | 动态协变量张量                                         | $\mathbb{R}^{S \times T \times P}$ |
| $\mathbf{Z}$          | 静态地形特征矩阵                                        | $\mathbb{R}^{S \times D_z}$        |
| $w_{s,s'}$            | 站点静态空间权重                                        |                                    |
| $\mathcal{G}$         | 生成器                                             |                                    |
| $\mathcal{D}$         | 判别器                                             |                                    |
| $\alpha_l(t)$         | $\mathcal{G}$ 的时间项变系数                           |                                    |
| $\beta_l(t)$          | $\mathcal{G}$ 的空间项变系数                           |                                    |
| $x_{s,t}^{q,(i)}$     | 第 $i$ 轮迭代中的展开特征                                 |                                    |
| $\Psi(\mathbf{z}_t)$  | 样条基函数向量, 其中 $\mathbf{z}_t$ 为归一化的时间              |                                    |
| $\boldsymbol{\eta}_q$ | 第 $q$ 个展开项的系数向量                                 |                                    |
| $\epsilon_{s,t}$      | 随机误差项                                           |                                    |
| $\lambda_{ad}$        | 对抗损失权重                                          |                                    |
| $\delta_\lambda$      | 对抗权重调整步长                                        |                                    |
| $\tau$                | $\mathcal{D}$ 的时间窗长度                            |                                    |

|                              |                      |                  |
|------------------------------|----------------------|------------------|
| $D_{s,s'}$                   | 站点间平面距离              | 米 (m)            |
| $\Phi_{s',s}$                | 从 $s'$ 指向 $s$ 的方位角   | 度 ( $^{\circ}$ ) |
| $\theta_{s,t}$               | 站点风向角                | 度 ( $^{\circ}$ ) |
| $\Lambda_s$                  | 站点坡向角 (aspect)       | 度 ( $^{\circ}$ ) |
| $\Delta\theta_{s',s}(t)$     | 风向与连线方位夹角            | 度 ( $^{\circ}$ ) |
| $\mu_{s',s}(t)$              | 地形迎风增益项              | [0,1]            |
| $\tilde{\alpha}_{s',s}(t)$   | 物理对齐权重               |                  |
| $v_{s',s}^{\text{eff}}(t)$   | 有效传播风速               | (0,1]            |
| $\tau_{s',s}(t)$             | 传播时延                 |                  |
| $\Omega(l, \tau)$            | 时空对齐核函数              |                  |
| $A_{s,l}(t)$                 | 双向时间项系数              |                  |
| $\beta_{s,l}^{\text{sp}}(t)$ | 空间传播项系数              |                  |
| $\gamma_s(t)$                | 同时刻空间项系数 ( $l = 0$ ) |                  |
| $B_{s,p}(t)$                 | 协变量项系数               |                  |
| $y_{s,t}^{\text{clean}}$     | 超网络输出的清洗值            |                  |
| $\tilde{y}_{s,t}^*$          | 混合清洗值 (观测值/清洗值融合)    |                  |
| $\lambda_{\text{clean}}$     | 清洗头损失权重              |                  |

# 第1章 绪论

## 1.1 研究背景及意义

随着物联网传感技术与信息通信技术的飞速发展，时空数据已成为环境监测、气象预报、智慧交通及公共卫生等领域的核心资源<sup>[1]</sup>。这类数据通常由分布在地理空间上的多个监测站点随时间连续采集而成，蕴含着丰富的时空依赖关系与动态演化规律。然而，在实际数据采集与传输过程中，受传感器故障、通信链路中断、极端天气干扰或人为操作失误等多重因素影响，数据缺失现象普遍存在。缺失数据不仅破坏了时空序列的完整性，更会导致后续的趋势分析、模式识别及决策支持模型性能显著下降，甚至产生误导性结论<sup>[2]</sup>。因此，如何基于已有观测信息高精度地恢复缺失值，即时空数据插补，已成为统计学与人工智能交叉领域亟待解决的关键问题之一。

从应用层面来看，时空数据插补的质量直接影响环境政策制定与公共健康评估的可靠性。以空气质量监测为例，根据《2024 年全球空气状况报告》，2021 年全球约 99% 的人口暴露于超过世界卫生组织标准的 PM2.5 浓度环境中<sup>[3]</sup>。PM2.5 作为可吸入颗粒物，能够深入支气管和肺泡，对人体健康产生深远影响<sup>[4]</sup>。然而，监测数据常因设备校准、维护或通信问题而出现缺失<sup>[5]</sup>，若采用简单删除或均值填充等粗糙处理方式，将导致污染趋势评估失真，进而延误针对性措施的制定与实施<sup>[6]</sup>。因此，准确插补缺失记录对于全面评估污染的环境影响及制定可持续的空气质量管理体系至关重要<sup>[7]</sup>。

从理论层面来看，时空数据插补面临三大核心挑战：非平稳性、缺失机制复杂性及物理一致性约束。首先，现实世界中的时空过程往往表现出显著的非平稳性与空间异质性。例如，空气污染物浓度受气象条件与人为排放的双重影响，其时空依赖结构随时间演变；风速传播则受地形地貌与风向变化的物理约束，具有强烈的各向异性。传统常系数模型难以捕捉这种动态变化的结构，导致在复杂场景下插补精度受限。其次，缺失数据的潜在机制显著影响插补技术的可靠性与有效性<sup>[8]</sup>。在时空场景中，数据缺失往往与观测值本身或相邻状态存在隐含关联，这种关联性使得缺失模式呈现出高度的动态性与不确定性。若无法准确建模缺失过程，直接进行数值填充极易引入系统性偏差，导致特征学习过程中的信息失真，从而削弱下游任务的性能。最后，部分黑盒模型缺乏物理可解释性，在复杂地理环境下可能生成违背物理规律的插补值，限制了其在业务场景中的可信度。

## 1.2 国内外研究现状

时空数据缺失值插补研究历经了从传统统计方法到现代深度学习方法的演进过程。本节将从时空数据缺失机制研究、统计方法插补研究现状及深度学习插补研究现状三个维度进行系统述评，并指出现有研究的不足与本文的研究切入点。

### 1.2.1 统计方法插补研究现状

传统统计插补方法以其可解释性强、计算复杂度低等特点，在早期研究中占据主导地位，并为后续深度学习模型提供了理论基础。经典方法包括均值插补、最近邻插补（K Nearest Neighbors Imputation, KNNI）、多重插补（Multiple Imputation by Chained Equation, MICE）以及基于自回归积分滑动平均（Autoregressive integrated moving average, ARIMA）的时间序列模型。

MICE 由 Van Buuren 和 Oudshoorn 提出，通过链式方程迭代估算缺失值，能够处理多变量间的复杂关系，是目前应用最广泛的统计插补方法之一<sup>[9]</sup>。然而，MICE 假设数据服从特定概率分布，在面对高维非线性时空数据时，其参数估计可能产生较大偏差。KNN 由 Cover 和 Hart 提出<sup>[10]</sup>，可以利用空间邻近站点的相似性进行加权填补，其核心优势在于无需假设数据分布，但对缺失率敏感，当缺失比例较高时，邻近站点的可用信息不足会导致插补质量急剧下降。末值携带法（Last Observation Carried Forward, LOCF）作为最简单的基线方法，用最近观测值填充缺失，虽计算高效但忽略时间动态变化，仅适用于缺失率极低的场景。

在时空序列建模方面，向量自回归模型（Vector Autoregression, VAR）由 Sims（1980）提出，是多元时间序列分析的经典方法<sup>[11]</sup>。VAR 通过捕捉变量间的滞后依赖关系进行预测，可直接扩展用于缺失值插补。然而，Bashir 和 Wei 指出，VAR 模型参数数量随变量维度呈平方增长，在站点数量较多时面临“维数灾难”，且常系数假设难以适应时空非平稳性<sup>[12]</sup>。为此，变系数模型（Varying-Coefficient Model）应运而生，允许模型参数随时间或协变量变化，为时空序列建模提供了更具灵活性的统计框架<sup>[13,14]</sup>。Luo 等人在生存分析中利用 B 样条逼近时变系数，证明了该方法在捕捉动态结构方面的优势<sup>[15]</sup>。然而，当协变量为高维时空状态（如包含风向、地形、多变量交互）时，张量积样条会导致基函数数量指数级增长，限制了其在复杂高维场景下的应用能力。

此外，矩阵分解（Matrix Factorization, MF）与迭代奇异值分解（Iterative Singular Value Decomposition, Iterative SVD）方法也被广泛应用于缺失数据恢复<sup>[16,17]</sup>。这类方法假设数据矩阵具有低秩结构，通过分解重构实现插补。然而，低秩假设在强非

线性时空过程中往往不成立，且难以捕捉局部动态特征。综上所述，传统统计方法在面对高维非线性时空数据时存在明显局限：一方面，常系数假设难以适应环境变量的动态结构变化；另一方面，传统方法在处理高缺失率数据时，往往因信息量不足导致估计偏差较大，且难以捕捉深层的时空交互特征。

### 1.2.2 深度学习插补研究现状

近年来，深度学习技术的兴起为时空数据插补提供了新的解决方案。基于循环神经网络（Recurrent Neural Network, RNN）及其变体（如 GRU 和 LSTM）的模型能够有效捕捉时间依赖关系，生成对抗网络（Generative adversarial network, GAN）通过对抗训练提升生成数据的分布真实性，而基于 Transformer 架构的模型凭借自注意力机制在全局依赖建模与并行计算方面的优势，已成为当前的主流骨干网络。

循环神经网络类方法中，Che 等人提出的 GRUD（Gated Recurrent Unit with Decays）模型通过引入缺失掩码机制与时间衰减函数，改进了循环单元的输入表示，能够显式建模缺失值对预测的影响<sup>[18]</sup>。Ou 等人提出的位置编码去噪自编码器（Position-Encoding Denoising Autoencoders, PE-DAE）利用时间自相关性与缺失位置信息，结合自步学习策略提升性能<sup>[19]</sup>。然而，GRUD 与 PE-DAE 涉及模型组件需根据目标数据特征仔细调整，跨应用灵活性不足。例如，GRUD 需要领域特定的衰减机制设计，而 PE-DAE 涉及自步学习策略的参数调优，在实际应用中具有挑战性<sup>[20]</sup>。

生成对抗网络类方法中，Goodfellow 等人提出的 GAN 框架通过生成器与判别器的博弈使生成样本服从真实数据分布<sup>[21]</sup>。Miao 等人提出的 SSGAN 整合半监督分类器与时间提醒矩阵，提升了多变量时间序列的插补性能<sup>[22]</sup>。Hu 等人提出的 tnGAN（Generative Adversarial Network based on Trinetworks）采用范围感知特征提取与信息感知特征整合，更好地捕捉时间演化与空间相似性，但其评估仅限于中等缺失条件（不超过 33.33%），在高缺失率下有效性有待验证<sup>[23]</sup>。Hu 等人提出的层次化 GAN 恢复方法引入联合注意力模块提取时空依赖，但该方法需要完整数据对进行训练，在实际缺失场景中难以满足<sup>[24]</sup>。Yuan 等人提出的 SAMIIF（Stacked Adaptive Median Iterative Imputation Framework）结合移动窗口与动态样本叠加技术，通过自适应学习机制迭代优化插补过程<sup>[25]</sup>。Wang 等人提出的 STA-GAN（Spatio-Temporal Attention Generative Adversarial Network）将时空注意力机制与 GAN 结合，用于卫星数据缺失值插补，但在处理大规模监测网络时计算效率较低<sup>[26]</sup>。总体而言，GAN 类方法在生成分布真实性方面表现优异，但存在训练不稳定、收敛缓慢及高缺失率下性能下降等问题<sup>[27]</sup>。

Transformer 类方法中, Du 等人提出的 SAITS (Self-Attention-based Imputation for Time Series) 通过两个对角掩码自注意力 (DMSA) 块捕捉时间依赖与特征相关性, 成为当前插补任务的强基线方法<sup>[28]</sup>。Liu 等人提出的 iTransformer 将注意力与前馈网络应用于反转维度, 将时间点嵌入变量标记以更好地捕捉多变量相关性与非线性表示, 但在无外部特征变量场景下性能优势有限<sup>[29]</sup>。Nie 等人提出了 ImputeFormer 模型, 通过低秩性诱导的 Transformer 架构有效融合了低秩模型的结构先验与深度学习的表达能力, 实现了高效且通用化的时空数据缺失值插补<sup>[30]</sup>。Transformer 类方法的核心优势在于并行计算能力与长程依赖建模, 但其置换不变性特征要求引入位置编码以保留序列顺序信息, 且在处理空间异质性时仍需额外的空间建模组件。

混合方法是近年来的研究热点, 旨在融合统计方法的可解释性与深度学习的拟合能力。Yuan 等人提出的 AIA-Net 整合基于注意力的时间感知动态插补与间隔辅助时间感知模块, 自适应建模时间依赖<sup>[31]</sup>。然而, 现有混合方法大多停留在浅层融合层面, 未能深入挖掘统计模型与深度学习架构的互补优势。例如, 变系数模型的动态参数思想可与深度学习的超网络机制结合, 实现系数的自适应生成; 对抗训练的分布约束可与自回归结构融合, 提升插补结果的时空一致性。这方面的系统研究仍较为匮乏, 为本文提供了重要的研究切入点。

### 1.2.3 时空数据缺失机制研究

缺失数据的潜在机制是决定插补方法选择与效果评估的基础。Rubin 最初描述了三种缺失数据机制: 完全随机缺失 (Missing Completely At Random, MCAR, MCAR)、随机缺失 (Missing At Random, MAR) 与非随机缺失 (Missing Not At Random, MNAR)<sup>[32]</sup>。**MCAR** 指数据缺失的概率与任何观测值或未观测值均无关, 缺失完全由偶然因素导致; **MAR** 指缺失概率依赖于其他观测变量 (如时间、位置), 但不直接依赖于当前缺失值本身; **MNAR** 指缺失概率依赖于缺失值本身或外部未观测因素。例如, 在电力监控场景中, 用电高峰期可能因供电不足导致监测站点记录缺失 (**MAR**); 而当 PM2.5 浓度过高时, 传感器表面颗粒堆积可能影响检测组件性能, 导致高值区域更易缺失 (**MNAR**)<sup>[33]</sup>。

除这三种机制外, 实际应用中还经常遇到序列缺失 (Missing In Sequence, MIS) 与块状缺失 (Missing In Block, MIB) 两种模式<sup>[34]</sup>, 这些具有连续性与空间相关性的缺失模式对数据恢复提出了更高要求。**MIS** 指单个站点在特定时间段内连续缺失, 破坏长期时间依赖; **MIB** 指多个站点在同一时段同时缺失, 保留部分局部时

空信息但造成区域性数据空洞<sup>[34]</sup>。这两种模式在环境监测网络中尤为常见，如区域通信中断、极端天气导致的集群设备故障等场景<sup>[35]</sup>。

现有研究大多在开发插补方法时假设特定的缺失机制，然而这一假设在真实场景中往往难以成立。Miao 等人提出的半监督生成对抗网络（SSGAN）及 Du 等人提出的自注意力插补方法（SAITS）主要适用于 MCAR 类型缺失，在 MAR 与 MNAR 场景下性能可能显著下降<sup>[22,28]</sup>。Yuan 等人提出的注意力间隔辅助网络（Attention-based Interval Aided Networks, AIA-Net）虽能自适应建模时间依赖，但对 MIB 模式的适应性有限<sup>[36]</sup>。Lin 等人的综述研究指出，当缺失率超过 50% 时，大多数插补方法的性能会出现断崖式下降，这表明现有方法在高缺失率及复杂缺失机制下的鲁棒性仍有待提升<sup>[37]</sup>。因此，开发能够适应多种缺失机制与模式、尤其在高缺失率下保持稳定的插补方法，是当前研究的重要方向。

## 1.3 本文研究内容与结构安排

### 1.3.1 本文研究内容

针对时空数据缺失值插补中面临的非平稳演化特征与物理环境约束两大核心挑战，本文以变系数自回归理论为基础，分别从纯数据驱动的统计建模与融入物理先验的智能建模两个维度展开深入探讨。主要研究内容涵盖以下三个方面：

**（1）时空数据插补与变系数建模的基础理论探究。** 系统梳理变系数模型的核心思想，对比分析基于 B 样条的基函数逼近与基于超网络的参数生成这两种动态建模路径的适用场景；同时，探讨生成对抗网络与注意力机制在时空序列特征提取与分布拟合中的优势，为后续两类插补模型的构建确立坚实的理论基石。

**（2）面向稀疏空间点采样的对抗插补网络（VCAAN）构建。** 针对低维协变量场景下时空序列的非平稳性难题，提出将 B 样条基函数与自回归方程相结合以刻画局部时空动态依赖；在此基础上，引入卷积判别网络并实施对抗训练，以期在一定程度上增强插补结果的分布真实性与时空一致性。并以北京市 PM2.5 监测数据为依托，验证该模型在多种复杂缺失机制及高缺失率条件下的鲁棒性。

**（3）面向复杂地理环境的基于时空注意力的自回归插补网络（STAAN）构建。** 针对高山等复杂地形下气象要素传播所面临的空间各向异性与三维地貌阻断问题，提出一种融合流体力学先验知识的时空对齐机制，通过约束风向一致性、地形迎风增益及物理平流时延以过滤伪相关噪声；配合时空注意力超网络强大的解耦与高维特征映射能力，实现复杂异构协变量驱动下的动态参数自适应生成。最后，利用



瑞士高山气象数据集评估该模型在应对区域空间相关缺失等极端场景时的物理推断效能。

### 1.3.2 本文结构安排

本文共分为五章，各章节的具体内容安排如下：

**第1章：绪论。** 主要阐述本文的研究背景及理论与实际应用意义，系统回顾国内外在时空数据缺失机制、传统统计插补方法以及深度学习插补模型等方面的研究现状，指出当前研究面临的局限性，并由此引出本文的主要研究内容与整体结构安排。

**第2章：相关理论概述。** 全面梳理支撑本研究的核心理论与技术框架，重点辨析变系数模型中基于基函数逼近与超网络参数生成两种路径的技术特点，同时简要介绍生成对抗网络与自注意力机制的数学原理，为后续两个插补模型的提出提供方法论依据。

**第3章：基于稀疏空间点采样的对抗插补网络。** 详细阐述 VCAAN 模型的构建逻辑与算法细节，包括利用 B 样条逼近时变系数的生成器设计、卷积判别网络的结构以及两阶段交替对抗训练策略。随后，基于真实的 PM2.5 数据集开展多场景对比与消融实验，探讨该模型在低维协变量下的插补表现与局限性。

**第4章：基于时空注意力的自回归插补网络。** 针对复杂物理环境下的高维非线性插补难题，系统介绍 STAAN 模型的框架设计。重点剖析包含风向一致性与物理时延等约束的时空对齐机制，以及时空注意力超网络对时序与空间特征的解耦提取过程。最后，利用高山气象数据集评估模型在极端空间缺失模式下的物理一致性与插补精度。

**第5章：结论。** 对全文的研究工作与阶段性成果进行客观总结，并结合实际业务需求与现有模型的不足，对未来可能的优化方向（如算法轻量化设计、物理演化动态适应性等）进行展望。

## 第2章 相关理论概述

时空数据普遍具有显著的非平稳性与空间异质性，传统常系数模型难以捕捉其动态结构，且现有深度学习方案在分布真实性与长程依赖建模上仍存在局限。为突破上述技术瓶颈，构建高精度插补模型亟需引入更具灵活性的统计框架与先进架构作为理论支撑。本章将系统梳理支撑本文研究的核心理论基础，涵盖变系数模型中基于基函数逼近与超网络参数生成的方法论，生成对抗网络的对抗训练范式，以及 Transformer 架构的全局依赖建模能力，旨在明确各理论在时空建模中的适用场景，为后续章节提出针对性的插补模型奠定方法论基础。

### 2.1 变系数模型理论基础

时空数据往往表现出显著的非平稳性与空间异质性。传统的常系数模型假设回归参数在整个时空域内保持恒定，难以捕捉环境变量随时间演变或空间位置变化而产生的动态结构。为此，变系数模型允许模型参数随时间或协变量变化，为时空序列建模提供了更具灵活性的统计框架。

设空间中某点的时间序列观测值为 $y_t$ ，协变量向量为 $x_t$ ，常系数线性模型可表示为 $y_t = x_t^T \beta + \epsilon_t$ 。然而，当时间序列收到潜在的时空状态 $u_t$ （如时间索引或空间位置等）影响时，系数 $\beta$ 应视为 $u_t$ 的函数，即变系数模型可表示为<sup>[38]</sup>：

$$y_t = x_t^T \beta(u_t) + \epsilon_t \quad (2-1)$$

其中， $\beta(\cdot)$ 为未知的系数函数。

变系数建模的核心难点在于如何从有限的样本中稳定地估计 $\beta(\cdot)$ 。本节将分别阐述基于基函数展开的 B 样条逼近方法与基于深度学习的超网络逼近方法，二者构成了本文后续章节方法设计的理论核心。

#### 2.1.1 基于 B 样条的基函数逼近方法

B 样条（B-Spline）逼近是统计学中处理变系数模型的经典方法，其核心思想是将未知的系数函数投影到有限的基函数空间中进行线性表示<sup>[39]</sup>。假设系数函数 $\beta(u)$ 定义在归一化区间 $u \in [0,1]$ 上，利用 $K$ 阶 B 样条基函数 $\{B_k(u)\}_{k=1}^K$ 进行展开，

$$\beta(u) = \sum_{k=1}^K \theta_k B_k(u) = \mathbf{B}(u)^T \boldsymbol{\theta} \quad (2-2)$$

其中,  $\boldsymbol{\theta} = [\theta_1, \dots, \theta_K]^T$  为待估参数向量,  $\mathbf{B}(u)$  为基函数向量。代入上式, 原变系数模型可转化为关于  $\boldsymbol{\theta}$  的线性模型, 可通过最小二乘法或极大似然估计进行求解。

该方法具有以下统计特性:

1. 局部支撑性: 每个基函数仅在局部区间非零, 使得参数估计具有局部适应性, 某区间的异常值不会全局影响系数曲线。
2. 平滑性约束: 通过调整节点数量和阶数, 可控制系数函数的平滑程度, 避免过拟合。
3. 可解释性: 估计出的参数  $\boldsymbol{\theta}$  具有明确的统计意义, 便于分析系数随协变量的变化趋势。

然而, 当协变量  $u$  为高维时空状态 (如包含风向、地形、多变量交互) 时, 张量积样条会导致基函数数量指数级增长 (维数灾难), 限制了其在复杂高维场景下的应用能力。

### 2.1.2 基于超网络的参数生成方法

随着深度学习的发展, 超网络 (Hypernetwork) 为变系数建模提供了非参数化的神经网络逼近方案<sup>[40]</sup>。超网络的核心思想是构建一个主网络负责任务执行, 同时构建一个超网络负责生成主网络的权重参数。

在变系数建模中, 超网络将时空状态  $\mathbf{u}_t$  作为输入, 直接映射为模型系数  $\boldsymbol{\beta}$ 。设超网络为  $h_\phi(\cdot)$ , 参数为  $\phi$ , 则变系数可表示为  $\boldsymbol{\beta}(\mathbf{u}_t) = h_\phi(\mathbf{u}_t)$ , 此时主模型的预测输出为:

$$\hat{y}_t = \mathbf{x}_t^T h_\phi(\mathbf{u}_t) \quad (2-3)$$

通过端到端的反向传播算法, 联合优化超网络参数  $\phi$ , 使得生成系数能够自适应地捕捉  $\mathbf{u}_t$  与数据分布之间的复杂非线性关系。

相较于 B 样条, 超网络逼近具有以下优势与挑战:

1. 高维表达能力: 神经网络万能逼近定理保证了其对任意连续函数的拟合能力, 能够有效处理高维、非线性的时空协变量。
2. 动态适应性: 系数生成过程是动态的, 每个样本时刻均可拥有独立的模型参数, 极大地提升了模型对非平稳过程的刻画能力。
3. 黑盒特性: 生成的系数缺乏显式的数学表达式, 可解释性弱于基函数方法。

## 2.2 生成对抗网络

生成对抗网络(Generative Adversarial Networks, GAN)由 Goodfellow 等于 2014 年提出, 通过对抗训练的方式来使得生成网络产生的样本服从真实数据分布<sup>[21]</sup>。在生成对抗网络中, 有两个网络进行对抗训练。一个是判别网络(Discriminator Network,  $\mathcal{D}$ ), 目标是尽量准确地判断一个样本是来自于真实数据还是由生成网络产生; 另一个是生成网络(Generator Network,  $\mathcal{G}$ ), 目标是尽量生成判别网络无法区分来源的样本。这两个目标相反的网络不断地进行交替训练。当最后收敛时, 如果判别网络再也无法判断出一个样本的来源, 那么也就等价于生成网络可以生成符合真实数据分布的样本。

判别网络 $\mathcal{D}(\mathbf{x}; \phi)$ 的目标是区分出一个样本 $\mathbf{x}$ 是来自于真实分布 $p_r(\mathbf{x})$ 还是来自于生成模型 $p_\theta(\mathbf{x})$ , 因此其本质上是一个二分类器。如果用标签 $y = 1/0$ 分别表示样本来自真实分布/生成模型,  $\mathcal{D}(\mathbf{x}; \phi)$ 的输出为 $\mathbf{x}$ 是来自于真实分布的概率, 即

$$p(y = 1|\mathbf{x}) = \mathcal{D}(\mathbf{x}; \phi) \quad (2-4)$$

判别网络的目标函数为最小化交叉熵, 即

$$\min_{\phi} -(\mathbb{E}_{\mathbf{x}}[y \log p(y = 1|\mathbf{x}) + (1 - y) \log p(y = 0|\mathbf{x})]) \quad (2-5)$$

若分布 $p(\mathbf{x})$ 是由分布 $p_r(\mathbf{x})$ 和分布 $p_\theta(\mathbf{x})$ 等比例混合而成的, 那么上式等价于:

$$\begin{aligned} & \max_{\phi} \mathbb{E}_{\mathbf{x} \sim p_r(\mathbf{x})} [\log \mathcal{D}(\mathbf{x}; \phi)] + \mathbb{E}_{\mathbf{x}' \sim p_\theta(\mathbf{x}')} [1 - \log \mathcal{D}(\mathbf{x}'; \phi)] \\ & = \max_{\phi} \mathbb{E}_{\mathbf{x} \sim p_r(\mathbf{x})} [\log \mathcal{D}(\mathbf{x}; \phi)] \\ & \quad + \mathbb{E}_{\mathbf{z} \sim p(\mathbf{z})} [\log(1 - \log \mathcal{D}(\mathcal{G}(\mathbf{z}; \theta); \phi))] \end{aligned} \quad (2-6)$$

其中 $\theta, \phi$ 分别是生成网络和判别网络的参数。

生成网络的目标刚好和判别网络相反, 即让判别网络将自己生成的样本判别为真实样本:

$$\begin{aligned} & \max_{\phi} \mathbb{E}_{\mathbf{z} \sim p(\mathbf{z})} [\log(\mathcal{D}(\mathcal{G}(\mathbf{z}; \theta); \phi))] \\ & = \min_{\phi} \mathbb{E}_{\mathbf{z} \sim p(\mathbf{z})} [\log(1 - \mathcal{D}(\mathcal{G}(\mathbf{z}; \theta); \phi))] \end{aligned} \quad (2-7)$$

上面的这两个目标函数是等价的。由于当判别网络 $\mathcal{D}$ 以很高的概率认为生成网络 $\mathcal{G}$ 产生的样本是“假”样本, 即 $1 - \mathcal{D}(\mathcal{G}(\mathbf{z}; \theta); \phi) \rightarrow 1$ , 这时目标函数关于 $\theta$ 的梯度反而很小, 从而不利于优化, 因此在实际训练时一般使用前者。

## 2.3 Transformer

Transformer 由 Vaswani 等于 2017 年提出, 是一种完全基于注意力机制的深度学习架构<sup>[41]</sup>。与传统循环神经网络(RNN)和卷积神经网络(CNN)不同, Transformer 摒弃了递归和卷积结构, 通过自注意力机制 (Self-Attention Mechanism) 直接建模序列内部的全局依赖关系。其在处理长序列数据时具有显著的并行计算优势和长程依赖捕捉能力, 已成为时空序列建模的主流骨干网络。

自注意力机制是 Transformer 的核心组件, 旨在计算序列内部不同位置之间的关联权重。设输入序列为  $\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_T] \in \mathbb{R}^{d_x \times T}$ , 其中  $T$  为序列长度,  $d_x$  为输入维度。自注意力机制首先通过三个线性变换将输入映射为查询 (query)、键 (key) 和值 (value) 矩阵:

$$\mathbf{Q} = \mathbf{W}^Q \mathbf{X}, \quad \mathbf{K} = \mathbf{W}^K \mathbf{X}, \quad \mathbf{V} = \mathbf{W}^V \mathbf{X} \quad (2-8)$$

其中  $\mathbf{W}^Q, \mathbf{W}^K \in \mathbb{R}^{d_k \times d_x}$ ,  $\mathbf{W}^V \in \mathbb{R}^{d_v \times d_x}$  为可学习的参数矩阵,  $d_k, d_v$  分别为键/查询和值的维度。然后通过缩放点积注意力计算输出:

$$\text{Att}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}(\mathbf{Q}\mathbf{K}^T / \sqrt{d_k})\mathbf{V} \quad (2-9)$$

其中,  $\mathbf{Q}\mathbf{K}^T$  计算了序列中任意两个位置的相关性得分, 除以  $\sqrt{d_k}$  是为了防止点积的结果过大导致 Softmax 函数进入梯度消失区域。Softmax 函数将得分归一化为概率分布, 表示每个位置在聚合信息时的权重, 最终输出是值矩阵的加权和, 实现了信息的动态筛选与融合。

为了增强模型捕捉不同子空间特征的能力, Transformer 引入了多头注意力机制 (Multi-Head Attention)。该机制将查询、键和值分别投影到  $h$  个不同的低维子空间中, 并行计算注意力, 最后将结果拼接并通过线性变换输出:

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)\mathbf{W}^O \quad (2-10)$$

$$\text{head}_i = \text{Att}(\mathbf{Q}\mathbf{W}_i^Q, \mathbf{K}\mathbf{W}_i^K, \mathbf{V}\mathbf{W}_i^V) \quad (2-11)$$

其中  $h$  为注意力头数,  $\mathbf{W}_i^Q, \mathbf{W}_i^K, \mathbf{W}_i^V$  为第  $i$  个头的三个投影参数,  $\mathbf{W}^O$  为输出投影矩阵。

通过多头机制, 模型能够同时关注来自不同表示子空间的信息, 例如在时空数据中, 某些头可能关注短期时间依赖, 而另一些头可能关注长距离空间关联, 显著提升了模型的表达能力。

由于自注意力机制具有置换不变性 (Permutation Invariance), 即输入序列的顺序变化不会影响输出结果, 因此必须引入位置编码 (Positional Encoding, PE) 以保留序列的顺序信息:

$$\begin{aligned} PE_{(t,2i)} &= \sin(t/10000^{2i/d}) \\ PE_{(t,2i+1)} &= \cos(t/10000^{2i/d}) \end{aligned} \quad (2-12)$$

其中 $t$ 表示序列位置， $i$ 表示维度索引， $d$ 为编码维度。这种编码方式使得模型能够学习到相对位置关系，因为对于任意固定偏移量 $k$ ， $PE_{t+k}$ 可以表示为 $PE_t$ 的线性函数。位置编码直接与输入嵌入向量相加，即可作为模型的最终输入：

$$X_{input} = X_{embedding} + PE \quad (2-13)$$

Transformer 模型通常采用编码器-解码器（Encoder-Decoder）架构。编码器由 $N$ 个相同层堆叠而成，每层包含两个子层：多头自注意力机制和前馈神经网络。解码器在此基础上增加了掩码多头自注意力层和交叉注意力层。每个子层周围均采用了残差连接和层归一化：

$$LayerNorm(x + SubLayer(x)) \quad (2-14)$$

残差连接解决了深层网络中的梯度消失问题，层归一化则加速了模型收敛并提高了稳定性。

与前馈神经网络相比，Transformer 的主要优势在于：

1. 并行计算能力：不再依赖上一时刻状态，可同时计算整个序列，训练效率显著高于 RNN。
2. 长程依赖建模：任意两个位置之间的路径长度为常数，有效缓解了长序列中的信息衰减问题。
3. 灵活的可扩展性：可通过调整注意力掩码适应不同任务，如因果建模或双向编码。

## 2.4 本章小结

本章系统综述了时空数据插补任务所需的核心理论，确立了变系数模型、生成对抗网络及 Transformer 架构三大理论支柱，并辨析了不同逼近方法在局部支撑性、高维表达能力及全局依赖建模上的差异。所梳理的理论内容不仅是独立的知识点，更是后续研究的方法论基石，其中基于 B 样条的基函数逼近方法与生成对抗网络的对抗训练范式将直接应用于第三章模型构建，以解决低维协变量场景下的时空动态依赖与分布一致性问题，而基于超网络的参数生成方法与 Transformer 架构则作为第四章模型的核心组件，结合物理先验信息处理高维非线性时空协变量与长程依赖问题。综上所述，本章明确了各理论方法在时空数据建模中的适用场景，为后续提出针对性的插补模型提供了充分的理论依据与实现路径。

### 第3章 基于稀疏空间点采样的对抗插补网络

时空数据插补的核心挑战在于如何有效捕捉数据的非平稳动态结构，并同时确保生成结果的分布真实性。针对传统常系数模型难以适应环境变量时空演变，以及现有深度学习方案在高缺失率场景下时空一致性不足等问题，本章提出了一种基于变系数自回归的对抗插补网络（VCAAN）。本章首先对时空插补问题进行数学形式化定义，并构建五种缺失机制以模拟真实的复杂业务场景；随后，详细阐述 VCAAN 的模型架构，重点介绍利用 B 样条基函数逼近时变系数的生成器，以及基于卷积结构的判别器，并提出两阶段对抗训练策略以平衡重构误差与分布约束；最后，基于北京市 PM2.5 实际监测数据开展对比实验，从插补鲁棒性、收敛稳定性及泛化能力三个维度验证所提模型的有效性。本章工作旨在确立变系数建模与对抗训练相融合的方法论框架，为后续处理高维复杂协变量场景的研究奠定理论与实践基石。

#### 3.1 问题描述

设研究区域包含  $S$  个站点、 $T$  个观测时刻。记  $\mathbf{Y} = (y_{s,t}) \in \mathbb{R}^{S \times T}$  为原始观测矩阵， $\tilde{\mathbf{Y}} = (\tilde{y}_{s,t})$  为原始真实数据矩阵，模型的插补结果记为  $\hat{\mathbf{Y}} = (\hat{y}_{s,t})$ 。同时，定义观测指示矩阵  $\mathbf{R} = (r_{s,t}) \in \mathbb{R}^{S \times T}$ ：当时空位置  $(s, t)$  有真实观测时  $r_{s,t} = 1$ ；当该位置缺失时  $r_{s,t} = 0$ 。对应的缺失指示矩阵定义为  $\mathbf{M} = \{m_{s,t}\}$ ，其中  $m_{s,t} = 1 - r_{s,t}$ 。

本章的时空插补任务可表述为：在已知观测数据  $\mathbf{Y}$  以及掩码矩阵  $\mathbf{M}$  的条件下，学习映射函数  $\mathcal{F}$  得到插补矩阵  $\hat{\mathbf{Y}}$ ，使其在缺失位置尽可能逼近真实值，优化目标如式(3-1)所示：

$$\min_{\mathcal{F}} \mathbb{E}[\mathcal{L}(\mathcal{F}(\mathbf{Y}, \mathbf{R}), \tilde{\mathbf{Y}})] \quad (3-1)$$

若采用按缺失位置计算的均方误差（Mean Squared Error, MSE）作为损失函数，则优化目标可具体写为式(3-2)：

$$\text{MSE}_{\text{miss}} = \frac{\sum_{s=1}^S \sum_{t=1}^T (\hat{y}_{s,t} - \tilde{y}_{s,t})^2 (1 - r_{s,t})}{\sum_{s=1}^S \sum_{t=1}^T (1 - r_{s,t})} \quad (3-2)$$

为全面评估模型在不同数据缺失场景下的鲁棒性与泛化能力，本文考虑了五种不同的缺失类型，以模拟现实世界监测网络中复杂的数据缺失情况。这五种类型涵盖了三类缺失机制和两类缺失模式。缺失机制指导致数据缺失的潜在统计过程，

而缺失模式则描述缺失值在时空矩阵中的分布形态。图 3-1 展示了这五种缺失机制与模式的特征区别，具体模拟过程描述如下：

1. **MCAR**: 数据缺失的概率独立于任何观测值或未观测值。设定缺失概率为  $\pi$ ，以此控制总体缺失率。
2. **MAR**: 缺失概率依赖于其他观测变量（如时间），但不直接依赖于当前缺失值本身。本文模拟了一种随时间变化的缺失情况，缺失概率由强度函数  $f(t) = \exp(3\sin(\omega t + b))$  模拟，其中  $\omega = 24$  和  $b = 6$  分别代表强度函数的角频率和相位偏移，总体缺失率由缩放参数  $\pi$  控制。
3. **MNAR**: 缺失概率依赖于缺失值本身。具体而言，对于站点  $s$  的时间序列  $y_s$ ，总体缺失率由缩放参数  $\rho$  控制，任何大于  $\bar{y}_s + \rho\sigma_{y_s}$  的数据都被设为缺失，其中  $\bar{y}_s$  和  $\sigma_{y_s}$  分别是该序列的均值和标准差。
4. **MIS**: 缺失指示矩阵中的缺失数据表现为时间维度上的连续长条状。缺失区域以随机出现的长度为  $l = 12$  的线段形式呈现，缩放参数  $\pi$  控制着整体的缺失率。
5. **MIB**: 缺失指示矩阵中的缺失数据呈时空块状分布。缺失区域以随机出现的边长为  $d = 7$  的正方形形式呈现，缩放参数  $\pi$  控制着整体的缺失率。




图 3-1 五种缺失机制与模式的特征区别

### 3.2 算法框架

图 3-2 概括了本研究提出的变系数自回归对抗网络（Varying-Coefficient Autoregressive Adversarial Network, VCAAN）的整体架构。如图示，左侧的两个矩阵分别表示原始不完整观测数据与预插补后的数据。其中，白色区域代表已知观测值，灰色区域表示缺失值，而浅米色区域则显示通过初始算法生成的预填充值。

VCAAN 框架由两个相互制衡的核心组件构成：生成器  $\mathcal{G}$  与判别器  $\mathcal{D}$ 。其中，生成器即变系数自回归模型（Varying-Coefficient Autoregressive, VCA），其核心任



务是在保留时空统计特性的基础上填补缺失位置；判别器即卷积判别网络（Convolutional Discriminator Network, CDN），旨在尽可能准确地区分真实观测值与模型生成的插补值。该框架的总体目标在于：在最小化 VCA 估计误差的同时，增强 CDN 判别任务的难度，从而促使生成器学习到更接近真实分布的数据特征。VCA、CDN 的具体结构及其对抗训练过程的详细阐述见第3.3 至3.5 节。




图 3-2 VCAAN 算法框架

### 3.3 变系数自回归模型

为在缺失值填补过程中充分利用历史观测、未来信息及空间邻近站点之间的相关性，并捕捉时空数据固有的动态依赖结构，本文构建了变系数自回归（Varying-Coefficient Autoregressive, VCA）模型。其数学表达如下：

$$\hat{y}_{s,t} = \sum_{l=-L(\neq 0)}^L \alpha_l(t) \hat{y}_{s,t+l}^{(i)} + \sum_{l=-L}^L \beta_l(t) \sum_{s'=1}^S (w_{s,s'} \hat{y}_{s',t+l}^{(i)}) + \epsilon_{s,t} \quad (3-3)$$

式中各符号含义如下：

1.  $\hat{y}_{s,t}$  为模型对站点  $s$  在时刻  $t$  时 PM2.5 浓度的估计插补值；
2.  $\hat{Y}^{(i)} = (\hat{y}_{s,t}^{(i)})$  为模型在第  $i$  次迭代过程中得到的插补值；特别的， $\hat{Y}^{(0)}$  表示通过初始预插补算法生成的预备数据集；
3.  $w_{s,s'}$  为空间权重矩阵元素，由是通过计算站点  $s$  和  $s'$  的时间序列相关系数计算得到，并规定  $w_{s,s} = 0$  以规避自身的“信息泄露”；
4.  $L$  为最大滞后阶数，决定了模型考虑的历史与未来时间的最大跨度；
5.  $\alpha_l(t)$  和  $\beta_l(t)$  均为随时间变化的系数函数。当  $\alpha_l(t) = \alpha_l$  和  $\beta_l(t) = \beta_l$  时，该模型退化为常系数自回归模型；

6.  $\epsilon_{s,t}$  为随机误差项，假设服从均值为零、方差为  $\sigma_\epsilon^2$  的正态分布，即  $\epsilon_{s,t} \sim \mathcal{N}(0, \sigma_\epsilon^2)$ 。

图 3-3 展示了 VCA 模型的邻域依赖机制，该结构清晰地刻画了模型如何利用周围时空信息进行自回归估计。其中，带有橙色边框的单元格表示待填补缺失值的**目标时刻**；带有紫色边框的单元格分别代表目标站点的**历史与未来时序上下文**；其余颜色根据滞后顺序区分了来自相邻站点  $s'$  的信息：**红色区域**为历史信息，**绿色区域**为当前时刻信息，**蓝色区域**为未来信息。




图 3-3 VCA 示意图

为了简化理论符号的表述，记  $x_{s,t}^{q,(i)}$  与  $\gamma_q(t)$  分别为式(3-3)中特征项 ( $2L$  个  $\hat{y}_{s,t+l}^{(i)}$  以及  $2L + 1$  个  $\sum_{s'=1}^S (w_{s,s'} \hat{y}_{s',t+l}^{(i)})$ ) 及其对应的时变系数，具体定义如下：

$$x_{s,t}^{1,(i)} = \hat{y}_{s,t-L}^{(i)}, \dots, x_{s,t}^{4L+1,(i)} = \sum_{s'=1}^S (w_{s,s'} \hat{y}_{s',t+L}^{(i)}), \quad (3-4)$$

$$\gamma_1(t) = \alpha_{-L}(t), \dots, \gamma_{4L+1}(t) = \beta_L(t), \quad (3-5)$$

故式(3-3)可以重写为如下形式：

$$y_{s,t} = \sum_{q=1}^{4L+1} \gamma_q(t) x_{s,t}^{q,(i)} + \epsilon_{s,t} \quad (3-6)$$

式中,  $\gamma_q(t)$  为位置的时变系数函数, 本文采用 B 样条基函数对其进行逼近。为保证数值稳定性, 本节将时间索引  $t$  替换为归一化时间  $z_t = t/(T+1)$ , 其他部分仍保持  $t$  不变, 即  $\gamma_q(t) = \gamma_q(z_t)$ 。定义等距节点  $\kappa_k = K_T^{-1}k$ , ( $k = -p+1, \dots, K_T+p$ ), 其中  $K_T$  为区间  $(0,1)$  内的节点数量,  $p+1$  是 B 样条函数的阶数。时变系数可通过以下方式近似:

$$\gamma_q(z_t) = B'(z_t)b_q, \quad q = 1, \dots, 4L+1 \quad (3-7)$$

其中,  $B'(z_t)$  是  $p+1$  阶的 B 样条基函数,  $b_q$  为长度为  $(K_T+p)$  长度的待估系数向量。将式(3-7)代入式(3-6), 可得:

$$y_{s,t} = \sum_{q=1}^{4L+1} B'(z_t)b_q x_{s,t}^{q,(i)} + \epsilon_{s,t} \quad (3-8)$$

至此, 原方程中随时间变化的系数项已被转化为仅包含未知参数向量  $\mathbf{b} = [b_1, \dots, b_{4L+1}]'$  的形式, 可直接使用最小二乘或梯度下降法进行求解。

### 3.4 判别器：卷积判别网络

遵循生成对抗网络 (GAN) 的对抗训练范式, 本文设计了卷积判别网络 (Convolutional Discriminator Network, CDN), 旨在与变系数自回归模型 (VCA) 形成博弈, 从而生成更为准确的插补值。

鉴于本研究面向的是时空数据的缺失值插补任务, 若仅基于孤立的时空位置进行训练, 将难以充分捕捉数据点之间潜在的时空依赖关系, 进而导致生成结果的时空一致性评估失效, 最终造成判别器训练无效。因此, 参考深度学习中图像与视频生成的常规策略, 本文将长度为  $\tau$  的连续时间片段视为独立的单个样本。在输入具有  $\tau$  个时间步长的时空数据后, 模型输出一个形状相同的概率矩阵, 每个元素代表对应位置属于插补值的概率。具体而言, 判别器 CDN 映射为  $\mathcal{D} \in \mathbb{R}^{S \times \tau} \rightarrow [0,1]^{S \times \tau}$ , 其中  $S$  表示监测站点数量,  $\tau$  表示连续时间跨度的长度。(在深度学习术语中, 站点的数量也被称为通道数量, 连续时间跨度的长度被称为时间步长。) 在本研究的设定下,  $\tau$  被指定为 24, 意味着将一天内的时序数据作为一个整体进行建模。CDN 的具体网络结构如图 3-4 所示:




图 3-4 CDN 网络结构

首先，输入数据依次通过三个卷积块进行处理，各卷积块内部结构一致，主要由以下四个层级联组成：

1. 卷积层（Convolutional Layer）：采用大小为 3、步长为 1、填充为 1 的一维卷积核。由于特征主要在时间维度上提取，卷积操作沿时间轴滑动，不改变时间步维度上的序列长度。随着网络深度增加，卷积核数量在三个块中逐步递增，分别为 32、64 和 128。
2. 批量归一化层（Batch Normalization）：紧随卷积层之后，用于减少不同层之间输入数据的方差偏移，确保梯度在深度网络中更稳定地传播，并加速模型收敛。
3. 激活函数（Activation Function）：采用修正线性单元（ReLU）作为非线性激活函数，引入非线性特征表达能力。
4. 池化层（Pooling Layer）：应用最大池化操作（Max Pooling），设置卷积核大小与步长均为 2，以降低特征图的空间维度并进行降维特征提取。该操作会将时间步维度上的序列长度减半。

随后，将最后一个卷积块的输出展平（Flatten），并依次传入两个全连接层（Fully Connected Layers, FC）：第一个全连接层使用 ReLU 作为激活函数，并施加 Dropout 正则化（即随机“丢弃”部分神经元），以防止过拟合；第二个全连接层采用标准形式，以 Sigmoid 激活函数输出  $S$  个站点的“插补概率”。最终，这些概率值在第二个维度上进行广播扩展，使每个站点的评估概率重复  $\tau$  次，以匹配输入矩阵的维度。这一设计使得 CDN 能够为每个站点在全天时间内提供一致的缺失值评估，量化该站点的时间序列与真实观测分布不符的概率。

该设计主要基于以下两点考量：其一，通过全连接层对特征进行压缩，能够以更简洁的形式捕捉全局时空特征，避免逐点预测可能带来的局部过度拟合或一致性问题；其二，本研究的核心目标在于优化生成器 VCA，其关键并非要求判别器达到绝对准确的二分类能力，而是为其提供分布级的反馈信号，引导生成器逼近真实数据分布。因此，在保证判别有效性的前提下，简洁的网络结构与高效的计算效率是 CDN 设计的优先原则。

### 3.5 对抗训练

本节详细阐述变系数自回归对抗网络（VCAAN）的具体训练算法，其核心在于生成器（VCA）与判别器（CDN）的交替对抗优化。算法 3-1 概括了整体的训练流程，主要步骤包括基于观测数据的预训练及后续的对抗博弈训练。

算法 3-1 对抗训练算法

**输入：**待插补观测数据矩阵 $\mathbf{Y}$ 、预插补数据 $\hat{\mathbf{Y}}^{(0)}$ 、缺失指示矩阵 $\mathbf{M}$ 、最大迭代次数 $K$ 、收敛精度阈值 $\xi$ 以及动态对抗权重参数（初始值 $\lambda_0$ 与衰减步长 $\delta_\lambda$ ）

**输出：**最终插补结果矩阵 $\hat{\mathbf{Y}}$

---

```

1.  $L'_1 \leftarrow \inf, L'_{12} \leftarrow \inf$  /* 初始化损失
2. For  $i \leftarrow 1$  to  $K$  do
3.    $\hat{b}^{(i)} \leftarrow \arg \min_b L_1^{(i)}$  /* 更新 VCA
4.    $\hat{\mathbf{Y}}^{(i)} \leftarrow \sum_{q=1}^{4L+1} B'(z_t) b_q x_{s,t}^{q,(i)}$ 
5.   if  $|L_1^{(i)} - L'_1| < \xi$  then
6.     break
7.   end if
8.    $L'_1 = L_1^{(i)}$ 
9. end for
10. /* 对抗过程
11. For  $j \leftarrow i + 1$  to  $i + K$  do
12.    $\hat{\phi}^{(j)} \leftarrow \arg \min_\phi L_2^{(j)}$  /* 更新 CDN
13.    $\hat{b}^{(j)} \leftarrow \arg \min_b L_{12}^{(i)}$  /* 更新 VCA
14.    $\hat{\mathbf{Y}}^{(j)} \leftarrow \sum_{q=1}^{4L+1} B'(z_t) b_q x_{s,t}^{q,(j-1)}$ 
15.   if  $|L_{12}^{(j)} - L'_{12}| < \xi$  then
16.     break
17.   end if
18.    $L'_{12} = L_{12}^{(j)}$ 
19. end for
20. return  $\hat{\mathbf{Y}} = \hat{\mathbf{Y}}^{(j)}$ 

```

---

训练过程分为以下的两个阶段：

**第一阶段：VCA 预训练** 首先，遵循第3.1节的定义，利用真实观测位置（即缺失指示矩阵 $\mathbf{M}$ 中对应元素为0的位置）上的均方误差对VCA进行独立初始化训练。该阶段的优化目标如式(3-9)所示：

$$L_1^{(i)} = \sum_s \sum_t (1 - m_{s,t}) \left( y_{s,t} - \sum_{q=1}^{4L+1} B'(z_t) b_q x_{s,t}^{q,(i)} \right) \quad (3-9)$$

式中， $b = [b_1, \dots, b_{4L+1}]'$ 及特征项 $x_{s,t}^{q,(i)}$ 的定义见式(3-8)。若相邻项次迭代间模型损失的变化量低于预设收敛阈值 $\xi$ ，或达到预设最大迭代次数，则该阶段提前终止。所得到的插补值将作为后续对抗训练的初始状态。

**第二阶段：对抗训练优化** 随后，进入VCA与CDN的交替优化循环，具体步骤如下：

1. 判别 CDN 更新：在第 $j$ 次对抗迭代中，使用上一轮生成器输出的数据 $\hat{Y}^{(j-1)}$ 构建输入样本。判别器旨在最小化二元交叉熵损失以区分真实值与插补值，优化目标如式所示：

$$L_2^{(j)} = \sum_s \sum_t \left\{ m_{s,t} \log \mathcal{D}(\phi, \hat{Y}^{(j-1)})_{s,t} + (1 - m_{s,t}) \log (1 - \mathcal{D}(\phi, \hat{Y}^{(j-1)})_{s,t}) \right\} \quad (3-10)$$

其中， $\mathcal{D}(\cdot)$ 表示判别器输出概率， $\phi$ 为判别器的参数。

2. 生成器 VCA 更新：在生成器的第 $j$ 次更新中，融合重构损失与对抗损失。总损失函数在原始重构损失的基础上引入了动态对抗项，如式所示：

$$L_{12}^{(j)} = L_1^{(j)} - \lambda L_2^{(j+1)} \quad (3-11)$$

此处 $L_1^{(j)}$ 指当前时刻的重构误差， $L_2^{(j+1)}$ 指将本次模型作为下一轮预测值时，当前判别器的判别损失。

为避免重构项与对抗项之间的量级失衡影响优化稳定性，对抗权重 $\lambda$ 采用自适应调整策略。默认取值为 $\lambda_0$ ，并在每次迭代中监测两项损失的比例关系。设定约束条件为 $\lambda L_2 \geq L_1/5$ 。若满足该条件，则保持 $\lambda$ 不变；否则，通过迭代递减 $\delta_\lambda$ 直至约束满足。

训练过程中持续监控损失变化，若损失下降幅度小于收敛阈值 $\xi$ ，则判定模型收敛并提前终止训练。最终的参数状态对应生成的插补结果即为 $\hat{\mathbf{Y}}$ ，代表VCAAN模型的最终输出。

## 3.6 实验与分析

### 3.6.1 研究数据

本章研究采用的 PM2.5 浓度数据来源于北京市环境监测中心管理的 12 个省级监测站点。受复杂地形气候条件、城市热岛效应及快速城市化进程中人为排放等多重因素影响，北京市空气污染物（尤其是 PM2.5）在时空维度上呈现出显著的波动特征。数据集涵盖 2013 年 3 月 1 日至 30 日的小时级 PM2.5 浓度观测值，数值区间为 3 至  $558\mu\text{g}/\text{m}^3$ ，共计 8640 个样本点，原始缺失率约为 0.53%。

图 3-5 展示了各站点 PM2.5 浓度的箱线图统计信息，数据显示下四分位数与上四分位数分别约为  $26\mu\text{g}/\text{m}^3$  和  $152\mu\text{g}/\text{m}^3$ ，且各站点数据均呈现出一定程度的重尾分布特征。为消除不同监测点间 PM2.5 浓度量纲差异的影响，本研究采用 Z-Score 方法对各站点数据进行了标准化处理。

如图 3-6 所示，部分监测点存在较长的连续缺失时段，且某些时刻 PM2.5 浓度波动剧烈，增加了缺失值插补的难度。然而，观测数据亦显示不同监测点间存在相似的变化趋势，这表明利用站点间的时空相关性进行建模具有可行性。




图 3-5 各站点 PM2.5 浓度分布箱线图




图 3-6 各站点 PM2.5 时间序列曲线图

### 3.6.2 实验设置

为验证所提方法的有效性，本章的实验均在统一的硬件与软件环境下完成。硬件平台采用搭载 NVIDIA GeForce RTX 3050Ti 独立显卡的笔记本电脑，中央处理器为 Intel(R) Core(TM) i5-12500H（主频 2.50 GHz）。软件环境基于 Python 3.11 构建，深度学习框架选用 PyTorch 2.5.1（CUDA 版本 12.1），并调用 PyGrinder 0.6.4 工具包进行缺失模式模拟。为确保实验结果的可复现性，所有代码及数据均经过严格版本控制。

为了全面评估本文提出的 VCAAN 模型性能，本研究选取了七种主流的时空数据缺失值填补方法作为基准（Baseline）进行对比分析。这些对比方法涵盖了传统统计学习与深度学习方法两类：

1. **传统统计方法：**包括 MICE、KNNI 和 LOCF。
2. **深度学习方法：**包括 GRUD、SSGAN、SAITS 和 iTransformer。

所有模型的超参数均通过网格搜索在预设范围内选取最优配置。具体设置如下：

1. **传统统计方法：**MICE 的最大迭代次数从集合{10,20,30}中筛选；KNNI 中的最近邻数量 $k$ 设定为{1,2,3,4,5}；LOCF 无需特定参数调整。
2. **深度学习方法：**GRUD 与 SSGAN 的循环神经网络隐藏层单元数{32,64,128}中选择。SAITS 与 iTransformer 涉及更多架构参数，其中 Transformer 编码器层数、注意力头数、查询/键维度、值维度、嵌入维度以及中间前



馈网络维度分别从 $\{2,4\}$ ,  $\{2,4\}$ ,  $\{4,8\}$ ,  $\{4,8,16,32\}$ ,  $\{8,16,32\}$ ,  $\{8,16,32\}$ ,  $\{32,64,128\}$ 中进行组合搜索。上述四种深度模型的最大训练轮次均从 $\{50,100,150,200\}$ 中确定。

3. **本文提出的 VCAAN 模型：**初始阶段使用简单的 LOCF 算法进行数据预填充。变系数自回归模块中 B 样条基函数的阶数在 $\{3,4,5\}$ 范围内选取。生成器（VCA）与判别器（CDN）采用全批量梯度下降法联合优化，最大训练轮次同样从 $\{50,100,150,200\}$ 中筛选。根据算法流程，关键超参数 $K$ （最大迭代次数）、 $\xi$ （收敛阈值）、 $\lambda_0$ （对抗权重初值）及 $\delta_\lambda$ （权重衰减步长）分别设定为集合 $\{5,10,15,20\}$ ,  $\{0.0001,0.001,0.01\}$ ,  $\{-0.2,-0.1,0,0.1,0.2\}$ 和 $\{0.1,0.2,0.3,0.4,0.5\}$ 中的元素。

### 3.6.3 结果分析

基于第3.6.1节所述实验配置，本文对所提出的 VCAAN 模型与七种主流基准模型进行了系统性对比。图 3-7 展示了在不同缺失类型及五个缺失率水平下，各模型的插补性能分布。

实验结果表明，所提模型在多种缺失机制下均展现出优异的鲁棒性与收敛稳定性。具体而言，在 MCAR（绿色）、MAR（蓝色）及 MIB（橙色）三类缺失场景下，该模型的整体性能均优于对比方法；在 MNAR（红色）场景中，模型性能虽面临更大挑战，但仍保持在前列；而在 MIS（紫色）设置中，尽管该模型始终位居前两名，但在缺失率达到 50% 的高位区间，性能出现轻微波动。总体而言，VCAAN 模型在高缺失率及复杂缺失机制下的优势更为显著，特别是在处理高比例缺失时，其相对于基线模型的改进幅度更加突出，仅在 MNAR 场景下优势相对有限。

进一步的横向分析揭示了模型性能与缺失率及缺失机制之间的内在关联。首先，在固定缺失类型的条件下，当缺失率较低时，传统统计方法凭借其参数稳定性，往往在部分场景下优于基于深度学习的模型；然而，随着缺失率升高，特别是超过 50% 时，基于深度学习的模型凭借强大的非线性拟合能力展现出显著的优越性。其次，在固定缺失率的前提下，考察不同缺失数据类型的影响发现，随着缺失机制的复杂性递增（从完全随机缺失 MCAR 到随机缺失 MAR，再到非随机缺失 MNAR），各类模型的插补性能普遍呈现下降趋势。

值得注意的是，鉴于特定缺失构造参数对结果的敏感性影响，本文未将“不可靠缺失”等极端类型纳入本阶段的详细对比，以确保实验结论的可靠性与普适性。

| Model        | Type | Rate | MCAR   |        |        |        |        | MAR    |        |        |        |        | MNAR   |        |        |        |        |
|--------------|------|------|--------|--------|--------|--------|--------|--------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
|              |      |      | 10%    | 30%    | 50%    | 70%    | 90%    | 10%    | 30%    | 50%    | 70%    | 90%    | 10%    | 30%    | 50%    | 70%    | 90%    |
| MICE         |      |      | 0.1142 | 0.1871 | 0.2273 | 0.7726 | 0.9001 | 0.1319 | 0.3900 | 0.6967 | 0.7606 | 0.8801 | 0.3833 | 0.9423 | 1.3081 | 1.3103 | 1.2833 |
| KNNI         |      |      | 0.0876 | 0.1389 | 0.3184 | 0.3970 | 0.8931 | 0.2053 | 0.4392 | 0.6986 | 0.7322 | 0.7908 | 0.5924 | 0.9919 | 1.2152 | 1.1511 | 1.1177 |
| LOCF         |      |      | 0.1981 | 0.2305 | 0.2797 | 0.3800 | 0.6166 | 0.1160 | 0.2009 | 0.3278 | 0.3452 | 0.6245 | 0.7079 | 0.6715 | 0.8143 | 0.8212 | 1.0028 |
| GRUD         |      |      | 0.1979 | 0.2010 | 0.2134 | 0.2447 | 0.3071 | 0.1540 | 0.1774 | 0.2499 | 0.2681 | 0.3704 | 0.7182 | 0.8650 | 1.0460 | 1.1295 | 1.2037 |
| SSGAN        |      |      | 0.1664 | 0.1674 | 0.1975 | 0.2091 | 0.3073 | 0.1796 | 0.2182 | 0.2305 | 0.2541 | 0.3463 | 0.6568 | 0.8274 | 0.9499 | 0.9526 | 1.0679 |
| SAITS        |      |      | 0.1776 | 0.1685 | 0.1995 | 0.2248 | 0.3612 | 0.1774 | 0.2054 | 0.2815 | 0.3191 | 0.3493 | 0.5935 | 0.6302 | 0.8445 | 0.7473 | 1.0663 |
| iTransformer |      |      | 0.1764 | 0.1680 | 0.1859 | 0.2092 | 0.3096 | 0.2098 | 0.2038 | 0.4378 | 0.6514 | 0.7202 | 0.7242 | 0.8365 | 0.9668 | 0.9166 | 0.9786 |
| VCAAN        |      |      | 0.0581 | 0.0882 | 0.1075 | 0.1478 | 0.1937 | 0.0917 | 0.0971 | 0.1271 | 0.1462 | 0.2094 | 0.4445 | 0.5109 | 0.7603 | 0.7913 | 0.9575 |

| Model        | Type | Rate | MIS    |        |        |        |        | MIB    |        |        |        |        |
|--------------|------|------|--------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
|              |      |      | 10%    | 30%    | 50%    | 55%    | 60%    | 10%    | 30%    | 50%    | 70%    | 90%    |
| MICE         |      |      | 0.1085 | 0.2840 | 0.4324 | 0.3020 | 0.3709 | 0.0657 | 0.1916 | 0.3063 | 0.3940 | 0.7080 |
| KNNI         |      |      | 0.1304 | 0.2697 | 0.5139 | 0.4646 | 0.3813 | 0.0476 | 0.2039 | 0.3156 | 0.4176 | 0.7342 |
| LOCF         |      |      | 0.2439 | 0.5043 | 0.4878 | 0.5161 | 0.5363 | 0.0884 | 0.3704 | 0.4456 | 0.5235 | 0.7771 |
| GRUD         |      |      | 0.1258 | 0.2078 | 0.2002 | 0.2313 | 0.2420 | 0.0739 | 0.2379 | 0.2752 | 0.2752 | 0.5165 |
| SSGAN        |      |      | 0.1506 | 0.1838 | 0.1932 | 0.2031 | 0.2321 | 0.0977 | 0.1826 | 0.2213 | 0.2600 | 0.4239 |
| SAITS        |      |      | 0.1324 | 0.2044 | 0.1995 | 0.2071 | 0.2278 | 0.0540 | 0.1774 | 0.2132 | 0.2308 | 0.4291 |
| iTransformer |      |      | 0.1455 | 0.2128 | 0.2283 | 0.2351 | 0.2508 | 0.0558 | 0.2306 | 0.2147 | 0.3716 | 0.6518 |
| VCAAN        |      |      | 0.1201 | 0.1711 | 0.2196 | 0.2033 | 0.1990 | 0.0458 | 0.1612 | 0.2091 | 0.2080 | 0.3374 |

图 3-7 VCAAN 与七种基准模型实验结果

### 3.6.4 消融实验

为验证 VCAAN 架构中各关键组件的有效性并量化其贡献，本章设计了一系列消融实验。通过系统地移除或替换模型中的核心模块，对比分析了不同变体在 PM2.5 浓度时空插值任务上的性能差异。具体而言，本研究构建了以下对比模型：

(1) 移除对抗机制后的基础模型（仅包含 VCA 组件）；(2) 将自回归系数固定为常数的模型，包括恒系数自回归模型（Constant-Coefficient Autoregressive, CCA）及其对抗网络变体（CCAAN）。此外，为探究初始插补算法对最终结果的影响，本研究评估了七种主流基准模型作为预插补算法的敏感性。

图 3-8 展示了不同缺失机制与缺失率下的模型对比结果。在 MCAR（绿色）、MAR（蓝色）以及 MIB（橙色，缺失率 10%–50%）设置下，完整模型 VCAAN 的性能始终优于其简化版本，仅有少数例外情况（如 MCAR-iTransformer 在 90% 缺失率下及 MIB-SSGAN 在 10% 缺失率下）。在缺失率较高的 MIB 模式（70%–90%）中，排名前三的模型依次为完整 VCAAN、VCA 及 CCAAN。这一趋势表明，引入 VCA 动态系数结构及 CDN 对抗约束对提升整体性能具有积极促进作用。针对 MNAR（红色）和 MIS（紫色）缺失场景，模型优选情况随缺失率变化而呈现一定波动：在 10% 低缺失率下倾向于选择完整 VCAAN；而在 30%–90% 的 MNAR 范围内，CCAAN 表现更为优异；在 MIS 场景中，中等及以上缺失率下则更倾向 VCA 模型。




图 3-8 VCAAN 消融实验结果

此外,关于初始插补算法的鲁棒性分析显示,在 MCAR 和部分 MAR 场景下, VCAAN 及其变体受预填充算法的影响较小,不同初始化策略下的最终性能趋于一致,体现了模型较强的稳定性。相比之下,在 MIS、MNAR 及 MIB 模式中,模型的收敛行为(即跨不同预填充策略的一致性)存在差异。其中,仅在 MNAR 场景下,CCAAN 与完整 VCAAN 展现出相对稳定的性能收敛特性;而在 MIB 模式下,收敛行为则较为敏感。值得注意的是,在处理 MIS、MNAR 及 MIB 缺失数据时,完整模型与 CCAAN 对预填充算法表现出较好的适应性,其中 CCAAN 展现了更多稳定收敛的实例。

为了从统计角度进一步量化改进效果，表 3-1 汇总了各模型相对于基准方法的改进程度统计量（基于均方误差降低百分比）。结果显示，完整 VCAAN 模型的中位改进率为 38.40%，第 75 百分位数为 52.77%，这表明在大多数情况下该模型能显著降低预测误差。然而，四分位距（35.08%）及负改进比例（-13.71%）也反映出模型在部分极端场景下仍对初始值存在一定的依赖性，这为后续优化指明了方向。

表 3-1 消融实验改进率统计

|     | CCA      | VCA     | CCAAN   | VCAAN   |
|-----|----------|---------|---------|---------|
| min | -120.35% | -19.27% | -61.14% | -13.71% |
| 25% | -19.45%  | 16.37%  | 8.79%   | 18.24%  |
| 50% | 5.38%    | 35.17%  | 31.01%  | 38.93%  |
| 75% | 31.62%   | 50.48%  | 40.07%  | 53.32%  |
| max | 71.96%   | 80.71%  | 76.04%  | 81.88%  |

相应的核密度分布图见图 3-9。除 CCA 变体外，其他所有方法的核密度曲线主要分布在参考线右侧（正改进区域），证实了其普遍优于原始算法的特性。其中，CCAAN（绿色曲线）在正区域的峰值最高，与其在更多情况下实现稳定收敛的观察结果相吻合。对于 VCA 和完整模型，尽管其曲线在参考线左侧（负改进区域）有少量延伸，但完整模型的高密度峰值显著高于其他变体。这说明 VCA 能够有效地捕捉原始数据中的动态变化特征，而引入 CDN 对抗约束则进一步拓宽了模型的训练空间，提升了整体泛化能力。




图 3-9 消融实验改进率核密度图

### 3.7 本章小结

本章聚焦于时空数据的非平稳性特征与复杂缺失难题，构建了基于变系数自回归的对抗插补网络（VCAAN）。通过引入 B 样条基函数对时变系数进行逼近，该模型在低维协变量场景下能够较好地捕捉时空序列的动态依赖关系；同时，卷积判别网络与对抗训练机制的引入，在一定程度上增强了生成数据的分布真实性与时空一致性。基于北京市 PM2.5 数据的多场景实验结果表明，VCAAN 在五种不同缺失机制及高缺失率条件下，其整体性能均优于对比的七种主流基准方法，中位改进率达到 38.40%，验证了变系数结构与对抗约束协同优化的有效性。尽管消融实验指出该模型在部分极端缺失场景下对预插补初始值仍具有一定的敏感性，但本章探讨的“变系数自回归结合对抗训练”基础框架，为缓解稀疏空间点采样下的时空序列插补难题提供了一种可行的解决方案。此外，本章关于 B 样条逼近方法的应用经验，也为第四章探索高维非线性协变量场景提供了理论参照与对比基准。

## 第4章 基于时空注意力的自回归插补网络

当研究场景由平坦的城市空间转向地形崎岖的复杂地理环境时，风速等气象要素的传播往往会受到空间各向异性、三维物理屏障阻断及平流耗时等多重因素的制约。由于传统的纯数据驱动类模型普遍缺乏对上述流体动力学常识的感知能力，极易在强非线性场景下产生违背物理规律的推断。鉴于此，本章提出一种基于时空注意力的自回归插补网络（STAAN），力求在深度学习架构中内嵌严格的物理先验约束。本章以瑞士高山气象数据集为研究对象，在明晰多维地理拓扑变量的基础上，构建了包含区域空间相关缺失等三种契合实际故障模式的评测场景；进而详细拆解了 STAAN 的运作机制：一方面通过构建时空对齐自回归模型以显式规范信息传播方向与时延，另一方面借助时空注意力超网络动态输出适配高维协变量的非线性参数。最终的横向对比实验全方位检验了该模型在极端物理环境下的稳健性与高阶推断效能。

### 4.1 问题描述

设研究区域包含  $S$  个监测站点和  $T$  个观测时刻。记  $\mathbf{Y} = (y_{s,t}) \in \mathbb{R}^{S \times T}$  为原始风速观测矩阵， $\tilde{\mathbf{Y}} = (\tilde{y}_{s,t})$  为真实数据矩阵，模型的插补结果记为  $\hat{\mathbf{Y}} = (\hat{y}_{s,t})$ 。此外，引入动态协变量矩阵  $\mathbf{X} \in \mathbb{R}^{S \times T \times d_c}$ （如风向、气压等）和静态地形特征矩阵  $\mathbf{Z} \in \mathbb{R}^{S \times d_g}$ （如海拔、坡度等）。

本章的时空插补任务可表述为：在已知观测数据  $\mathbf{Y}$ 、掩码矩阵  $\mathbf{R}$  以及辅助信息  $(\mathbf{X}, \mathbf{Z})$  的条件下，学习映射函数  $\mathcal{F}$  得到插补矩阵  $\hat{\mathbf{Y}}$ ，使其在缺失位置尽可能逼近真实值。优化目标如式(4-1)所示：

$$\min_{\mathcal{F}} \mathbb{E}[\mathcal{L}(\mathcal{F}(\mathbf{Y}, \mathbf{R}, \mathbf{X}, \mathbf{Z}), \tilde{\mathbf{Y}})] \quad (4-1)$$

若采用按缺失位置计算的均方误差作为损失函数，则优化目标可同样写为第 3 章式(3-2)的形式。

与常规污染物扩散不同，风速插补面临以下三大核心挑战，这对模型构建提出了更高要求：

1. 空间关联的各向异性：风速传播具有极强的方向依赖性，不同于污染物的各向同性扩散。若强制采用无方向性的空间平滑，将引入大量下游无关站点的噪声干扰，因此需显式建模风向与距离的空间加权关系。



2. 三维地貌的物理阻断：山地环境下，山体、坡向等物理屏障会瞬间改变或阻断风流动量交换。即使两点空间距离极近，若存在地形遮挡或处于背风坡，其相关性也将大幅减弱，导致传统欧氏距离失效。
3. 时空对齐的滞后性：风在站点间的平流输送需要物理耗时。若直接建立 $t$ 时刻的跨站点关联，忽略了信号传播的滞后效应（即物理时延），会导致时空信息错位，影响连续缺失场景下的长程依赖恢复。

为系统评估模型在上述复杂场景下的性能，并验证地理先验信息的有效性，本研究基于该数据集的站点地理坐标与地形属性，构建了更具业务针对性的三种缺失模拟模式：完全随机缺失（MCAR）、序列缺失（Sequential Missing, SEQ）和空间相关缺失（Spatially Correlated Missing, SCM），以全面评估模型在复杂物理环境下的鲁棒性。

图 4-1 展示了这三类缺失机制的特征与区别，其构造逻辑、参数设置及算法流程如下。




图 4-1 三种缺失机制的特征与区别

### 1. MCAR

- a) 构造逻辑：模拟设备偶发性故障或数据传输瞬时中断等无规律缺失情形。每个时空点位的缺失状态相互独立，服从同一伯努利分布，不依赖于其他点位或真实观测值。
- b) 构造算法：对观测矩阵 $Y$ 中的每个元素 $(s, t)$ 进行独立伯努利采样，缺失概率为预设总体缺失率 $\pi$ ，即 $P(m_{s,t} = 1) = \pi, \forall s, t$ 。

该方法用于建立极限性能基准, 检验模型在无结构化偏差条件下的基本插补能力。

## 2. SEQ

- a) 构造逻辑: 模拟传感器持续离线、通信链路中断或供电异常导致的“黑障期”。通过交替生成观测段与缺失段的子区间, 构建长程连续缺失, 以检验模型对时间链路的恢复能力。
- b) 构造算法: 假设缺失块长度服从  $\text{Binomial}(n_1, p_1)$ , 观测块的基础长度为  $L_{base}$ , 观测块的额外长度服从二项分布, 已知概率参数为  $p_0$ .
  - i. 估算缺失块数量: 根据目标缺失率  $\pi$  与缺失块期望长度  $\mu_m = n_1 p_1$ , 估算所需缺失块总数  $k \approx (T \cdot \pi) / \mu_m$ .
  - ii. 动态平衡观测化参数: 反向求解观测块二项分布参数  $n_0$ , 使得生成序列总长度接近  $T$ , 满足  $k \cdot \mu_m + (k + 1) \cdot (L_{base} + n_0 p_0) \approx T$ .
  - iii. 块序列生成: 缺失块长度  $\delta_m^{(i)} \sim \text{Binomial}(n_1, p_1)$ ; 观测块长度  $\delta_o^{(i)} = L_{base} + \text{Binomial}(n_1, p_1)$ .
  - iv. 循环移位: 按  $\delta_o^{(1)}, \delta_m^{(1)}, \dots$  的顺序拼接生成初始掩码序列, 并在随机位置进行循环移位, 消除起始点对分布的潜在影响。

## 3. SCM

- a) 构造逻辑: 模拟区域性断电、极端天气或网络分区故障等场景。利用数据集丰富的地理信息, 先将站点划分为若干空间簇, 使同簇站点共享相似的缺失时序模式, 实现“区域集群缺测”的复合效果。
- b) 构造算法:
  - i. 空间簇划分: 基于 K-Means 聚类算法, 选取站点的平面地理坐标  $(X, Y)$  以及数字高程模型获取的海拔高度  $Z$  作为输入人特征, 将所有站点划分为  $K$  个互不重叠的空间簇 (Clusters)。
  - ii. 聚类模板生成, 对每个簇  $k \in \{1, \dots, K\}$ , 以簇编号为随机种子, 调用 SEQ 构造算法生成基础掩码模板  $m_k \in \{0, 1\}^T$ 。
  - iii. 站点级扰动生成: 对于每个站点  $s$ , 以站点索引  $s$  为随机种子, 生成随机噪声掩码  $n_s$ , 其中缺失概率  $\hat{\pi}$  设为较低值 (例如, 0.05)。
  - iv. 逻辑融合: 最终掩码由簇缺失模板与随机噪声掩码按“位或”逻辑运算得到:  $m_{s,t} = \mathbb{I}(m_{c_s,t} = 1 \vee n_{s,t} = 1)$ 。

对于 SCM 缺失而言, 同聚类站点因共享模板种子, 其缺失事件的起始时刻、持续时间与频率在宏观上高度同步; 逻辑或运算确保仅当模板与背景噪声同时判定为缺失时, 该点位才最终缺失, 从而在保留个体差异的同时, 强化了空间维度的



相关性结构。这种构造方式不仅更符合实际业务场景中“区域通信中断”或“区域设备故障”的特征，也为验证模型利用空间先验信息进行联合修复的能力提供了严格的环境。

## 4.2 算法框架

图 4-2 概括了本研究提出的基于时空注意力的自回归插补网络（Spatio-Temporal Attention-based Autoregressive Network, STAAN）的整体算法架构。如图所示，模型的输入层集成了多源异构数据，主要包括原始不完整的风速观测矩阵、缺失指示掩码、站点的三维静态地形特征（如海拔、坡向）以及动态气象协变量（如风向、气压等）。

STAAN 框架旨在实现对高度动态风场的“全域关联感知”与“物理逻辑重构”，其由两个深度协同的核心组件构成：时空注意力超网络（ST-AHN）与时空对齐自回归模型（STAR）。其中，ST-AHN 利用解耦的时空双路注意力机制深度捕捉全局非线性依赖，负责动态推断并输出适用于目标节点的各项变系数参数及预插补清洗值；STAR 则作为硬性物理约束骨架，通过引入风向一致性、地形迎风增益、距离衰减及物理传播时延，对空间邻域特征进行严格的数理对齐与校准。该框架的总体目标在于：将 ST-AHN 的全局注意力特征表示能力与 STAR 刻画的局域流体物理规律相耦合，通过单次前向自回归计算，在保留时空统计一致性的基础上剔除无效背景噪声，从而实现复杂高维场景下缺失值的高精度填补。各核心模块的具体数学推导与联合建模流程详见第4.3 与4.4 节。




图 4-2 STAAN 算法框架

### 4.3 时空对齐自回归模型

针对风速缺失值插补任务，为有效捕捉风场演化的各向异性与物理时延特性，本章提出了一种时空对齐自回归模型（Spatio-Temporal Aligned Autoregression, STAR）。该模型的核心机制在于**显式刻画风场的各向异性**，将风向、距离及海拔等地理拓扑先验映射为自回归方程的结构约束。如图 4-3 所示，STAR 模型不仅融合了目标站点的历史与未来时序信息，还依据风向一致性、地形迎风效应、距离衰减及物理时延等时空对齐准则，筛选并引入邻近站点的风速特征，同时耦合了多源气象因素的影响。




图 4-3 STAR 示意图

对于目标站点  $s$  在时刻  $t$  的风速状态，其受源站点  $s'$  在时刻  $t-l$ （或未来时刻  $t+l$ ）的影响程度取决于风向是否从源站点指向目标站点。定义源站点  $s'$  朝向目标站点  $s$  的地理方位角为  $\Phi_{s',s}$ ，源站点  $s'$  在时刻  $t$  的实际风向为  $\Theta_{s',t}$ ，则两者之间的绝对偏差角为：

$$\Delta \theta_{s',s}(t) = \min(|\Theta_{s',t} - \Phi_{s',s}|, 360^\circ - |\Theta_{s',t} - \Phi_{s',s}|) \quad (4-2)$$

当  $\Delta \theta_{s',s} \approx 0^\circ$  时，表明  $s'$  的风向正吹向  $s$ ；当  $\Delta \theta_{s',s} \approx 90^\circ$  时，表明  $s'$  处于下游位置或因背向气流而无法有效输送动量至  $s$ 。

此外，若目标站  $s$  的坡向  $\Lambda_s$  和入射风向一致，则会产生地形汇聚效应。为此引入时空感知坡向迎风增益  $\mu_{s',s}(t)$ ：

$$\mu_{s',s}(t) = \max\left(0, \cos\left(\frac{\pi}{180} \times |\Theta_{s',t \pm l} - \Lambda_s|\right)\right) \quad (4-3)$$

综合的时空对齐权重  $\tilde{\alpha}_{s',s}(t)$  由方向一致性、距离衰减、海拔落差导致的能量衰减以及地形迎风增益共同构建，如下所示：

$$\tilde{\alpha}_{s',s}(t) = \begin{cases} \cos(\Delta \theta_{s',s}) e^{-\frac{D_{s',s}}{\sigma_d}} e^{-\frac{|z_s - z_{s'}|}{\sigma_z}} \cdot (1 + \lambda_{topo} \mu_{s',s}), & \Delta \theta_{s',s} \leq 90^\circ \\ 0, & else \end{cases} \quad (4-4)$$

其中,  $\cos(\Delta \theta_{s',s})$ ,  $e^{-D_{s',s}/\sigma_d}$ ,  $e^{-|z_s - z_{s'}|/\sigma_z}$  分别表征迎风角余弦相似度、水平距离衰减系数和垂直距离衰减系数。该权重在  $\Delta \theta > 90^\circ$  时强制归零, 从而在数理层面剔除背向无效特征, 构建了一张动态生成的、具有流体导向性的时空感知稀疏图。

同时, 气流从  $s'$  传输至  $s$  需要经历一定的时间偏移  $\tau$ 。定义  $s'$  向  $s$  的有效传输速度为:

$$v_{s',s}^{eff} = \max(y_{s',t \pm l} \cdot \cos(\Delta \theta_{s',s}), \epsilon_v) \quad (4-5)$$

由此, 气流穿越距离  $D_{s',s}$  所需的离散时空感知时延  $\tau_{s',s}(t)$  (以采样间隔  $T_{gap}$  为单位) 为:

$$\tau_{s',s}(t) = \frac{D_{s',s}}{T_{gap} \cdot v_{s',s}^{eff}} \quad (4-6)$$

在建模滞后/超前阶数  $l$  时, 需确保源站点  $s'$  在  $l$  阶时刻的风速与物理传导耗时  $\tau_{s',s}(t)$  相吻合。为此建立高斯核形式的时延对齐核  $\Omega$ :

$$\Omega(l, \tau_{s',s}) = \exp\left(-\frac{(l - \tau_{s',s})^2}{\sigma_\tau}\right) \quad (4-7)$$

综上, 将上述各时空先验代入统计自回归插补公式, 得到时空对齐自回归模型:

$$\begin{aligned} \hat{y}_{s,t} = & \sum_{l=-L(\neq 0)}^L A_{s,l}(t) \tilde{y}_{s,t+l}^* \\ & + \sum_{l=-L(\neq 0)}^L \beta_{s,l}^{sp}(t) \cdot \left[ \sum_{s' \neq s}^S \Omega(l, \tau_{s',s}) \cdot \tilde{\alpha}_{s',s}(t) \cdot \tilde{y}_{s',t+l}^* \right] \\ & + \gamma_s(t) \cdot \left[ \sum_{\substack{s' \neq s \\ P}}^S \Omega(l, \tau_{s',s}) \cdot \tilde{\alpha}_{s',s}(t) \cdot \tilde{y}_{s',t}^* \right] \\ & + \sum_{p=1}^P B_{s,p}(t) \cdot x_{s,t}^{(p)} \end{aligned} \quad (4-8)$$

其中,  $A_{s,l}(t)$ ,  $\beta_{s,l}^{sp}(t)$ ,  $\gamma_s(t)$ ,  $B_{s,p}(t)$  均为时变系数函数;  $A_{s,l}(t) \tilde{y}_{s,t+l}^*$  为自身惯性项, 刻画站点自身的历史和未来趋势惯性;  $\Omega \cdot \tilde{\alpha} \cdot \tilde{y}^*$  为时空传导项, 利用满足流向下游且平流耗时匹配条件的邻站风速数据;  $\gamma_s(t)$  为瞬时对流项, 衡量几乎同一时刻 ( $l =$

0) 整个风场的共性;  $\tilde{y}_{s',t+l}^*$  为混合预插补值, 定义为  $\tilde{y}^* = ry + (1-r)y^{clean}$ , 其中  $y^{clean}$  为超网络生成的预插补值, 以确保在原始观测缺失时仍能进行计算。

#### 4.4 时空注意力超网络

为求解上述物理自回归方程, STAAN 引入了时空注意力超网络 (Spatio-Temporal Attention HyperNetwork, ST-AHN) 以动态生成时变系数。ST-AHN 利用多头注意力机制捕捉风场演化的全局时序依赖与空间拓扑关联, 并将提取的高阶特征映射为 STAR 方程的动态系数及风速的预插补估计值。

如图 4-4 所示, ST-AHN 以多源数据为输入, 首先通过线性映射将原始特征投影至隐藏空间, 同时分别对时间维度施加正弦/余弦位置编码、对站点维度注入可学习的标识嵌入, 以保留时空相对位置信息。随后, 特征序列依次流经时间注意力编码器与空间注意力编码器以实现时空特征解耦, 最终通过三个输出分支分别预测时间系数、风速预插补值以及时空协变量综合特征。




图 4-4 ST-AHN 网络结构图

具体而言, 模型将风速、观测掩码、风向、气象协变量及地形特征拼接为输入张量, 其初始维度记为  $d_X = (1 + 1 + 1 + d_c + d_g)$ 。该张量经线性映射投影至隐藏维度  $d_{model}$  后, 与时间位置编码和站点标识嵌入相加, 形成包含完整时空信息的初始特征表示。其中, 时间位置编码为时间窗口内的  $W$  个采样点注入绝对时序信息, 而站点标识嵌入则使模型能够识别不同站点的地理特异性, 如局部微气候特征或观测设备特性。

在特征编码阶段, 超网络采用解耦的时空双路注意力架构以同时捕捉时序依赖与空间拓扑关联。序列数据首先被重塑为以站点为独立单元的形态  $[B \cdot S, W, d_{model}]$  进入时序注意力分支, 通过多头自注意力机制学习各站点内部的历史演变规律与周期性特征; 随后, 特征被转置为以时刻为切片的瞬时空间场  $[B \cdot$

$W, S, d_{model}]$ 进入空间注意力分支，以捕获全域测站间的空间交互关系。这种时序与空间依次解耦的自注意力设计，不仅保持了全局场特征的学习能力，更将全局注意力计算复杂度从 $O((S \times W)^2)$ 降低至 $O(S \cdot W^2 + W \cdot S^2)$ ，显著提升了大规模监测网络的计算效率。

经时空特征提纯后，最终特征张量通过三个独立的线性投影头映射为物理方程所需参数，并采用 Tanh 激活函数确保输出系数在合理范围内动态变化。其中，清洗预插补头输出 $y^{clean}$ ，用于在原始观测数据缺失导致物理特征输入不足时提供稳健的预测基准；自回归系数头输出 $A_{s,l}(t)$ ，动态调节站点自身历史观测值的权重衰减模式以控制时间平滑度；时空与协变量综合头则输出 $\beta_{s,l}^{sp}(t)$ 、 $\gamma_s(t)$ 及 $B_{s,p}(t)$ ，自适应调整物理先验权重的置信度并提取外生协变量中的非线性修正信息。例如，在风速极低导致物理时延计算不稳定的时段，超网络可自动降低该项权重，转而依赖时间自回归项。这种"物理先验框架+深度学习参数化"的混合架构，使模型在应对复杂地形及高频非平稳风速序列时，展现出优于传统黑盒模型的泛化能力与可解释性。

## 4.5 实验与分析

### 4.5.1 研究数据

本章实验采用瑞士联邦气象与气候办公室 (MeteoSwiss) 通过 Hugging Face 平台公开分享的 PeakWeather 数据集。该数据集涵盖百余个国家气象标准站点，研究区域地形复杂，包含显著的高程变化与多样的地貌特征，能够有效检验模型在复杂地理环境下的适应性。本研究筛选出包含完整 8 个气象变量的 112 个标准气象站作为研究对象。每个站点均配有一组基于 50 米分辨率数字高程模型 (DHM25) 计算得出的静态地形特征，用于精确刻画站点所处的地理环境特性，为后续气象建模提供关键上下文信息。站点静态信息的具体字段及其物理含义如表 4-1 所示。

表 4-1 瑞士数据集站点静态信息

| 列名      | 含义                            |
|---------|-------------------------------|
| Station | 气象站名称                         |
| Lat     | 站点纬度 (单位: 十进制度, °N)           |
| Lon     | 站点经度 (单位: 十进制度, °E)           |
| Height  | 站点海拔高度 (单位: 米)                |
| X       | 瑞士坐标系中的东向坐标 (LV95 坐标系, 单位: 米) |

|        |                            |
|--------|----------------------------|
| Y      | 瑞士坐标系中的北向坐标（LV95 坐标系，单位：米） |
| Z      | 站点的地面高程/裸地海拔（单位：米）         |
| ASPECT | 2 km 范围内的坡向（单位：度）          |
| SLOPE  | 2 km 范围内的坡度（单位：度）          |
| STD    | 2 km 范围内高程的标准差（单位：米）       |
| TPI    | 2 km 范围内的地形位置指数            |
| D_WE   | 2 km 范围内高程在东西方向的偏导数        |
| D_SN   | 2 km 范围内高程在南北方向的偏导数        |

其中，坡向（Aspect）表示最陡下坡方向的方位角，从正北顺时针计算；坡度（Slope）反映地形倾斜程度，数值越大表示地形越陡峭；高程标准差（STD）衡量邻域内高程波动幅度，值越大表明局部地形越复杂；地形位置指数（TPI）定义为当前点高程减去邻域平均高程，正值代表山脊或高地，负值代表谷地或洼地；东西/南北方向偏导数则分别反映相应方向上的地形变化率。这些地形特征对于理解局地微气候、风场通道效应、日照分布及降水格局至关重要，是构建高精度数据驱动气象模型的核心输入变量。

站点的动态观测数据包含 8 个气象变量，具体信息如表 4-2 所示。目标变量为平均风速，其余变量作为协变量参与建模。

表 4-2 瑞士数据站点监测数据信息

| 变量   | 说明                             | 单位  |
|------|--------------------------------|-----|
| 相对湿度 | 地面以上 2 米处的当前相对湿度               | %   |
| 降水   | 过去 10 分钟总降水量                   | mm  |
| 气压   | 站点位置的大气压                       | hPa |
| 日照时数 | 10 分钟内实际日照分钟数                  | Min |
| 气温   | 地面以上 2 米处空气温度                  | ℃   |
| 风向   | 10 分钟内风吹来的循环平均方向（0° =北，90° =东） | °   |
| 阵风峰值 | 过去 10 分钟内出现的 1 秒瞬时最大风速         | m/s |
| 平均风速 | 过去 10 分钟的标量平均风速（非矢量平均）         | m/s |

为了确保实验评估的严谨性与泛化能力的验证，本研究在时间维度上进行了严格的留一时期切分。采用 2023 年 1 月的数据作为训练集（Training Set），用于模型参数学习；2023 年 2 月的数据作为验证集（Validation Set），用于监控过拟合情况并调整超参数；而 2023 年 3 月的春季全时段数据作为独立测试集（Test Set），

用于最终性能评估。这种时间外推的切分策略有效避免了时间泄露，更能反映模型在未见过的气象条件下的适应能力。

#### 4.5.2 实验设置

为确保实验结果的公平性与可复现性，本章所有实验均在统一的软硬件环境下进行。硬件平台为搭载 Apple M4 芯片（24GB 统一内存）的 MacBook Air，软件基于 Python 3.12 与 PyTorch 2.9.1 构建，并利用 Metal Performance Shaders (MPS) 技术加速神经网络计算。此外，本研究开发了专用的缺失模式生成模块，可精确模拟随机缺失（MCAR）、单站时间连续缺失（SEQ）及区域性空间相关缺失（SCM）等多种时空数据缺失场景。

为全面评估 STAAN 模型的性能，本章选取了七种主流方法作为基准，对比体系基本延续第三章设置，涵盖传统统计方法（LOCF、MICE、KNNI）与深度学习模型（GRUD、SAITS、iTransformer）。在此基础上，新增第 3 章的研究成果 VCAAN 作为核心参照，旨在验证本章提出的物理空间对齐与时空全局感知架构的改进效果。值得注意的是，鉴于 SSGAN 在处理大规模高频时空数据时存在训练效率低与收敛缓慢等局限，本研究未将其纳入对比范围。

本研究采用 Optuna 框架对各算法的关键结构超参数进行自动化寻优，旨在确保各模型在不同缺失模式与比例下的对比公平性。其中，对于 SAITS、iTransformer 等深度学习模型，寻优重点在于 Transformer 层数及隐藏层维度；而针对本研究提出的 STAAN 模型，搜索空间进一步涵盖了时间滞后项  $L$  与空间注意力头数等特定参数。至于 LOCF、MICE 及 VCAAN 等经典基准模型，则采用既定的推荐配置，以模拟其在实际业务场景中的典型表现。具体的参数搜索空间、分类选项及取值范围详见表 4-3。

表 4-3 超参数优化表

| 算法           | $d_{model}$ | $n_{head}$ | $n_{layer}/n_{rnn_{size}}$ | $L$     | $d_{fnn}$ | $K$   | $max_{iter}$ | tol    |
|--------------|-------------|------------|----------------------------|---------|-----------|-------|--------------|--------|
| STAAN        | 64/128      | 2/4/8      | 1/2/3                      | 1/2/3/4 |           |       |              |        |
| SAITS        | 32/64       | 2/4        | 2/3                        |         | 64/128    |       |              |        |
| iTransformer | 32/64       | 2/4        | 2/4                        |         | 64/128    |       |              |        |
| GRUD         |             |            | 32/64                      |         |           |       |              |        |
| KNN          |             |            |                            |         |           | 3/5/7 |              |        |
| MICE         |             |            |                            |         |           |       | 10           | 0.001  |
| VCAAN        |             |            |                            |         |           |       | 8            | 0.0001 |

### 4.5.3 结果分析

基于第4.5节的实验配置，本节对 STAAN 模型与七种主流基准方法进行了系统性对比评估。图 4-5 与图 4-6 分别展示了各模型在不同缺失机制及缺失率水平下于训练集和测试集上的插补性能分布。

实验结果表明，STAAN 在多种缺失机制下均表现出优异的鲁棒性与收敛稳定性。在 MCAR 场景下，从训练过程（图 4-5）可见，STAAN 展现出平稳的收敛特性；在测试集上，该模型始终取得最优性能，RMSE 稳定在 2.4~2.7 区间，显著优于传统统计方法（LOCF、KNN）及前期工作 VCAAN。面对 SEQ 场景下时间维度长程连续缺失的挑战，STAAN 始终保持在第一梯队。结合图 4-5 的训练表现分析可知，该模型通过时空注意力超网络有效捕捉了时序依赖的变系数特征，仅在极低缺失率（ $PI=0.1$ ）条件下与基于注意力机制的基线方法 SAITS 性能接近。而在 SCM 场景下，STAAN 展现出更为显著的优势。特别是在缺失率达 50% 的极端条件下（图 4-6 右下角），当基准模型（如 iTransformer）因局部邻域信息严重缺失而导致预测误差急剧上升时，STAAN 仍能维持 2.18 的低误差水平，体现出较强的物理推断能力。总体而言，STAAN 在高缺失率及复杂缺失机制下的优势更为突出，特别是在处理高比例缺失时，相对于基线模型的改进幅度更加显著，充分验证了时空感知架构在应对大规模监测传感器失效场景时的工程可靠性。

进一步的横向分析揭示了模型性能与缺失率及缺失机制之间的内在关联。在固定缺失类型条件下，当缺失率较低时，部分深度学习方法凭借局部拟合能力可取得较好表现；然而随着缺失率升高，特别是超过 50% 时，STAAN 凭借超网络分发的全局变系数机制，展现出显著优于通用模型的非线性外推能力。在固定缺失率前提下考察不同缺失机制的影响，可以发现随着缺失复杂度的递增（由随机缺失 MCAR 至最具破坏性的空间相关缺失 SCM），各类模型的插补性能普遍呈现下降趋势。而 STAAN 则表现出独特的“抗复杂性”特征：在 SCM 模式下其 RMSE 甚至优于 MCAR 场景，这归因于模型能够根据环境条件动态调整搜索阶数，通过时间维度的深度回溯有效补偿了空间信息的缺失。






图 4-5 STAAN 与七种基准模型实验结果（训练集）




图 4-6 STAAN 与七种基准模型实验结果（测试集）

图 4-7 展示了各模型在多种实验场景下的测试集 RMSE 值核密度估计分布。观察分布曲线可以发现，相比于其他基准模型，STAAN 的误差分布曲线显著向左偏移，其概率密度重心集中在 2.0 至 3.0 的低误差区域，而 SAITS、iTransformer 等对比模型的误差分布则主要集中在 3.5 至 4.0 的高误差区间。这表明本文提出的

STAAN 在不同缺失模式与缺失率组合下均能保持更优且更稳定的填充精度。综合实验统计结果显示，STAAN 相较于其他七种对比算法在全场景案例下的平均 RMSE 改进率达到了 26.43%，从统计分布与量化指标双重维度验证了该模型在时空缺失数据补全任务中的显著性能优势。




图 4-7 不同模型在测试集上 RMSE 核密度图

## 4.6 本章小结

本章聚焦于复杂地理环境下风速数据插补所面临的空间各向异性与高维非线性建模挑战，构建了基于时空注意力的自回归插补网络（STAAN）。针对传统数据驱动方法往往忽视地理屏障与流体物理规律的局限性，本章设计了物理引导的时空对齐自回归机制。该机制尝试通过约束风向一致性、地形迎风增益及物理平流时延，在数理模型中融入先验知识，以期缓解空间各向异性与三维地貌阻断对插补结果造成的干扰。同时，模型结合时空注意力超网络，在多源异构高维协变量驱动下，实现了动态系数的生成与全局拓扑依赖的特征提取。

基于真实高山气象数据集的验证结果表明，STAAN 在三种复杂缺失机制及高缺失率条件下，其插补精度较七种主流基准方法及第三章提出的 VCAAN 模型均有提升。综合实验统计显示，STAAN 在全场景案例下的平均均方根误差（RMSE）相较于其他对比算法改进率达到了 26.43%，体现了物理先验约束与注意力机制协同建模的优势。尽管严苛的物理对齐运算在处理超大规模网络时增加了模型训练的计算复杂度，但本章所确立的“物理先验框架结合深度学习参数化”架构，为复杂自然环境下的时空序列高精度插补提供了一种兼顾流体逻辑与数据驱动的新途径。

时空对齐机制的引入不仅是对第三章变系数建模思想的拓展，也反映了本文研究在物理感知智能建模方向的进一步探索与尝试。

## 第5章 结论

本论文聚焦于时空数据缺失值插补任务中普遍存在的非平稳性演化特征与物理环境约束难题，围绕变系数模型理论与深度学习架构展开了探索性研究。针对不同复杂度的协变量场景，本文分别构建了基于对抗训练与基于时空注意力机制的两种自回归插补模型，旨在为环境监测与气象分析等领域的缺失数据恢复提供一定的理论参考与技术支持。本文的主要研究工作与初步结论如下：

(1) **构建了基于稀疏空间点采样的对抗插补网络 (VCAAN)，在一定程度上缓解了低维协变量下的时空非平稳性建模难题。**针对传统变系数模型难以刻画时空动态依赖的局限，本研究尝试引入 B 样条基函数对自回归方程的时变系数进行逼近；同时，为改善生成结果的分布特性，引入了卷积判别网络以实施对抗训练约束。基于北京市 PM2.5 实测数据的多场景实验表明，VCAAN 在应对五种不同缺失机制（尤其是较高缺失率）时，展现出了较为稳健的插补性能。统计结果显示，相较于选定的七种基准方法，该模型实现了 38.40% 的中位误差改进率。这一阶段性工作验证了“变系数结构结合对抗约束”在时空序列插补中的可行性，并为后续复杂场景的建模探索提供了基础基准。

(2) **构建了基于时空注意力的自回归插补网络 (STAAN)，探索了物理先验知识与深度注意力机制的融合途径。**针对复杂山地环境下风速数据插补所面临的时空各向异性与三维地貌阻断问题，本研究设计了物理引导的时空对齐机制，尝试将风向一致性、地形迎风增益及物理平流时延等自然流体规律作为硬性约束嵌入统计方程中。配合时空注意力超网络强大的特征解耦与全局拓扑感知能力，实现了高维气象协变量驱动下的动态参数自适应生成。依托瑞士 PeakWeather 高山气象数据集的实验分析表明，STAAN 在复杂的空间相关缺失等场景下，其平均均方根误差 (RMSE) 较对比算法取得了 26.43% 的相对改进。该工作初步论证了在纯数据驱动模型中引入物理拓扑约束能够在一定程度上过滤伪相关噪声，为物理感知智能建模方向提供了一种新的尝试。

尽管本文在时空数据插补方法上进行了系统的探索，并在两类典型场景下取得了一定的插补精度提升，但受限于研究时间与客观条件，本研究仍存在若干局限性，有待在未来的工作中进一步深化与完善：

(1) **超大规模监测网络下的高阶计算效率瓶颈。**STAAN 模型虽然通过时序与空间依次解耦的双路注意力机制，将全局注意力计算复杂度从  $O((S \times W)^2)$  降低至

$O(S \cdot W^2 + W \cdot S^2)$ ，但为保证物理推断一致性而引入的密集时空对齐核运算，在面对包含上千个节点的超大规模传感器网络或极高频连续采样序列时，依然面临较高的算力与显存压力。后续研究亟需探索更为轻量化的时空算子，例如引入状态空间模型（如 Mamba 架构）或稀疏感知机制，以进一步在空间表征精度与计算开销之间取得平衡。

（2）**面向工业级流式场景的算法工程化部署挑战。**本文的模型评估主要基于静态的留一时期离线数据集展开，侧重于理论建模与后置误差分析。然而，在真实的环境监测与气象业务中，观测网络持续产出高频的流式数据，要求插补算法必须具备毫秒级的在线推断能力，以及应对数据分布偏移的快速适配性。未来亟待探索在线增量学习机制以支持模型的动态热更新，并结合底层算子优化与异构计算加速技术，推进理论模型向高并发、低延迟的工业级算法引擎转化，进而打通从学术探讨到工程落地的最后一公里。

## 致 谢

本学位论文是在导师郑海涛教授的悉心指导下完成的。导师严谨的治学态度、深厚的学术造诣与耐心的循循善诱，使我在科研能力与学术思维上受益匪浅，在此致以最诚挚的谢意。感谢西南交通大学数学学院提供的良好科研平台与学术氛围。感谢同门及好友在研究过程中给予的宝贵建议、技术支持与温暖陪伴。感谢家人一直以来的理解、鼓励与无私支持，是我求学路上最坚实的后盾。

## 参考文献

- [1] Kumar R, Bhanu M, Mendes-Moreira J, et al. Spatio-temporal predictive modeling techniques for different domains: a survey[J]. *ACM Computing Surveys*, 2024, 57: 1-42.
- [2] Coro G, Bove P, Armelloni E, et al. Filling gaps in trawl surveys at sea through spatiotemporal and environmental modelling[J]. 2022, 9.
- [3] Health Effects Institute. State of global air 2024: a special report on global exposure to air pollution and its health impacts[R/OL]. Health Effects Institute, 2024. <https://www.stateofglobalair.org/>.
- [4] Zhu Y, et al. Health effects of PM<sub>2.5</sub> exposure: mechanisms and implications for public health[J]. *Environmental Health Perspectives*, 2021, 129(5): 054001.
- [5] Zhu Y, et al. Challenges and solutions in air quality monitoring data quality assurance [J]. *Environmental Monitoring and Assessment*, 2024, 196: 456.
- [6] Zhang Y, Thorburn P J. Handling missing data in near real-time environmental monitoring: a system and a review of selected methods[J]. *Future Generation Computer Systems*, 2022, 134: 153-167.
- [7] Zhao B, et al. Comprehensive assessment of air pollution impact and sustainable management strategies[J]. *Atmospheric Environment*, 2025, 315: 120543.
- [8] Kumar A, Varija B. Advanced techniques for handling missing data in environmental time series[J]. *Environmental Modelling & Software*, 2024, 175: 105998.
- [9] Van Buuren S, Oudshoorn C G M. Multivariate imputation by chained equations: MICE V1.0 user's manual[J]. TNO Prevention and Health, 2000: 1-20.
- [10] Cover T, Hart P. Nearest neighbor pattern classification[J]. *IEEE Transactions on Information Theory*, 1967, 13(1): 21-27.
- [11] Sims C A. Macroeconomics and reality[J]. *Econometrica*, 1980, 48(1): 1-48.
- [12] Bashir F, Wei H L. Handling missing values in multivariate time series prediction using VAR and neural networks[J]. *Applied Soft Computing*, 2018, 71: 365-379.
- [13] De Boor C. On calculating with B-splines[J]. *Journal of Approximation Theory*, 1972, 6(1): 50-62.
- [14] Cox M G. The numerical evaluation of B-splines[J]. *IMA Journal of Applied Mathematics*, 1972, 10(2): 134-149.

- [15] Luo L, He K, Wu W, et al. Using information criteria to select smoothing parameters when analyzing survival data with time-varying coefficient hazard models[J]. *Statistical Methods in Medical Research*, 2023, 32(9): 1664-1679.
- [16] Troyanskaya O, Cantor M, Sherlock G, et al. Missing value estimation methods for DNA microarrays[J]. *Bioinformatics*, 2001, 17(6): 520-525.
- [17] Koren Y, Bell R, Volinsky C. Matrix factorization techniques for recommender systems [J]. *Computer*, 2009, 42(8): 30-37.
- [18] Che Z, Purushotham S, Cho K, et al. Recurrent neural networks for multivariate time series with missing values[J]. *Scientific Reports*, 2018, 8(1): 6085.
- [19] Ou C, Zhu H, Shardt Y A, et al. Missing-data imputation with position-encoding denoising autoencoders for industrial processes[J]. *IEEE Transactions on Instrumentation and Measurement*, 2024, 73: 1-11.
- [20] Radišić B, Seljan S, Dundjer I. Impact of missing values on the performance of machine learning algorithms[C]. *5th International Conference on Recent Trends and Applications in Computer Science and Information Technology (RTA-CSIT)*, 2023: 54-62.
- [21] Goodfellow I J, et al. Generative adversarial networks[J]. *Advances in Neural Information Processing Systems*, 2014, 27.
- [22] Miao X, Wu Y, et al. Generative semi-supervised learning for multivariate time series imputation[J]. *Proceedings of the AAAI Conference on Artificial Intelligence*, 2021, 35(10): 8983-8991.
- [23] Hu X, Zhang H, Ma D, et al. A tnGAN-based leak detection method for pipeline network considering incomplete sensor data[J]. *IEEE Transactions on Instrumentation and Measurement*, 2020, 70: 1-10.
- [24] Hu X, Zhang H, Ma D, et al. Hierarchical pressure data recovery for pipeline network via generative adversarial networks[J]. *IEEE Transactions on Automation Science and Engineering*, 2021, 19(3): 1960-1970.
- [25] Yuan X, Zhang J, Wang K, et al. Missing data imputation for industrial time series with adaptive median iteration based on generative adversarial networks[J]. *IEEE Sensors Journal*, 2024, 24(21): 35081-35091.
- [26] Wang S, Li W, Hou S, et al. STA-GAN: a spatio-temporal attention generative adversarial network for missing value imputation in satellite data[J]. *Remote Sensing*, 2022, 15(1): 88.



- [27] Brimos P, Seregkos P, Karamanou A, et al. Deep learning missing value imputation on traffic data using self-attention and GAN-based methods[C]. 2024 Panhellenic Conference on Electronics & Telecommunications (PACET), 2024: 1-4.
- [28] Du W, et al. SAITS: self-attention-based imputation for time series[J]. Expert Systems with Applications, 2023, 219: 119619.
- [29] Liu Y, Hu T, Zhang H, et al. iTransformer: inverted transformers are effective for time series forecasting[J]. arXiv preprint arXiv:2310.06625, 2023.
- [30] Nie T, Qin G, Ma W, et al. ImputeFormer: low rankness-induced transformers for generalizable spatiotemporal imputation[C]. Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2024: 2260-2271.
- [31] Yuan X, Xu N, Ye L, et al. Attention-based interval aided networks for data modeling of heterogeneous sampling sequences with missing values in process industry[J]. IEEE Transactions on Industrial Informatics, 2023, 20(4): 5253-5262.
- [32] Rubin D B. Inference and missing data[J]. Biometrika, 1976, 63(3): 581-592.
- [33] Bruun Ipsen C, et al. Effects of PM2.5 exposure on sensor performance and data quality in air quality monitoring networks[J]. Atmospheric Measurement Techniques, 2020, 13: 567-579.
- [34] Du W, et al. TSI-Bench: benchmarking time series imputation methods[J]. arXiv preprint arXiv:2406.12747, 2024.
- [35] Hu M, et al. Regional missing data patterns in environmental monitoring networks: characteristics and implications[J]. Environmental Science & Technology, 2020, 54(15): 9281-9290.
- [36] Yuan H, et al. AIA-Net: attention interval assisted network for time series imputation [J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(8): 7891-7904.
- [37] Lin W C, Tsai C F. Missing value imputation: a review and analysis of the literature (2006–2020)[J]. Artificial Intelligence Review, 2020, 53: 1487-1509.
- [38] Robinson P M. Nonparametric estimation of time-varying parameters[M]// Statistical analysis and forecasting of economic structural change. Springer, 1989: 253-264.
- [39] Schoenberg I J. Contributions to the problem of approximation of equidistant data by analytic functions. Part A. On the problem of smoothing or graduation. A first class of analytic approximation formulae[J]. Quarterly of Applied Mathematics, 1946, 4(1): 45-99.
- [40] Ha D, Dai A, Le Q V. Hypernetworks[J]. arXiv preprint arXiv:1609.09106, 2016.

- [41] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30.

## 攻读博士/硕士学位期间取得的科研成果

包括攻读学位期间发表的论文、专著/译注、专利、作品；参与的科研项目及科研获奖等。  
内容采用 5 号宋体，行距 16 磅，段前后各为 0 磅，具体格式参见 2.10。

### 一、攻读博士/硕士学位期间发表的论文及科研成果

Xiang L, Zheng H. Imputation for spatiotemporal PM2.5 data via varying-coefficient autoregressive adversarial network[J]. Environmental Modelling & Software, 2025, 193: 106564. (中科院二区 SCI)

### 二、参与科研项目/科研获奖等

2023 年华为杯研究生数学建模竞赛国家二等奖