

中国图书分类号_____

密级_____公开_____

国际图书分类号_____

单位代码_____10613_____

西南交通大学

硕士学位论文

基于深度生成模型的邻近空间风速分布推断 和风速序列生成方法

学 科 专 业_____统计学_____

学 号_____2022201650_____

作 者 姓 名_____李旭涛_____

指 导 老 师_____郑海涛_____

学 院_____数学学院_____

2025 年 月 日

A Thesis Submitted to
Southwest Jiaotong University for Master Degree

**Inference of Adjacent Spatial Wind Speed
Distribution and Wind Speed Sequence
Generation Method Based on Deep Generative
Models**

Discipline Statistics

Student ID 2022201650

Author Xutao Li

Supervisor Haitao Zheng

School School of Mathematics

. , 2025

西南交通大学

学位论文独创性声明

本人郑重声明：所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得西南交通大学或其它教育机构的学位或证书而使用过的材料。其他人员对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

本学位论文的主要创新点如下：

1、针对风速数据空间分布稀疏问题。本文提出了一种基于生成式条件分布采样器（GCDS）的邻近空间风速分布推断方法，并推导了模型训练的目标函数和算法流程。所提出的方法不仅可用于拟合风速数据的概率分布，而且能够在没有观测值的情况下推断邻近空间位置的风速概率分布。

2、本文提出了一种基于 GCDS-Transformer 的邻近空间风速序列生成方法。在该方法中提出了一种新的空间-噪声融合编码器神经网络结构用以改进 Transformer 模型来建模时空数据，并将改进的 Transformer 模型与 GCDS 模型相融合并提出 GCDS-Transformer 模型。此外针对该模型设计了无监督学习和有监督学习相结合的多任务联合优化的目标函数。所提出的模型能够在没有观测值的情况下生成邻近空间位置的风速序列数据。

作者签名：_____

日期： 年 月 日

西南交通大学

学位论文使用授权

本学位论文作者完全了解西南交通大学有关保留、使用学位论文的规定，同意学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅。本人授权西南交通大学可以将学位论文的全部或部分内容编入有关数据库进行检索及下载，可以采用影印、缩印、扫描等复制手段保存、汇编本学位论文。

本学位论文属于

1. 保密□，在 年解密后适用本授权书；
2. 不保密☑，使用本授权书。

（请在以上方框内打“√”）

作者签名：_____ 导师签名：_____

日期： 年 月 日

摘 要

风能已成为替代化石燃料发电的重要选择。然而，风能发电主要受气候条件和风电场选址的风速分布影响，因此具有较高的不确定性。尤其是当前风速数据获取主要依赖地面测风塔。由于设备部署成本高、地理条件受限等原因，测风塔的空间分布稀疏，严重制约了风电场选址、风能预测及优化调度等应用。本文针对风速数据空间分布稀疏问题，从邻近空间风速分布推断和风速序列生成两个维度展开研究，并提出了两种创新方法。

首先，本文提出了一种基于生成式条件分布采样器（GCDS）的邻近空间风速分布推断方法。该方法是一种非参数化的条件采样方法，无需假设风速分布的概率函数形式。通过将空间位置和高度等关键要素作为条件变量引入模型，实现了对目标空间位置风速数据的概率分布建模，从而有效解决了无观测数据条件下邻近空间风速分布的推断问题。此外还可通过蒙特卡洛采样方式计算均值、分位数等特征。该方法减少了由传统插值方法引起的误差传递和累积。在数据集上的实验结果表明，该方法对邻近空间的风速分布推断优于传统的分布拟合模型和插值模型。

其次，针对基于 GCDS 的邻近空间风速分布推断方法受到长时序平稳性假设的限制和缺乏时序建模能力的问题。本文又进一步提出了基于 GCDS-Transformer 模型的邻近空间风速序列生成方法。为建模时空序列的相关关系，本文提出一种改进的 Transformer 生成网络结构，改进后的生成网络包含空间-噪声编码器（SNEncoder）和因果时序解码器（CTDecoder）。此外，通过在生成对抗网络目标函数上增加有监督学习的目标函数来提升邻近空间风速序列生成的准确性。实验结果表明，GCDS-Transformer 模型可以有效生成邻近空间位置的风速序列数据。其准确性优于传统的空间插值模型。

关键词： 深度生成模型；分布推断；条件采样；时间序列生成；Transformer

ABSTRACT

Wind energy has emerged as a significant alternative to fossil fuel-based power generation. However, the generation of wind energy is primarily influenced by climatic conditions and the wind speed distribution at wind farm sites, resulting in high levels of uncertainty. Currently, the acquisition of wind speed data mainly relies on ground-based anemometer towers. Due to the high costs of equipment deployment and geographical constraints, the spatial distribution of these towers is sparse, which severely limits applications such as wind farm site selection, wind energy prediction, and optimal scheduling. This thesis addresses the issue of sparse spatial distribution of wind speed data by conducting research from two perspectives: inferring wind speed distributions in neighboring spaces and generating wind speed sequences. Two innovative methods are proposed to tackle these challenges.

Firstly, this thesis proposes a method for inferring wind speed distributions in neighboring spaces based on a Generative Conditional Distribution Sampler (GCDS). This method is a non-parametric conditional sampling approach that does not require assumptions about the probability function form of the wind speed distribution. By incorporating key factors such as spatial location and altitude as conditional variables into the model, it achieves probabilistic distribution modeling of wind speed data at target spatial locations, effectively addressing the inference problem of wind speed distributions in neighboring spaces under conditions of no observational data. Additionally, it enables the calculation of features such as mean and quantiles through Monte Carlo sampling. This method reduces error propagation and accumulation caused by traditional interpolation methods. Experimental results on datasets demonstrate that this method outperforms traditional distribution fitting models and interpolation models in inferring wind speed distributions in neighboring spaces.

Secondly, this thesis further proposes a GCDS-Transformer-based method for generating wind speed sequences in neighboring spaces. This method addresses the limitations of the GCDS-based approach for inferring wind speed distributions in neighboring spaces, which is constrained by the long-term stationarity assumption and lacks temporal modeling capabilities. To capture the correlations in spatiotemporal

sequences, an enhanced Transformer-based generative network architecture is introduced, which consists of a Spatial-Noise Encoder (SNEncoder) and a Causal Temporal Decoder (CTDecoder). Moreover, the accuracy of wind speed sequence generation in neighboring spaces is improved by incorporating a supervised learning objective into the generative adversarial network's loss function. Experimental results demonstrate that the GCDS-Transformer model can effectively generate wind speed sequence data for neighboring spatial locations, achieving higher accuracy compared to traditional spatial interpolation models.

Keywords: Deep Generative Model; Distribution Inference; Conditional Sampling; Time-Series Generation; Transformer

目 录

第1章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 风速分布拟合研究现状	2
1.2.2 时空插值方法研究现状	3
1.2.3 深度生成模型研究现状	4
1.3 本文研究内容与结构安排	6
1.3.1 本文研究内容	6
1.3.2 本文结构安排	7
第2章 相关理论概述	8
2.1 条件概率密度估计和噪声外包引理	8
2.2 生成对抗网络	9
2.3 f-散度族及其变分形式	10
2.4 Transformer	12
2.4.1 多头自注意力机制	13
2.4.2 位置编码	14
2.4.3 Transformer 网络结构	15
2.5 本章小结	16
第3章 基于GCDS的邻近空间风速分布推断方法	18
3.1 问题描述	18
3.2 生成式条件分布采样	19
3.3 基于 GCDS 的风速采样方法	20
3.4 实验与分析	22
3.4.1 数据集介绍	22
3.4.2 实验设置	23
3.4.3 评价指标	23
3.4.4 结果分析	24
3.5 本章小结	29
第4章 基于GCDS-Transformer的邻近空间风速序列生成方法	30

4.1 问题描述	30
4.2 GCDS-Transformer 模型	31
4.3 目标函数和对抗训练	33
4.4 实验与分析	36
4.4.1 数据集介绍	36
4.4.2 实验设置	38
4.4.3 评价指标	38
4.4.4 结果分析	40
4.5 本章小结	44
第5章 结论	45
致 谢	46
参考文献	47
攻读硕士学位期间取得的科研成果	52

第1章 绪论

1.1 研究背景及意义

为了应对全球能源需求的增加,能源危机加剧和气候变化加速,可再生能源的份额在全球能源市场呈指数级增长^[1]。近年来,风能引起了全世界越来越多的关注,由于其储量丰富、分布广泛,同时能减少温室气体的排放,已成为替代化石燃料发电的最重要的替代能源^{[2][3]}。风能发电最重要的特点是不确定性较高,会受到气候条件和所在地理位置的风速的影响。尤其是风力发电机的选址取决于风电场位置的风速分布情况^[4]。风速是一个非常重要的气象因素,也是确定风电场区域风能发电可行性的重要参数^[5]。在寻找潜在的风力发电区域时,测量并收集该区域的风速数值序列和风速分布对评估该区域的风能发电量,以及对风电场的布局优化和发电预测具有重要意义^[6]。风速的可用信息一般分为三种情况:①风速分布和统计信息是完全已知的;②只有当前区域内部分空间位点的风速历史数据可用;③只有部分历史数据和分布族的理论知识可用^[2]。风速分布的拟合质量取决于观测的历史数据的风速时长、空间位点数量,以及风速序列的质量。因此,如何准确获取风速数据,尤其是如何解决风速数据的时空分布问题,已经成为风力发电领域中的一大挑战。

当前,风速数据的获取主要依赖于地面测风塔,这些测风塔通常部署在风电场周围以及一些典型的测量点。然而,由于风速测量设备的成本较高,且部署过程中受到地理、环境等因素的限制,导致测风塔的数量较少,分布较为稀疏^[5]。因此,在许多地区,尤其是偏远区域,风速数据的空间分布呈现较为稀疏的特点。这种数据稀缺性使得基于传统的测风塔数据进行风电场选址、风能预测以及优化调度等应用时面临许多困难,尤其是在没有足够测量点的区域,无法精准的衡量各个空间位点的风速分布情况。

风速数据是一种典型的时空数据。其变化不仅受到时间因素的影响,还与空间分布密切相关。例如一个风电场内相邻地理位置的风速分布会受到所在空间位置、距离地面高度等多种因素的影响^[7]。同时,相邻位置的风速变化往往具有较强的相关性,且空间邻近位置的风速序列变化趋势在短期内相似。因此,如何有效利用已有的稀疏空间位点测风塔收集到的风速观测数据,推测并生成邻近位置的风速分布或风速序列,成为解决风速数据稀缺问题的一项重要任务。本文研究的目标是利用现有稀疏空间位点布置的测风塔收集到的风速观测数据,通过深度生成模型等方法,构建能够有效生成邻近空间位置的风速分布或风速序列的方法。为当前的风

能发电领域提供新的解决方案,不仅能够提高风能评估的准确性,还能为风电场选址、布局优化以及风速、风能发电量预测提供更加准确的数据支撑,推动风能发电行业的发展和进步。

1.2 国内外研究现状

1.2.1 风速分布拟合研究现状

针对风速数据的概率分布拟合研究已取得了长足的发展。这些研究中一般假设收集到的长期风速序列数据是平稳的时间序列,且对于风速数据的分布拟合集中在某一区域内单个空间位点收集到的风速数据。风速分布拟合研究主要分为两类,第一类是研究单分布模型拟合,第二类是研究混合分布模型拟合。单分布模型拟合的优点是模型简洁明了,方便工程技术人员了解有关分布的参数,但同时单分布模型拟合存在拟合优度不足,尤其是针对多峰分布的风速数据时拟合效果较差。例如针对风速是单峰分布情况下,Weibull 分布和 Rayleigh 分布是最广泛被用于拟合风速分布的统计分布模型:Bonfils Safari 等^[8]采用 Weibull 分布和 Rayleigh 分布分别拟合卢旺达部分高海拔地区 10 米高度的风速分布,结果表明 Weibull 分布更接近该地区风速的经验分布;Serban 等^[9]基于 Weibull 和 Rayleigh 分布研究了罗马尼亚加拉蒂县两个地点的风速分布情况,并发现两个地点的风速分布存在差异,其风力发电最大功率也存在较大差异,并得出结论:对风力发电潜力影响最大的是产生最大能量的风速,而不是平均风速或最频繁的风速。此外近年来也有部分学者提出了全新的统计分布拟合模型用以更好的拟合风速数据,例如 Zheng 等^[10]提出双参数威布尔分布主要用于拟合单峰风速概率分布,但其拟合精度较低,适用性不足,因此提出了一种新的分布模型 Falling 模型,相比于其它常用的单峰分布,Falling 分布模型在实验数据上的拟合优度最好。Jia 等^[11]通过使用 Topp-Leone (TL) 家族引入了一个新的 Topp-Leone Lindley (TLL) 分布来研究风速数据的概率分布拟合,在多个站点的长期风速数据上的拟合优度均优于其他传统的概率分布模型。

实际情况中风速数据很可能出现多峰、厚尾等情况,因此仅仅使用单分布模型难以拟合多峰情况下的数据分布。而混合分布正是通常被用以拟合多峰分布的统计模型,其通常由多个单分布组合而成。Jung 等^[12]比较了多种单分布模型组成的混合分布来拟合风速分布,效果较好的有七参数 Burr-广义极值、七参数 dagum-广义极值、六参数广义极值-Weibull 分布等;Zhang 等^[13]在研究极端风速分布时,使用混合极值分布拟合实际风速数据,其拟合结果较好;Khamees 等^[14]使用 Weibull 分布、Gamma 分布和 Lognormal 分布组成的混合分布拟合风速概率分布,与其他

混合分布相比其效果最好；目前各种有限混合分布来拟合经验风速分布。但是它们有两个缺点。首先，不同的分布组件导致不同的拟合性能，很难确定单个分布的最佳类型来构建混合模型。其次，分布组件的数量对混合模型的最终性能有显著影响^[15]。为了克服上述问题，Wang 等^[15]提出一种用于风速分布估计的贝叶斯无限混合模型，提出的模型不仅具有优越的拟合性能，而且自动确定高斯分量的最佳数量。

虽然针对风速数据分布拟合的研究已取得了很多成果，但是仍存在以下问题：第一是目前对风速数据的概率分布拟合主要集中在一维情况即单条风速时间序列，难以处理多个位点风速是时空序列情况下的概率分布；第二是目前主要的分布拟合方法还是以混合分布拟合为主，这就需要假设分布形式和单分布组成数量，不同领域、不同空间位置的时空数据服从的分布形式并不相同，通过主观选择的分布形式会导致拟合误差较大；第三是这些研究都集中在已收集到有观测风速数据上，无法推断邻近空间未观测位点的风速数据分布情况。

1.2.2 时空插值方法研究现状

在时空数据插值研究方面，插值方法主要分为三大类：确定性方法（非统计方法）、地理统计方法和基于机器学习的方法^[17]。其中确定性插值方法主要根据空间数据的相似性和平滑性创建连续的预测表面进行插值；地理统计方法主要以普通克里金（Ordinary Kriging, OK）及其变体组成；基于机器学习的插值方法则是以神经网络等模型为基础建立空间或时空插值方法。

在确定性方法上，Li 等^[18]提出将 IDW 方法扩展到时空数据上，其 IDW 的加权公式保持不变，将其空间距离变为时空距离；Losser 等^[19]提出了一种基于径向基函数的时空插值方法，该方法假设在时空域中插值连续变化现象时，空间和时间维度同等重要。基于克里金改进的时空插值方法关键点在于如何构建时空变异函数，因为时空插值中加入了时间维度，而时间距离和空间距离难以融合，所以在构建时空变异函数与时空距离上存在诸多研究：最为常用的就是积和式时空变异函数，例如李莎等^[20]基于时空变异函数的克里金方法对气温数据进行时空插值；徐爱萍等^[21]研究了时空变异函数和协方差函数的积和模型并将其推导成能够实现的形式，提出了时空权重系数的计算矩阵、基于该矩阵实现了积和模型的时空插值；许美玲等^[22]提出了将时空 Kriging 方法与弹性网算法相结合的新方法，来解决时空变异函数矩阵为病态矩阵无法求逆的问题，并且还进一步提高了时空插值精度。此外还有对时空克里金方法扩展到含有协变量情况下的研究，例如 Hu 等^[23]将协同克里金扩展到时空插值领域，用以插值新疆地区的月平均降水量，并且以月平均空气相对湿度作为协变量，其插值精度相比普通时空克里金方法有所提高。由于时空数据之间存

在复杂的非线性关系和时空自相关性，其传统的确定性时空插值方法和时空克里金插值方法难以拟合时空权重与数据之间的时空关系，因此将机器学习尤其是神经网络与传统方法结合的思路成为时空插值领域新的突破点。Hsieh 等^[24]提出一种基于图的半监督学习的时空插值方法 AQInf，该模型通过时空图构建插值点与邻近时空观测值之间的时空关系，并基于半监督学习方法实现时空插值；Qi 等^[25]提出了一种名为 Deep Air Learning 的方法，该方法实现了插值、预测、特征选择三个功能融为一个神经网络的目标，其中时空插值部分则是通过时空半监督学习完成，该方法可以拟合插值点与领域属性值之间的非线性关系，但是只考虑了目标插值点邻域内的属性值，并没有考虑协变量问题；Ma 等^[26]将 IDW 和双向长短时记忆网络相结合对 PM_{2.5} 进行时空插值，该方法通过双向长短时记忆网络拟合时间序列信息，通过 IDW 网络层实现插值；同时 Ma 等^[27]还提出了一种新的空间插值/外推方法 Geo-LSTM 来生成空气污染物浓度的空间分布，该方法可以同时考虑空气污染的长短时间趋势和空间关联。此外，近些年来的图神经网络在时空数据建模和时空序列预测领域已取得突出的进展，因此众多学者也着手研究时空图神经网络与克里金方法的结合，例如 Appleby 等^[28]提出了一种结合图神经网络和克里金法优势的方法：Kriging Convolutional Networks (KCN)，插值精度相比于传统空间插值方法具有明显提高；Wu 等^[29]提出一种归纳式图克里金神经网络模型 IGNNK，该模型可以有效建模时空数据之间的关系，在多个真实数据集上的插值精度优于 KNN、普通克里金等方法，但是上述的 KCN 和 IGNNK 模型都需要针对特定数据设计特定的邻接矩阵和聚合函数，应用不够灵活；Zheng 等^[30]提出了一种新的时空克里金归纳图表示学习模型，在多个数据集上的实验结果表明，该模型始终优于其他对比方法，当观察到的位置较少时，优势更为显著。

虽然时空插值方法可以预测未观测空间位点的属性值，但是容易受到缺失值、异常值的影响，且插值过程中产生的误差再进行概率分布拟合时会造成误差的传导和累计。此外一些时空插值方法还会出现空间边界效应，即空间点分布在相对边缘且稀疏的位置时，插值效果通常较差，误差较大。

1.2.3 深度生成模型研究现状

深度生成模型是当前最为火热的深度学习和人工智能研究方向之一。深度生成模型可以拟合高维数据的概率分布并且不再假设分布形式，例如可以生成逼真的图像、视频等^[31]。GAN 模型及其思想最先由 Goodfellow 等^[32]提出，其优点是不再假设数据分布形式，而是通过估计一个未知函数将简单分布中采样的数据映射到目标分布上，从而实现在目标分布上采样数据，并且深度生成对抗模型可以有效

地从高维数据中采样,如图片生成等,这是传统统计模型难以完成的,因此 GAN 模型也可以被视作是一种非参数概率密度估计模型;Nowozin 等^[33]在上述研究的基础上总结出 GAN 是变分散度估计方法的特殊情况,提出了基于 f 散度族作为衡量两个分布之间差异性的变分散度生成对抗训练方法,证明了任何 f 散度都可以用于训练生成神经网络采样器;Mao 等^[34]提出初始的 GAN 模型的判别器使用交叉熵损失函数在模型训练过程中会产生梯度消失问题,因此提出了采用最小二乘损失函数作为判别器的最小二乘生成对抗网络 (LSGAN),并且证明了其目标函数等价于最小化 Pearson 卡方散度;针对 GAN 模型训练时会产生梯度消失的问题,Arjovsky 等^[35]提出使用 Wasserstein 距离衡量模型训练过程中生成数据分布与真实数据分布之间的差异性,并从理论和实际数据分析两方面证明了提出的 WGAN 模型可以提高学习的稳定性,摆脱模式崩溃等问题。由于生成对抗方法是通过生成器将噪声变量 z 映射到目标分布空间的变量上,所以无法通过控制 z 的某些维度来控制生成数据的语义特征,即 z 是不可解释的,因此 Chen 等^[36]提出 InfoGAN 模型:将输入生成器的随机噪声分成了两部分:一部分是随机噪声 z ,另一部分是由若干隐变量拼接而成的 latent code c ,其中, c 会有先验的概率分布,可以离散也可以连续,用来代表生成数据的不同特征,该方法可以成功让神经网络学习到可解释的特征表示,例如可以生成指定倾斜度和粗细度的手写数字图片。以上生成对抗模型均是在没有条件变量下的无条件概率密度估计,而实际情况中经常会遇到需要条件密度估计或条件样本生成的场景,因此 Mirza 等^[37]在 GAN 的基础上提出 Condition GAN 方法即 CGAN,该模型引入条件变量可以生成给定条件变量下的响应样本,该方法在条件图像生成、条件文本生成等多领域均有广泛的应用^{[38][39][40]};但是 CGAN 在处理条件变量是连续且高维情况时表现不佳,所以 Zhou 等^[41]提出一种新的生成式条件分布采样器 (GCDS),该方法相对于 CGAN 可以更好地处理高维连续性条件变量的情况,并可运用于条件图像生成、条件概率密度估计、图像补全等诸多场景。

上述研究都是基于生成对抗模型处理类似于图像的截面数据,难以生成具有时间相关性的序列数据,而众多学者也展开了基于生成对抗模型生成时间序列的研究:Esteban 等^[42]提出了一种循环 GAN (RGAN) 和循环条件 GAN (RCGAN) 来生成真实的实值多维时间序列,并展示了它们在医疗数据中的应用;Yoon 等^[43]指出一个好的时间序列数据生成模型应该保留时间动态信息,因此在 GAN 模型基础上引入自回归监督目标函数提出 TimeGAN 模型,通过实际数据实验说明 TimeGAN 可以生成具有时间动态信息的序列数据;Liao 等^[44]受到自回归模型的启发,即对给定过去信息的未来时间序列的条件分布感兴趣,提出了通用的条件

SigWGAN 框架, 此外还提出了条件 Sig-W1 度量, 它捕获了时间序列模型的条件联合定律, 并将其用作鉴别器; Jeha 等^[45]提出了 PSA-GAN, 使用 GAN 和自注意力的渐进式增长生成高质量的长时间序列样本; Qin 等^[46]设计了一个时空生成对抗网络, 在给定一些初始数据和随机噪声的情况下, 可以生成具有逻辑关系的连续时空样本序列, 通过构建空间鉴别器和时间鉴别器来区分生成器生成的样本是否满足时间和空间相关性的要求。此外还有一些研究借助生成对抗模型可以估计高维数据概率密度的优点, 将其运用于马尔可夫性质的检验, 例如 Zhou 等^[47]提出了一种基于深度条件生成学习的高维时间序列马尔可夫性的非参数检验方法, 应用测试来确定马尔可夫模型的阶数。

在上述研究之外, 还有一些研究是基于生成对抗网络及其改进版本以少量空间维度的时空数据估计区域内不同空间点的数据分布情况。Zhu 等^[48]设计了一种新的深度学习架构, 称为条件编码器-解码器生成对抗神经网络 (CEDGANs), 用于空间插值, 其中将编码器-解码器结构与对抗学习相结合, 用以建模采样空间数据的深度表示及其与局部结构模式的相互作用; Xu 等^[49]为了解决车辆遥感数据的空间稀疏性问题, 设计了一种基于 GAN 的数据增强策略, 该策略利用有条件测量数据的先验模型 COPERT 来填充其他位置的缺失数据, 结果表明, 所提出的模型能够有效地模拟给定地区的真实车辆尾气排放分布情况; Zhou 等^[50]首次提出了一种联邦学习框架下的条件 GAN 方法, 用以解决空气质量监测数据缺失且来自于不同数据所有者的问题, 实验结果表明提出的基于 GAN 的插补方法相比于其他方法能够达到最佳的插补效果。虽然以上研究都是针对未观测空间点的数据推断和预测, 但是并不是从数据分布角度出发用以估计其概率分布, 此外也并没有研究空间位置与时间序列的概率分布之间的关系。

1.3 本文研究内容与结构安排

1.3.1 本文研究内容

风资源评估是风电场建设和运营的基础, 其准确性直接影响风电场的选址、设计以及经济效益预测。然而, 传统风资源评估方法依赖于有限且空间分布稀疏的测风塔数据, 难以全面、精确地反映区域风资源的空间分布和时间动态特性。针对这一问题, 本文以从邻近空间风速分布推断和风速序列生成两个维度展开研究, 提出了两种创新方法, 为风电场选址和运行模拟提供了可靠的技术支持。本文的主要研究内容如下:

(1) 基于生成式条件分布采样器 (GCDS) 的邻近空间风速分布推断方法

在风资源评估中,风速的概率分布是评估风能潜力的关键指标。然而,由于测风塔的空间布设密度有限,传统方法仅能基于稀疏的观测数据推断区域风速分布,导致评估结果存在较大误差。针对这一问题,本文提出了一种非参数的生成式条件分布采样器(GCDS)模型。该模型通过引入地理位置和高度等关键特征作为影响风速概率分布的条件变量,能够在没有观测数据的情况下采样邻近空间的风俗数据进而推断该位置的风速分布。

(2) 基于 GCDS-Transformer 的邻近空间风速序列生成方法

尽管 GCDS 模型在空间分布推断方面可以取得不错的效果,但其对长期风速序列的严格平稳性假设和缺乏时间维度数据生成能力的局限性,限制了其在风电场运行模拟的应用。针对这一问题,本文进一步提出了一种基于 GCDS-Transformer 模型的邻近空间风速序列生成方法。GCDS-Transformer 模型结合 GCDS 模型的空间条件生成能力和 Transformer 模型的时序建模能力,突破了 GCDS 模型拟合风速分布时对风速序列平稳性假设的依赖,能够生成邻近空间位置具有时间维度信息的风速序列数据。

1.3.2 本文结构安排

本文结构共分为 5 章,每一章节的主要内容与行文安排如下:

第 1 章:绪论。首先描述了本文研究的背景以及意义。然后梳理和总结了当前对于风速分布拟合、时空插值模型以及深度生成模型的国内外研究现状。最后简要阐述了本文的主要研究内容以及创新性。

第 2 章:相关理论概述。主要介绍了本文研究内容中需要用到的基础理论知识,包括:条件概率密度估计的定义、噪声外包引理、生成对抗网络、f-散度族和变分估计形式、Transformer 模型等。

第 3 章:基于 GCDS 的邻近空间风速分布推断方法。首先介绍了邻近空间风速分布推断问题的描述。然后简要介绍了生成式条件分布采样方法的理论内容,同时详细描述了该章提出的基于 GCDS 的邻近空间风速分布推断方法。最后描述了该方法在实际数据集上的应用以及结果对比等。

第 4 章:基于 GCDS-Transformer 的邻近空间风速序列生成方法。首先介绍了邻近空间风速序列生成问题的描述。然后详细介绍了该章提出的基于 GCDS-Transformer 的邻近空间风速序列生成方法,同时阐述了模型的目标函数推导过程以及对抗训练的算法细节。最后描述了该方法在实际数据集上的应用以及结果对比等。

第 5 章:主要对本文的研究内容进行总结,并给出了未来研究内容的展望。

第2章 相关理论概述

本文的研究内容主要是基于深度条件生成模型推断临近空间位置的风速分布和生成风速序列，因此涉及到条件概率密度估计问题以及时空序列建模问题。本章主要梳理并总结了本文研究内容中需要用到相关基础理论或方法，包括：条件概率密度估计、噪声外包引理（Noise-Outsourcing Lemma）、生成对抗网络（Generative Adversarial Networks, GAN）、 f 散度族（ f -Divergence Family）和变分估计、Transformer 模型等。

2.1 条件概率密度估计和噪声外包引理

对于一组随机向量 (X, Y) ，假设其联合分布为 $(X, Y) \sim P_{X,Y}$ ，其边缘分布分别是 $X \sim P_X$ 和 $Y \sim P_Y$ 。在给定 $X = x$ 的条件下，随机向量 Y 的条件概率分布为 $P_{Y|X=x}$ ，其条件概率密度函数是 $p(y|x) = p(x, y)/p(x)$ 。对于条件概率密度 $p(y|x)$ 的估计是统计学和机器学习中最基本的问题之一。

条件概率生成模型（Conditional Probabilistic Generative Model）是解决该问题的一类模型，这类模型通常根据已观测到的样本 $\{(x^1, y^1), (x^2, y^2), \dots, (x^n, y^n)\}$ 来学习一个参数化模型 $p_\theta(y|x)$ 近似真实条件概率密度 $p(y|x)$ 。由于随机向量 (X, Y) 中的 Y 是高维的且各变量之间存在复杂的依赖关系，因此直接建模 $p_\theta(y|x)$ 较为困难。通常可引入隐变量 z 简化模型，条件密度估计问题可转化为估计随机变量 (x, y, z) 的两个局部条件概率 $p_\theta(z)$ 和 $p_\theta(y|x, z)$ 。为进一步简化模型，可假设隐变量 z 的先验分布是多元标准正态分布 $N(\mathbf{0}, \mathbf{I}_l)$ 且 z 的每一维度都是独立的。因此无需再估计局部条件概率 $p_\theta(z)$ 。此外，条件概率密度估计的一个重要应用是在给定样本 x 的条件下生成样本 y 即条件采样。一般可分为两步进行^[51]：

- （1）根据隐变量的先验分布 $P_\theta(Z)$ 进行采样，得到样本 z ；
- （2）根据条件分布和 $P_\theta(Y|X=x, Z=z)$ 进行采样，得到样本 y 。

其中一种生成样本的思想是首先从隐变量先验分布中采样 z ，同时采样条件变量样本 x ，然后将样本 z 和 x 通过神经网络模型 G 计算后输出样本 $G(x, z)$ 使其服从于条件概率分布 $P_\theta(Y|X=x, Z=z)$ 。该思想的理论基础便是噪声外包引理^[52]：假设 (X, Y) 分别是来自 Borel 可测空间 A 和 B 的两组随机向量， (X, Y) 服从于联合分布 $P_{X,Y}$ ，存在随机变量 $Z \sim U[0, 1]$ 独立于 X ，同时有一个 Borel 函数 G 使得式(2-1)成立：

$$(X, Y) = (X, G(Z, X)) \quad a.s. \quad (2-1)$$

引理中的函数 G 是非唯一的。因此噪声外包引理可归纳为：对于任何标准的 Borel 概率空间 (B, ν) ，存在一个 Borel 函数 $G: [0, 1) \rightarrow B$ 使得当 $Z \sim U[0, 1)$ 时 $G(Z) \sim \nu$ 。Zhou 等^[41]证明了随机变量 Z 可替换为服从于标准多元正态分布的随机向量 $Z \sim N(\mathbf{0}, \mathbf{I}_l)$ ，且 $l \geq 1$ 。

2.2 生成对抗网络

Goodfellow 等^[32]提出的生成对抗网络是深度生成模型中最重要的一类模型，可以学习高维数据的概率分布。生成对抗网络由两个神经网络构成：判别网络 (Discriminator Network) $D_\theta(\cdot)$ 和生成网络 (Generator Network) $G_\phi(\cdot)$ ，如图 2-1 所示。其中 Z 是从标准多元正态分布 $N(\mathbf{0}, \mathbf{I})$ 中采样的随机向量，经过生成网络输出随机向量 $G_\phi(z) \sim P_G$ 使其近似于目标变量的概率分布 P_X 。而判别网络用以分类输入样本是从概率分布 P_G 中采样的样本还是 P_X 中采样的样本。通过这两个网络对抗训练来使得生成网络输出的样本尽可能地服从于真实数据的分布。




图 2-1 生成对抗网络结构示意图

判别网络的目标是判断输入的样本 x 是来自于真实数据的分布 P_X 还是来自于生成网络生成数据的分布 P_G 。即判别网络本质上是一个二分类的神经网络模型， $D_\theta(\cdot)$ 的输出是样本 x 属于真实数据分布 P_X 的概率： $p(D_\theta = 1|x)$ ，属于生成网络生成数据分布的概率： $p(D_\theta = 0|x)$ 。判别网络的目标函数是最小化真实样本和生成样本之间的交叉熵如式(2-2)所示：

$$\min_{\theta} - \left\{ \mathbb{E} \left[D_\theta \log p(D_\theta = 1|x) + (1 - D_\theta) \log p(D_\theta = 0|x) \right] \right\} \quad (2-2)$$

假设样本 x 等比例采样于分布 P_X 和 P_G ，因此等价于式(2-3)即判别网络的目标函数：

$$\max_{\phi} \left\{ \mathbb{E}_{x \sim P_x} [\log D_{\theta}(x)] + \mathbb{E}_{z \sim P_z} [\log(1 - D_{\theta}(G_{\phi}(z)))] \right\} \quad (2-3)$$

生成网络的目标是将隐变量 z 映射到真实数据的概率分布中，即需要判别网络将自己的输出分类到真实数据的概率分布中。其生成网络的目标函数如式(2-4)所示：

$$\min_{\phi} \left\{ \mathbb{E}_{z \sim P_z} [\log(1 - D_{\theta}(G_{\phi}(z)))] \right\} \quad (2-4)$$

综合式(2-3)和式(2-4)便可得到生成对抗网络的目标函数，见式(2-5)。由目标函数可知训练生成对抗网络的目标是通过最小化目标函数来优化生成网络的参数 ϕ ；通过最大化目标函数来优化判别网络的参数 θ 。

$$L = \min_{\phi} \max_{\theta} \left\{ \mathbb{E}_{x \sim P_x} [\log D_{\theta}(x)] + \mathbb{E}_{z \sim P_z} [\log(1 - D_{\theta}(G_{\phi}(z)))] \right\} \quad (2-5)$$

生成对抗网络目标函数中的判别网络等价于衡量真实数据分布 P_x 和生成数据分布 P_g 之间的 JS 散度。将目标函数中的生成网络固定，寻找最优判别网络就等价于最大化目标函数可推导出式(2-6)：

$$L = \int_x [p_x(x) \log D(x) + p_g(x) \log(1 - D(x))] dx \quad (2-6)$$

其中 $p_x(x)$ 表示样本 x 来自真实数据分布的概率， $p_g(x)$ 表示样本 x 来自生成数据分布的概率。要使得式(2-6)最大，需对其求导并得到最优判别网络为式(2-7)：

$$D^*(x) = \frac{p_x(x)}{p_x(x) + p_g(x)} \quad (2-7)$$

将 $D^*(x)$ 代入式(2-5)并推到可得式(2-8)，即 $D^*(x)$ 的目标是最大化分布 P_x 和分布 P_g 之间的 JS 散度，而 $JS(P_x \parallel P_g)$ 越小，说明分布 P_x 和 P_g 越接近也就是生成网络输出的样本分布越接近真实数据分布。

$$L = -\log 4 + 2JS(P_x \parallel P_g) \quad (2-8)$$

2.3 f -散度族及其变分形式

生成对抗网络的判别器本质上是衡量真实数据分布 P_x 和生成数据分布 P_g 之间的 JS 散度， JS 散度是 f 散度族中的一种散度形式^[53]。而 Nowozin 等^[33]提出并证明了任何 f 散度都可以用于训练生成网络采样器即 f -GAN。 f 散度是衡量两个概率分布差异的重要统计量。给定两个概率分布 P 和 Q ， p 和 q 分别是对应于两个分布的概率密度函数，因此可定义 f 散度族 $D_f(P \parallel Q)$ 见式(2-9)：

$$D_f(P \parallel Q) = \int q(x) f\left(\frac{p(x)}{q(x)}\right) dx \quad (2-9)$$

其中 $p(x)/q(x)$ 可表示为 $u = p(x)/q(x)$, $f(u)$ 被称为生成函数, 必须满足以下三个条件:

- (1) $p(x)$ 和 $q(x)$ 分别是服从于概率分布 P 和 Q 连续的密度函数;
- (2) $f(u): \mathbb{R}_+ \rightarrow \mathbb{R}$ 是一个凸下半连续函数;
- (3) $f(1) = 0$ 即 f -散度族是非负的。

常见的 f 散度计算公式与对应的生成函数 $f(u)$ 如下表 2-1 所示。

表 2-1 常见 f 散度计算公式及其生成函数 $f(u)$ ^[33]

f 散度	计算公式 $D_f(P \parallel Q)$	生成函数 $f(u)$
Kullback-Leibler	$\int p(x) \log(p(x)/q(x)) dx$	$u \log u$
Reverse KL	$\int q(x) \log(q(x)/p(x)) dx$	$-\log u$
Pearson χ^2	$\int \frac{(q(x) - p(x))^2}{p(x)} dx$	$(u - 1)^2$
Squared Hellinger	$\int (\sqrt{p(x)} - \sqrt{q(x)})^2 dx$	$(\sqrt{u} - 1)^2$
Jensen-Shannon	$\frac{1}{2} \int p(x) \log \frac{2p(x)}{p(x) + q(x)} + q(x) \log \frac{2q(x)}{p(x) + q(x)} dx$	$-(u + 1) \log \frac{1 + u}{2} + u \log u$
GAN	$\int p(x) \log \frac{2p(x)}{p(x) + q(x)} + q(x) \log \frac{2q(x)}{p(x) + q(x)} - \log(4)$	$u \log u - (u + 1) \log(u + 1)$

f 散度族提供了测量分布 P 和 Q 之间差异的一种方式, 但是在生成对抗网络中不再假设真实数据和生成数据的概率密度函数, 因此无法直接使用各种 f 散度的公式来计算两个分布之间的差异。Nguyen 等^[53]推导出一种计算 f 散度的通用变分方法, 该方法仅需要从分布 P 和 Q 采样数据。

由于 $f(\cdot)$ 是凸函数, 因此设 $f^*(\cdot)$ 是 $f(\cdot)$ 的 Fenchel 共轭函数, 见式(2-10):

$$f^*(t) = \sup_{u \in \text{dom} f} \{ut - f(u)\} \quad (2-10)$$

$\text{dom} f$ 表示函数 $f(\cdot)$ 的定义域即 u 的取值范围, $\sup\{\}$ 表示上确界。 $f^*(\cdot)$ 和 $f(\cdot)$ 互为共轭函数: $f^{**} = f$, 因此有式(2-11):

$$f(u) = \sup_{t \in \text{dom} f^*} \{tu - f^*(t)\} \quad (2-11)$$

将式(2-11)带入式(2-9)可得式(2-12):

$$D_f(P \parallel Q) = \int q(x) f \left[\sup_{t \in \text{dom} f^*} \left\{ t \frac{p(x)}{q(x)} - f^*(t) \right\} \right] dx \quad (2-12)$$

根据 Jensen 不等式, 上式可推导出 $D_f(P \parallel Q)$ 的变分下界如式(2-13)所示:

$$\begin{aligned} D_f(P \parallel Q) &\geq \sup_{T \in \mathcal{T}} \left\{ \int_x T(x) \cdot p(x) dx - \int_x q(x) \cdot f^*(T(x)) dx \right\} \\ &= \sup_{T \in \mathcal{T}} \left\{ \mathbb{E}_{x \sim P} [T(x)] - \mathbb{E}_{x \sim Q} [f^*(T(x))] \right\} \end{aligned} \quad (2-13)$$

其中 $\mathcal{T}$ 是一类可测函数 $T(\cdot): \mathbb{R}^t \rightarrow \mathbb{R}$ 。使用生成对抗网络中的判别网络函数 $D(\cdot)$ 代替式(2-13)中的函数 $T(\cdot)$ 可得 f -GAN 的目标函数。为计算该下界函数, 只需分别在分布 P 和 Q 中小批量采样来逼近期望值, 这两个分布一般在 f -GAN 训练时分别对应真实数据的分布和生成数据的分布。

在式(2-13)中需要考虑不同 f 散度的共轭函数 f^* 及其定义域 $\text{dom} f^*$, 也就是要求可测函数 $T(\cdot)$ 的值域是定义域 $\text{dom} f^*$ 的子集。而在实际应用 f -GAN 的时候一般使用判别网络 $D(\cdot)$ 作为可测函数 $T(\cdot)$, 因此就要求判别网络的输出层激活函数需要满足相应的函数形式。下表 2-2 列举了不同 f 散度的共轭函数 f^* 、定义域 $\text{dom} f^*$ 和对应判别网络的输出层激活函数。

表 2-2 各 f 散度的共轭函数、定义域及其对应的判别网络输出层激活函数

f 散度	共轭函数 $f^*(t)$	定义域 $\text{dom} f^*$	激活函数
Kullback-Leibler	$\exp(t-1)$	$\mathbb{R}$	v
Reverse KL	$-1 - \log(-t)$	$\mathbb{R}_-$	$-\exp(-v)$
Pearson χ^2	$\frac{1}{4}t^2 + t$	$\mathbb{R}$	v
Squared Hellinger	$\frac{t}{1-t}$	$t < 1$	$1 - \exp(-v)$
Jensen-Shannon	$-\log(2 - \exp(t))$	$t < \log(2)$	$\log(2) - \log(1 + \exp(-v))$
GAN	$-\log(1 - \exp(t))$	$\mathbb{R}_-$	$-\log(1 + \exp(-v))$

2.4 Transformer

Transformer 模型由 Google 的研究团队在 2017 年提出^[54], 最初是应用于 seq2seq 的翻译任务并取得了优秀的表现性能。目前火热的生成式预训练大语言模型都是

基于 Transformer 模型架构及其改进构建的。除了在语言模型中的应用,Transformer 模型也被广泛于时间序列/时空序列建模任务中并取得了不错的效果。相较于传统的 RNN 或 CNN 类神经网络结构,Transformer 具有以下优点:第一,RNN 类型的神经网络在处理长时序数据时,会出现梯度消失或梯度爆炸等问题,难以捕捉远距离的时序相关性;CNN 受到卷积核的限制,只能建模区域时段内的时序相关性;而 Transformer 利用自注意力机制可以在所有区域时段内计算任意两个时刻的相关关系,使其可以建模任意长度的时序数据。第二,RNN 类型的神经网络是循环结构,计算时依赖于上一时刻的计算输出,无法并行化处理导致其计算效率低下;而 Transformer 不依赖前后时刻的依赖关系,在训练时可以并行处理整个序列,显著提高了训练速度和效率。第三,由于 Transformer 的核心是自注意力机制,并且其结构分为编码器和解码器,因此在应用于不同的复杂任务场景时具有较强的可扩展性,例如基于 Transformer 编码器的 BERT 模型,基于 Transformer 解码器的 GPT 大语言模型等。

2.4.1 多头自注意力机制

Transformer 的核心是多头自注意力机制 (Multi-Head Self-Attention)。自注意力机制是序列建模中捕捉长距离相关关系和提高并行计算效率的关键。假设存在一组时长为 T , 维度是 d_x 随机向量 $X = [x_1, \dots, x_T] \in \mathbb{R}^{d_x \times T}$, 首先需要将随机向量 X 编码成高维矩阵 Q, K, V , 编码过程详见式(2-14), 式(2-15)和式(2-16)。

$$Q = W_q X \quad (2-14)$$

$$K = W_k X \quad (2-15)$$

$$V = W_v X \quad (2-16)$$

其中 W_q, W_k, W_v 分别是参数矩阵。

自注意力机制的计算过程如式(2-17)所示, d_k 表示高维矩阵 Q 和 K 中列向量的维度, 目的是缩放矩阵 Q, K 乘积计算后的结果, 避免产生梯度消失问题。其中 $\text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)$ 的计算结果被称为注意力得分, 可视为时序向量中任意时刻与其他所有时刻的权重得分。

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-17)$$

为提取时序向量中更多的特征信息, 使模型关注不同的特征子空间, 并避免注意力得分集中在同一时刻, 可以在随机向量 X 编码成高维矩阵 Q, K, V 时进行

m 次线性变换，最后将计算结果拼接在一起。其多头自注意力机制的计算过程如式(2-18)和式(2-19)所示。

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \dots, \text{head}_m) \mathbf{W}^O \quad (2-18)$$

$$\text{head}_i = \text{Attention}(\mathbf{Q} \mathbf{W}_i^Q, \mathbf{K} \mathbf{W}_i^K, \mathbf{V} \mathbf{W}_i^V) \quad (2-19)$$

其中 $\mathbf{W}^O \in \mathbb{R}^{d_m \times m \cdot d_v}$ 是输出投影的参数矩阵， $\mathbf{W}_i^Q \in \mathbb{R}^{d_k \times d_m}$ 、 $\mathbf{W}_i^K \in \mathbb{R}^{d_k \times d_m}$ 、 $\mathbf{W}_i^V \in \mathbb{R}^{d_v \times d_m}$ 均为投影的参数矩阵。多头注意力机制的结构如图 2-2 所示。




图 2-2 自注意力机制和多头注意力机制结构示意图

2.4.2 位置编码

虽然多头自注意力机制可以建模序列数据中任意时刻之间的相关关系，但是自注意力机制计算过程不同于传统的循环神经网络，在其计算过程中并没有保留时序位置信息。因此需要在初始输入模型的序列数据中加入位置编码（Positional Encoding, PE）来保留时序位置信息。位置编码有多种方法，主要分为绝对位置编码和相对位置编码。在原始提出的 Transformer 中使用的位置编码方法是正余弦位置编码，这是一种绝对位置编码方式。

位置编码一般在输入多头自注意力机制之前，并且位置编码的计算结果与输入数据向量具有相同维度，因此可以直接相加。正余弦位置编码的计算方式如式所示。

$$PE_{t,2i} = \sin\left(t/10000^{2i/d_x}\right) \quad (2-20)$$

$$PE_{t,2i+1} = \cos\left(t/10000^{2i/d_x}\right) \quad (2-21)$$

其中 t 表示序列位置， i 表示维度。偶数维度使用正弦曲线编码，奇数维度使用余弦曲线编码。

2.4.3 Transformer 网络结构

Transformer 的网络结构主要由两部分组成，分别是编码器（Encoder）和解码器（Decoder）。无论是编码器还是解码器，都是在多头自注意力机制的基础上叠加而成。其网络结构示意图如图 2-3 所示。




图 2-3 Transformer 结构示意图^[54]

通过图 2-3 可知，Transformer 编码器的输入是经过位置编码后的 Embedding 向量 $\mathbf{x}_{1:S}$ ，输出为向量序列 $\mathbf{H} = [\mathbf{h}_1, \dots, \mathbf{h}_S]$ 。编码器由多个相同的层堆叠而成，每

层包含以下两个子层：①**多头自注意力机制**：通过计算输入序列中各个位置之间的相关性，捕捉全局依赖关系；②**前馈神经网络（Feedforward Neural Network）**：多头自注意力机制的计算结果经过一个前馈神经网络进行非线性变换，通常由两个线性变换和一个激活函数（如 ReLU）组成。每个子层之后都采用残差连接（Residual Connection）和层归一化（Layer Normalization）即图中的 Add&Norm 来确保模型的稳定性和加速训练。

Transformer 解码器负责将编码器的输出通过自回归的方式生成为目标序列。解码器的输入通常是目标序列的 Embedding 向量，经过位置编码后，输入到解码器中。例如在第 t 步时的输入序列为 $y_{0:(t-1)}$ 。在训练过程中，目标序列的 Embedding 向量作为解码器的输入；在推理过程中，解码器会逐步生成输出序列，每一步的输出作为下一步的输入，直到生成完整的序列。解码器的每一层主要由以下三个子层组成：①**掩码多头自注意力机制（Masked Multi-Head Self-Attention）**：该层通过对解码器的输入序列应用掩码，确保每个位置只能关注当前位置之前的 Embedding 向量，从而防止模型在训练时看到当前位置之后的 Embedding 向量。这种方式使模型在生成序列时，仅利用已生成的部分作为自回归模型的条件向量来预测后一个时刻的目标向量。②**交叉注意力机制（Cross-Attention）**：该层通过将解码器的输入映射为查询（Query） q_t ，将编码器的输出映射为键（Key） k 和值（Value） v 进行交叉注意力计算，使解码器能够关注编码器输出的相关部分，从而在生成目标序列时有效利用原始序列的信息。③**前馈神经网络**：该部分与编码器中的前馈神经网络相同。同理，解码器的每个子层后都采用残差连接和层归一化。

Transformer 的整体架构通过堆叠多个编码器和解码器层，实现对输入序列的编码和解码。多头注意力机制使模型能够并行处理序列数据，捕捉全局依赖关系，位置编码则为模型提供序列的时序位置信息。此外，Transformer 中的各个模块也可进行改进和替换，具有极大的可扩展性。

2.5 本章小结

根据本文的研究内容，该章主要介绍了研究内容中需要用到的基础理论知识及相关模型方法。包括条件概率密度估计问题的定义和条件概率生成模型及其相关引理：噪声外包引理；生成对抗网络的原理与模型结构； f -散度族的相关概念和变分散度最小化（Variational Divergence Minimization, VDM）；可以建模长时序数据的神经网络模型 Transformer。以上的理论知识是后续研究内容的重要基础。本文的研究内容主要分为两部分：第一部分是临近空间位置的风速分布与风速

序列生成问题转换为条件概率密度估计问题。并基于生成对抗网络的改进模型 GCDS 用于推断邻近空间位置的风速分布；第二部分是对多头自注意力机制进行改进来建模时空相关性，同时提出了一种新的 Transformer 改进模型并和 GCDS 相结合来生成邻近空间位置的风速序列数据。

第3章 基于 GCDS 的邻近空间风速分布推断方法

风资源评估对于建立风电场和预测其经济效益至关重要。风资源评估的一个关键问题是估计风速的概率分布。地理位置和高度是影响风速的基本要素，尤其是风速随距离地面高度的变化而变化。在传统的风资源评估中，通常将带有测风仪的测风塔安装在给定区域的固定位置。通过风速计收集的风速数据评估该地区的风能潜力。然而，测风塔以及测风仪是分散的。仅仅从几个站点的风速数据分布来评估区域的风能会有很大的误差。因此，在没有观测数据的情况下推断新位置的风速分布十分重要。这是本章要解决的关键问题。本章提出了一种基于生成式条件分布采样器（GCDS）的邻近空间风速分布推断方法。所提出的方法不仅可用于拟合风速数据，而且能够在没有观测值的情况下推断该位置的风速分布。该方法减少了由传统插值方法引起的误差传递和累积。分析结果表明，在关键指标下，该方法优于常用的分布拟合方法和插值模型。

3.1 问题描述

假设存在一组时空数据的随机向量 (S, Y) ，其中 S 是空间位置 $S = \{s_m, m=1, \dots, M\}$ ， Y 是对应于 M 个空间位置的多维时间序列 $Y = \{y_{m,t}, m=1, \dots, M; t=1, \dots, T\}$ 。本章研究内容的想法是基于严平稳时间序列的定义^[55]。当时间序列 $Y = \{y_{m,t}\}$ 满足式(3-1)的条件时是严格平稳的时间序列。

$$(y_{m,1}, \dots, y_{m,t})' \stackrel{d}{=} (y_{m,1+h}, \dots, y_{m,t+h})' \quad (3-1)$$

其中 h 和 t 都是整数，并且 $h \geq 1$ ， $t \geq 1$ 。 $\stackrel{d}{=}$ 表示 $(y_{m,1}, \dots, y_{m,t})'$ 的分布与 $(y_{m,1+h}, \dots, y_{m,t+h})'$ 相同。严格平稳时间序列中任意时刻的值均服从于同一分布。本章的研究致力于建立平稳时间序列的空间位置 S 和相应的分布 P_Y 之间的关系。实际上是将推断不同空间位置的时间序列分布问题转化为推断条件概率分布 $P_{Y|S}$ 的问题。由于在实际情况中时空观测数据的空间点比较稀疏，只有少量的空间位置有观测值 (S^o, Y^o) ，关键问题是推断未观测空间位置 S^u 的概率分布 P_{Y^u} 。因此首先利用已观测数据 (S^o, Y^o) 建立空间位置与时间序列分布之间的关系，然后基于训练好的模型推断第 n 个未观测空间位置 s_n^u 的时间序列 $\{y_{n,t}^u, n=1, \dots, N; t=1, \dots, T\}$ 的概率分布 $P_{Y^u|S^u=s_n^u}$ 。这样就能够推断没有观测值位置的风速概率分布。

3.2 生成式条件分布采样

Zhou 等^[41]提出的生成式条件分布采样器（GCDS）可以更好地处理高维连续型条件变量的情况，例如本章研究内容中的空间位置信息（高度、网格坐标、经纬度坐标等）便是连续型条件变量。GCDS 的目标是基于生成对抗训练的方式寻找一个最优条件生成函数 $G(\cdot)$ 使得 $G(z, x) \sim P_{Y|X=x}$ 。其中 z 是服从于多元标准正态分布的随机向量； Y 是目标随机向量； X 是条件随机向量。条件生成函数 $G(\cdot)$ 的理论基础正是上一章中介绍的噪声外包引理。根据噪声外包引理， $G(Z, X)$ 与 $Y|X$ 的条件分布匹配等价于 $(X, G(Z, X))$ 与 (X, Y) 的联合分布匹配：对于随机向量 (X, Y) ，当且仅当 $P_{G(Z, X)|X} P_X = P_{Y|X} P_X$ 成立时 $P_{G(Z, X)|X} = P_{Y|X}$ 成立，也就是 $P_{X, G(Z, X)} = P_{X, Y}$ 。因此，本章研究的目标是寻找一个条件生成函数 $G(\cdot)$ 使得 $(X, G(Z, X))$ 与 (X, Y) 的联合分布相同。假设存在一个最优条件生成函数 $G^*(\cdot)$ 可以最小化两个联合分布之间的 f 散度 $\mathbb{D}_f(P_{X, G(Z, X)} \| P_{X, Y})$ ，当且仅当 $P_{X, G^*(Z, X)} = P_{X, Y}$ 即 $(X, G^*(Z, X)) \sim (X, Y)$ 时存在式(3-2)。

$$G^* \in \arg \min_G \mathbb{D}_f(P_{X, G(Z, X)} \| P_{X, Y}) \quad (3-2)$$

根据式(3-2)便可构建 GCDS 方法对抗训练生成器和判别器的目标函数。




图 3-1 基于生成式条件分布采样器的风速采样框架图

3.3 基于 GCDS 的风速采样方法

本节将介绍一种基于 GCDS 的风速采样方法。该方法主要由采样步骤、生成网络和判别网络组成。生成网络和判别网络由多个全连接层组成。全连接层的激活函数是 LeakyReLU 函数。需要注意的是由于风速是非负实数，生成网络的最后一层应该使用 ReLU 函数。本章风速采样方法的基本结构如图 3-1 所示。从图 3-1 中可以看出，在模型训练过程中，由两个采样步骤组成：分别是条件向量即空间信息 S^o 和多元标准正态分布 Z 中随机采样 $(s_m^o, z_1, \dots, z_l)$ ，然后进入生成网络计算得到生成的风速样本 $\tilde{y}_{m,t}^o$ ；从空间信息 S^o 和已观测的风速数据 Y^o 中随机采样 $(s_m^o, y_{m,t}^o)$ ，然后与生成风速样本 $(s_m^o, \tilde{y}_{m,t}^o)$ 一起进入判别网络计算用以判别是否是空间信息和真实风速数据的联合分布，最终输出 1 或 0。这里需要注意的是，由于本章的风速采样方法假设长期风速序列是严平稳时间序列即每个时刻的值服从于同一分布。因此生成网络计算出来的样本 $\tilde{y}_{m,t}^o$ 是风速序列时间区间 $[1, T]$ 内任意时刻的值。

由于 f 散度族包含多种散度，本章仅使用最常用的 GAN 模型散度 $\mathbb{D}_{gan}$ 来推导基于 GCDS 的风速采样模型的目标函数。当一组不同地点的风速数据 (S, Y) 服从联合概率分布 $P_{S,Y}$ 即 $(S, Y) \sim P_{S,Y}$ 时，存在两个可测函数 G 和 D 使得式(3-3)成立。其中 S 表示空间位置例如经纬度或网格坐标等； Y 是风速时间序列 $\{y_{m,t}, m=1, \dots, M; t=1, \dots, T\}$ 。

$$\begin{aligned} & \mathbb{D}_{gan}(P_{S,Y} \parallel P_{S,G(Z,S)}) \\ &= \sup_{D \in \mathcal{R}} \left\{ \mathbb{E}_{(S,Y) \sim P_{S,Y}} [\log D(S, Y)] + \mathbb{E}_{(S,Z) \sim P_S P_Z} [\log(1 - D(S, G(Z, S)))] \right\} \end{aligned} \quad (3-3)$$

目标函数的推导过程如下：假设 $u = p_{S,Y}(\omega) / p_{S,G(Z,S)}(\omega)$, $\omega \in \mathbb{R}$ 是联合概率分布 $P_{S,Y}$ 与 $P_{S,G(Z,S)}$ 的密度比。根据表 2-1 可知， f 散度族中的散度 $\mathbb{D}_{gan}$ 函数形式是 $f(u) = u \log u - (u+1) \log(u+1)$ 。由于本章研究不假设风速的概率密度函数，因此需要通过优化散度 $\mathbb{D}_{gan}$ 函数的变分下界来实现目标函数的优化。 $\mathbb{D}_{gan}$ 函数的 Fenchal 共轭函数为式(3-4)。

$$f^*(v) = -\log(1 - \exp(v)), v \in \mathbb{R} \quad (3-4)$$

将该共轭函数代入 f -GAN 鉴别器的目标函数得到式(3-5)。

$$\mathcal{L}_D = \mathbb{E}_{(S,Y) \sim P_{S,Y}} [\psi] - \mathbb{E}_{(S,G(S,X)) \sim P_S P_Z} [-\log(1 - \exp(\psi))] \quad (3-5)$$

其中 ψ 是一个可测函数。这里可以使用 $\psi = \log D$ 便可以得到式(3-3)的目标函数， D 是判别网络函数。

本文使用的 GAN 散度 $\mathbb{D}_{gan}(P_{S,Y} \parallel P_{S,G(Z,S)})$ 等价于衡量联合分布 $P_{X,Y}$ 和 $P_{X,G(Z,X)}$ 之间的 JS 散度，通过式(3-6)可以证明该结论。

$$\begin{aligned}
 & \mathbb{D}_{gan}(P_{X,Y} \parallel P_{X,G(\eta,X)}) \\
 &= \int f\left(\frac{P_{X,Y}(z)}{P_{X,G(\eta,X)}(z)}\right) p_{X,G(\eta,X)}(z) dz \\
 &= \int \{u \log u - (u+1) \log(u+1)\} p_{X,G(\eta,X)}(z) dz \\
 &= \int \{p_{X,Y}(z) \log u - (p_{X,Y}(z) + p_{X,G(\eta,X)}(z)) \log(u+1)\} dz \\
 &= \int \{p_{X,Y}(z) \log u - p_{X,Y}(z) \log(u+1) - p_{X,G(\eta,X)}(z) \log(u+1)\} dz \\
 &= \int \left\{p_{X,Y}(z) \log \frac{u}{u+1} - p_{X,G(\eta,X)}(z) \log(u+1)\right\} dz \\
 &= -\log 4 + \int p_{X,Y}(z) \frac{2P_{X,Y}(z)}{P_{X,Y}(z) + P_{X,G(\eta,X)}(z)} dz + \int p_{X,G(\eta,X)}(z) \frac{2P_{X,G(\eta,X)}(z)}{P_{X,Y}(z) + P_{X,G(\eta,X)}(z)} dz \\
 &= -\log 4 + \mathcal{KL}\left(p_{X,Y}(z) \parallel \frac{P_{X,Y}(z) + P_{X,G(\eta,X)}(z)}{2}\right) + \mathcal{KL}\left(p_{X,G(\eta,X)}(z) \parallel \frac{P_{X,Y}(z) + P_{X,G(\eta,X)}(z)}{2}\right) \\
 &= -\log 4 + 2\mathcal{JS}(P_{X,Y}(z) \parallel P_{X,G(\eta,X)}(z)) \quad (3-6)
 \end{aligned}$$

根据 $\mathbb{D}_{gan}(P_{S,Y} \parallel P_{S,G(Z,S)})$ ，本章可使用 GAN 散度作为衡量联合分布 $P_{X,Y}$ 和 $P_{X,G(Z,X)}$ 之间分布差异的度量方式。综上所述可以构建用于对抗训练生成网络 $G_\phi(\cdot)$ 和判别网络 $D_\theta(\cdot)$ 的目标函数如式(3-8)所示。

$$\mathcal{L}(G, D) = \mathbb{E}_{(X,Y) \sim P_{X,Y}} \log D(X, Y) + \mathbb{E}_{(X,G(\eta,X)) \sim P_X P_\eta} \log(1 - D(X, G(\eta, X))) \quad (3-7)$$

即：

$$(G^*, D^*) = \arg \min_G \max_D \mathcal{L}(G, D) \quad (3-8)$$

在实际应用场景中，可以通过在联合分布 $P_{S,Y}$ 中采样同分布的样本 $\{(s_k, y_k), k=1, \dots, K\}$ 和在 P_Z 中采样的独立同分布样本 $\{z_k\}$ 来计算，即实际对抗训练中的目标函数为式(3-9)：

$$(G^*, D^*) = \arg \min_G \max_D \left\{ \frac{1}{K} \sum_{k=1}^K \log D(s_k, y_k) + \frac{1}{K} \sum_{k=1}^K \log(1 - D(s_k, G(z_k, s_k))) \right\} \quad (3-9)$$

基于式(3-9)定义的基于生成式条件分布采样器采样风速数据的目标函数，本章接下来描述了在没有观测值的位置进行风速采样的 GCDS 算法，如算法 3-1 所示。采样的风速数据可用于推断没有观测的位置的风速分布。

算法 3-1: 基于生成式条件分布采样器的邻近空间风速采样算法

输入: 已观测位置的位置变量 S^o ; 已观测位置的风速序列 Y^o ; 未观测位置的位置变量 S^u ; 采样次数 K ;

输出: 训练好的最优生成网络 G^* ; 在 S^u 中第 n 个位置采样的风速数据 $\tilde{y}_n^u$;

```

1  随机初始化判别网络参数  $\theta$  和生成网络参数  $\phi$ ;
2  for  $e \leftarrow 1$  to  $E$  do:
3      for  $e_D \leftarrow 1$  to  $E_D$  do:
4          从  $S^o$  和  $Y^o$  中随机采样  $\{(s_m^o, y_{m,t}^o), m \in [1, M], t \in [1, T], k = 1, \dots, K\}$ ;
5          从正态分布  $N(0, I_l)$  中随机采样  $\{z_k, k = 1, \dots, K\}$ ;
6          更新判别网络参数  $\theta$ :
              
$$\nabla_{\theta} \left\{ \frac{1}{K} \sum_{k=1}^K \left[ \log D_{\theta}(s_m^o, y_{m,t}^o)_k + \log \left( 1 - D_{\theta}(s_m^o, G_{\phi}(z, s_m^o))_k \right) \right] \right\};$$

7      end
8      for  $e_G \leftarrow 1$  to  $E_G$  do:
9          从已观测位置的位置变量  $S^o$  中采样  $\{(s_m^o)_k, m \in [1, M], k = 1, \dots, K\}$ ;
10         从正态分布  $N(0, I_l)$  中随机采样  $\{z_k, k = 1, \dots, K\}$ ;
11         更新生成网络参数  $\phi$ :
              
$$\nabla_{\phi} \left\{ \frac{1}{K} \sum_{k=1}^K D_{\theta}(s_m^o, G_{\phi}(z, s_m^o))_k \right\};$$

12     end
13 end
14  $G^* \leftarrow G_{\phi}$ ;
15 从未观测位置的位置变量  $S^u$  中采样  $\{(s_m^u)_k, m \in [1, M], k = 1, \dots, K\}$ ;
16 从正态分布  $N(0, I_l)$  中随机采样  $\{z_k, k = 1, \dots, K\}$ ;
17 采样未观测位置  $S^u$  的风速数据  $\tilde{y}_n^u = \{\tilde{y}_{n,t}^u\} = G^*(z_n, s_n^u), n \in [1, N], t \in [1, T]$ 

```

3.4 实验与分析

3.4.1 数据集介绍

本章使用的数据集来自中国山东省一家技术服务公司建造的测风塔收集到的风速时序数据。该测风塔上共有 8 个传感器分别放置在不同高度: 150m、140m、120m、100m、90m、60m、30m 和 10m。风速数据采集时间为 2018 年 5 月 1 日至 6 月 1 日, 时间间隔为 10 分钟。

3.4.2 实验设置

GCDS 模型的实验是在 Keras 框架下实现的。经过调参后,模型参数设置如下: GCDS 的生成网络和鉴别网络均使用 Adam 优化器训练。生成网络由 3 层全连接层 (LeakyRelu(Dense)+Batch Normalization) 和 1 个输出层组成。判别网络由 3 层全连接层 (LeakyRelu(Dense)) 和 1 个输出层组成。学习率设置为 0.001。网络层的激活函数设置为 LeakyRelu, 但需要注意的是生成网络输出层的激活函数应该是 Relu 函数, 鉴别网络输出层的激活函数应该是 Sigmoid 函数。在实验中, 生成网络和鉴别网络都设置为每个迭代下训练 10 次, 总体对抗生成训练的迭代次数为 80000。由于需要确保模型中采样数据的分布保持不变, 因此没有对数据进行预处理。

实验分为两部分。第一部分是分布拟合优度的比较, 用于将本章模型与传统的统计分布模型进行比较, 以验证提出的模型在风速数据上的拟合效果; 第二部分是对比插值模型生成的数据分布与实际数据分布之间的距离。

①**分布拟合**: 在这部分实验中, 不需要划分训练集和测试集。只需在所有高度的风速数据上训练模型, 并使用训练好的模型对不同高度的风速数据进行采样, 以便与传统的统计分布模型进行比较。

②**插值拟合**: 由于数据集中只有 8 个高度的空间点, 按比例划分为训练集和测试集是不可行的。因此本章通过留一交叉验证的方式来衡量所提出的模型与其他模型生成的数据分布与实际数据分布之间的距离。留一交叉验证是指选择一个高度的时间序列数据作为测试集, 并使用其它 7 个高度的时间序列数据作为训练集。这一过程重复 8 次, 并对结果进行综合比较。

3.4.3 评价指标

深度条件生成模型的本质是条件概率密度估计。因此本章使用 Kolmogorov-Smirnov 检验统计量 $K-S$ 、分布决定系数 (Distribution R-Square, R_d^2) 和分布均方根误差 (Distribution Root Mean Squared Error, $RMSE_d$) 作为衡量分布拟合优度的评价指标。 $K-S$ 、 R_d^2 和 $RMSE_d$ 三个统计量的定义分别见式(3-10)、(3-11)和(3-12)。 $K-S$ 统计量定义为实际累积分布和预测累积分布之间的最大误差; R_d^2 被定义为实际累积分布和预测累积分布之间的拟合程度; $RMSE_d$ 被定义为实际累积分布和预测累积分布之间的平均误差。

$$K-S = \max_{1 \leq i \leq n} |F_i - \hat{F}_i| \quad (3-10)$$

$$R_d^2 = 1 - \frac{\sum_{i=1}^n (\hat{F}_i - F)^2}{\sum_{i=1}^n (F_i - \bar{F})^2} \quad (3-11)$$

$$RMSE_d = \sqrt{\frac{1}{n} \sum_{i=1}^n (F_i - \hat{F}_i)^2} \quad (3-12)$$

其中 F 是观测数据的经验累积分布函数, $\hat{F}$ 模型采样数据的经验累积分布函数或统计分布模型的累积分布函数。 $\bar{F}$ 表示平均值。

3.4.4 结果分析

本章除了分析提出的基于 GCDS 的邻近空间风速分布推断方法的实验结果, 还对比了常用的风速分布拟合模型和空间插值方法。在分布拟合研究方面: 主要对比了三种风工程中常用的单分布拟合模型即 Weibull 分布、Gamma 分布和 Lognormal 分布。由于本章提出的邻近空间风速分布推断方法没有指定分布函数形式, 因此首先采样风速数据, 然后使用蒙特卡罗方法来计算各种结果例如均值、分位数等。在插值拟合研究方面: 本章对比了两种常用的地理空间插值方法即反距离插值 (Inverse Distance Weight, IDW) 和普通克里金插值 (Ordinary Kriging, OK)。在普通克里金插值中, 分别使用了高斯变异函数 (OK-Gaussian) 和幂变异函数 (OK-Power)。本章将这两种方法与 GCDS 在所有 8 个高度 (8h) 上使用留一交叉验证的方式进行了比较。此外, 本章还比较了其它的确性插值方法: 幂律插值 (Power Law Interpolation, PLI)、三次样条插值 (Cubic-Spline Interpolation, CSI) 和局部多项式插值 (Local Polynomial Interpolation, LPI)。特别需要注意的是, 上述三种确定性插值方法难以实现外插也就是难以在有观测的空间位置区域外部进行插值。因此本章只在中间 6 个高度上使用留一交叉验证的方式进行比较, 分别是: 140m、120m、100m、90m、60m、30m。

以上对比方法与本章提出的基于 GCDS 的邻近空间风速分布推断方法在数据集上的实验结果的评价指标对比如表 3-1 所示。 $K-S$ 和 $RMSE_d$ 统计量越小, 则说明模型越能准确拟合风速数据的分布, 而 R_d^2 统计量则越大越好。结果表明, GCDS 比 Weibull、Gamma 和 LogNormal 分布具有更好的分布拟合性能。与地质统计插值模型插值的数据分布相比, GCDS 仍然具有最优表现。例如, 在分布拟合方面, 本章的方法在 $K-S$ 统计量上相较于对比方法降低了 14.7%, 在 $RMSE_d$ 统计量上相较于对比方法降低了 37.8%。尽管与确定性插值方法相比, 本章的方法并不总是在所有评价指标上是最优的, 但结果是接近于最优指标的。需要注意的是, 如果位置超出高度范围, 这些确定性插值方法是不稳定的, 而本章的方法可以生成边界相邻空间位置的风速分布。

表 3-1 基于 GCDS 的邻近空间风速分布推断方法与其它对比方法在数据集上的实验结果对比

	模型	$K-S$	$RMSE_d$	R^2
分布拟合	Weibull	0.02917	0.01532	0.99712
	Gamma	0.07083	0.03973	0.97973
	LogNormal	0.10951	0.06570	0.94084
	GCDS	0.02487	0.00953	0.99886
插值拟合	IDW(8h)	0.06606	0.04106	0.96488
	OK-Gaussian(8h)	0.09616	0.06240	0.91192
	OK-Power(8h)	0.03142	0.01860	0.99309
	GCDS(8h)	0.03245	0.01409	0.99756
	PLI(6h)	0.02744	0.01517	0.99595
	CSI(6h)	0.02393	0.01279	0.99767
	LPI(6h)	0.02210	0.01164	0.99781
	GCDS(6h)	0.02774	0.01285	0.99798

(1) 在有观测值高度上对风速进行分布拟合

为了进一步验证 GCDS 和其他分布拟合方法之间的对比,本章绘制了由 GCDS 和其他三种概率分布模型拟合的风速分布概率密度曲线,见图 3-2 (其中 GCDS 方法是核密度曲线)。从图 3-2 可以看出, Gamma 分布和 LogNormal 分布显然不适合用以拟合风速数据分布。威布尔分布和提出的方法可以较好地拟合风速数据分布。但是 Weibull 分布的概率密度曲线是单峰形状,因此不可能拟合多峰的风速数据分布例如本数据集中的 10 米高度风速数据分布。




图 3-2 Weibull, Gamma, LogNormal 分布的概率密度曲线和 GCDS 采样风速数据的核密度曲线

表 3-2 Weibull, Gamma, LogNormal 分布与 GCDS 方法拟合不同高度风速数据的分位数绝对误差比较

分位数	对比方法	150m	140m	120m	100m	90m	60m	30m	10m
5%	Weibull	0.12800	0.26337	0.18636	0.19247	0.22354	0.08481	0.15842	0.19102
	Gamma	0.17979	0.27652	0.20602	0.18947	0.20959	0.11901	0.21608	0.23424
	LogNormal	0.14840	0.25569	0.17189	0.14295	0.15259	0.07655	0.21908	0.27527
	GCDS	0.18709	0.18035	0.13333	0.08431	0.05162	0.03782	0.05203	0.00921
25%	Weibull	0.05555	0.08209	0.07539	0.06980	0.09194	0.11114	0.12699	0.05738
	Gamma	0.29012	0.33242	0.32357	0.32003	0.34412	0.30099	0.23396	0.11818
	LogNormal	0.56058	0.60633	0.57366	0.55967	0.58130	0.48324	0.38119	0.22846
	GCDS	0.04718	0.04702	0.07201	0.03977	0.04185	0.10184	0.04600	0.02436
50%	Weibull	0.08363	0.14045	0.11398	0.14460	0.15503	0.10721	0.04661	0.05210
	Gamma	0.37955	0.43858	0.40066	0.41631	0.41926	0.32369	0.20741	0.16865
	LogNormal	0.64781	0.72467	0.64348	0.63707	0.62833	0.48301	0.37200	0.34137
	GCDS	0.06374	0.03693	0.14176	0.03955	0.04370	0.05357	0.03307	0.03487
75%	Weibull	0.00008	0.08325	0.09043	0.11433	0.13729	0.01417	0.13600	0.08668
	Gamma	0.05809	0.12718	0.12458	0.12915	0.14026	0.03455	0.08240	0.02175
	LogNormal	0.10798	0.03559	0.02963	0.03457	0.03400	0.08485	0.14646	0.00700
	GCDS	0.08145	0.06404	0.05180	0.04439	0.09341	0.03850	0.02796	0.03102
95%	Weibull	0.02242	0.08546	0.13933	0.33504	0.27207	0.11751	0.07687	0.05192
	Gamma	1.08167	1.20344	1.19936	1.37440	1.30761	0.90718	0.46357	0.30653
	LogNormal	3.59527	3.93473	3.45113	3.50192	3.38645	2.35180	1.87201	1.60931
	GCDS	0.09752	0.11415	0.16921	0.06705	0.05409	0.09927	0.07055	0.05826




图 3-3 用 GCDS 拟合不同高度风速后采样数据箱线图的比较

此外，本章还比较了 GCDS 和其他三种概率分布模型拟合的各高度风速分位数与真实风速分位数之间的绝对误差。由于基于 GCDS 的邻近空间风速分布推断方法没有假设分布函数，因此使用蒙特卡洛采样（MC）方法来计算分位数。本章计算了对比模型中三个概率分布函数的理论分位数。这四种方法在 8 个不同高度上的拟合分位数的绝对误差如表 3-2 所示。从表中可以明显看出，本章基于 GCDS 提出的方法在大多数高度上拟合分位数的绝对误差最小。尤其是在第 5%、25% 和 75% 分位数时，所提出的方法明显优于其他模型。在第 75% 和第 95% 分位数处，即使不是最小值，其绝对误差值也与最小值相当。

本章还比较了从 GCDS 采样的数据中绘制的每个高度的风速数据的箱线图，如图 3-3 所示。红色箱线图表示实际风速数据，蓝色箱线图表示 GCDS 方法采样的风速数据。所提出方法的箱线图拟合良好，分位数与原始风速数据的分位数基本一致。




图 3-4 使用留一交叉验证方式下 IDW、OK-Gaussian、OK-Power 和 GCDS 四种方法在各个高度的风速采样数据箱线图比较：(a) IDW；(b) OK-Gaussian；(c) OK-Power；(d) GCDS

(2) 基于留一交叉验证方式的风速插值拟合

在风速插值拟合部分，本章分析了 GCDS 方法和其它插值对比方法的风速分布推断效果。通过图 3-3 的箱线图和表 3-3 所示的不同模型分位数绝对误差比较并分析了所提出的基于 GCDS 的邻近空间风速分布推断方法和其他插值模型。从图

3-3 以及表 3-3 可以看出, 所提出的方法总体上具有更好的风速分布推断效果。基于 GCDS 提出的方法通常在多数高度的分位数上具有更好的表现结果。即使不是最优值, 但是仍然非常接近最优值。所有的地理空间插值方法对 30 米和 10 米高度的风速数据的插值结果都很差。尤其是 OK-Gaussian 和 OK-Power 插值方法在多个高度存在负插值结果, 这会严重影响风速分布的推断。

表 3-3 使用留一交叉验证方式下 IDW、OK-Gaussian、OK-Power 和 GCDS 四种方法在各个高度的风速采样数据的分位数绝对误差对比

分位数	对比方法	150m	140m	120m	100m	90m	60m	30m	10m
5%	IDW	0.29409	0.32260	0.09281	0.02053	0.04289	0.18325	0.13065	0.54991
	OK-Gaussian	0.55063	0.21629	0.12448	0.05598	0.04806	0.21761	2.00335	1.05439
	OK-Power	0.21534	0.29362	0.05242	0.04078	0.02100	0.22227	0.26108	0.08363
	GCDS	0.32702	0.22900	0.11995	0.24937	0.03054	0.18213	0.18643	0.29888
25%	IDW	0.21092	0.18643	0.12481	0.01477	0.03438	0.17393	0.20538	0.88895
	OK-Gaussian	0.51163	0.29139	0.16337	0.10699	0.11632	0.38060	1.08620	0.50008
	OK-Power	0.15216	0.16296	0.10122	0.01847	0.12461	0.24244	0.00692	0.30222
	GCDS	0.09570	0.06380	0.09227	0.09119	0.00786	0.13402	0.02617	0.04431
50%	IDW	0.19779	0.13021	0.12816	0.07513	0.09629	0.09754	0.21359	0.98097
	OK-Gaussian	0.31978	0.15811	0.11597	0.05470	0.06887	0.41671	0.70627	1.50494
	OK-Power	0.07010	0.07455	0.09619	0.02640	0.10622	0.15033	0.00511	0.27347
	GCDS	0.10968	0.02784	0.04367	0.02975	0.00153	0.02612	0.04168	0.01922
75%	IDW	0.16194	0.05923	0.14601	0.11259	0.16007	0.01704	0.29792	0.99908
	OK-Gaussian	0.21789	0.10593	0.10279	0.06988	0.05336	0.44542	0.27455	2.98507
	OK-Power	0.06292	0.00536	0.08407	0.02124	0.12288	0.11176	0.08390	0.36072
	GCDS	0.00856	0.03839	0.00080	0.02794	0.02895	0.12410	0.07669	0.04720
95%	IDW	0.25404	0.00211	0.25855	0.20743	0.25418	0.02272	0.42904	0.93067
	OK-Gaussian	0.22964	0.16465	0.09599	0.06473	0.08088	0.42799	0.30087	4.02676
	OK-Power	0.23207	0.13949	0.13299	0.05714	0.11846	0.02328	0.22259	0.50366
	GCDS	0.05648	0.20056	0.12098	0.16205	0.03237	0.05909	0.38769	0.14697

(3) 在无观测值的高度进行风速分布推断

为了进一步验证本章提出方法的有效性, 使用所提出的方法在没有观测值的情况下对高度 (130m、110m、80m、70m、50m、40m、20m) 的风速进行采样, 并推断其风速分布情况。图 3-5 中的红框图表示有观测值的高度上的风速数据箱线图。绿框图表示在没有观测值的高度上采样的风速数据箱线图。从图 3-5 中可以看

出，无观测值高度的采样风速数据的分布遵循有观测值高度的箱线图变化趋势。这一结果表明，所提出的方法可用于在邻近空间的高度上采样风速数据并推断其分布情况。




图 3-5 基于 GCDS 的邻近空间风速采样数据箱线图，其中红色箱线图表示有观测值的高度上的风速数据；绿色箱线图表示在没有观测值的高度上采样的风速数据

3.5 本章小结

本章提出了一种基于生成式条件分布采样器的邻近空间风速采样方法。该方法可用于推断无观测数据空间位置的风速分布，在风资源评估中可以发挥重要作用。该方法无需假设风速数据服从特定的概率分布，并且可以通过蒙特卡罗采样的方法计算出均值和分位数等指标信息。该方法不仅可以更准确的拟合风速数据概率分布，还可以减少空间插值方法引起的误差传递和累积。大量的数值实验表明，该方法优于传统的概率分布拟合方法和插值方法。

第4章 基于 GCDS-Transformer 的邻近空间风速序列生成方法

在风资源评估领域，空间分布稀疏的测风塔数据难以有效表征区域风场的风速分布特征，这是制约风电场选址精度的重要瓶颈问题。如第 3 章所述，该章提出了一种基于 GCDS 的邻近空间风速分布推断方法。该方法有效解决了空间稀疏数据条件下的概率分布推断问题。然而，该方法在应用层面仍存在两个显著局限性：第一，严格平稳性假设难以适应实际风场数据的非平稳特性，特别是在风速序列较短时，风速序列往往呈现显著的不平稳特征；第二，基于 GCDS 的风速采样方法缺乏时间维度信息的采样能力，无法满足风电场运行模拟等需要时序相关分析的工程需求。针对这些问题，本章又提出了一种基于 GCDS-Transformer 的邻近空间风速序列生成方法，该方法无需遵循长期风速数据是严格平稳时间序列的假设，因此既可以生成短时段的风速序列数据，也可以生成较长时间的风速序列数据。GCDS-Transformer 模型是一种新的改进的 Transformer 模型结构，并和第 3 章的 GCDS 模型相结合。该方法可以有效生成邻近空间位置的风速序列数据。

4.1 问题描述

假设存在一组时空数据的随机向量 (S, Y) ，其中 S 是空间位置 $S = \{s_m, m=1, \dots, M\}$ ， Y 是对应于 M 个空间位置的多维时间序列 $Y = \{y_{m,t}, m=1, \dots, M; t=1, \dots, T\}$ 。随机向量 (S, Y) 的联合分布为 $P_{S,Y}$ 即 $(S, Y) \sim P_{S,Y}$ 。给定某一空间位置时，该位置的时间序列数据服从条件概率分布 $P_{Y|S}$ 。本章的研究目标不仅要建模空间位置 S 和相应的分布 P_Y 之间的关系，还要在上一章的基础上研究在给定空间位置 s 后生成符合该空间位置的时间序列 $\{y_1, \dots, y_T\}$ 也就是自回归生成问题。假设随机向量 (S, Y) 的联合概率密度为 $p(s, y_{1:T})$ ，根据概率乘法公式可分解为式(4-1)。

$$p(s, y_{1:T}) = p(s) \prod_{t=1}^T p(y_t | y_{1:(t-1)}, s) \quad (4-1)$$

由式(4-1)可知，自回归生成问题转化为时间序列的条件概率密度估计问题，即给定空间位置 s 时 y_t 的条件概率为 $p(y_t | y_{1:(t-1)}, s)$ 。在这种序列生成方式中，每一时刻都需要将前面时刻的输出和空间位置作为当前步的输入。

在实际情况中时空观测数据的空间点比较稀疏，只有少量的空间位置有观测值 (S^o, Y^o) ，关键问题是生成未观测空间位置 S^u 的时间序列 Y^u 。因此首先利用已观

测数据 (S^o, Y^o) 训练一个生成模型，然后基于训练好的生成模型生成第 n 个未观测空间位置 S_n^u 的时间序列 $\{y_{n,t}^u, n=1, \dots, N; t=1, \dots, T\}$ 。这样就能够生成没有观测值位置的风速序列数据。




图 4-1 用于邻近空间风速序列生成的 GCDS-Transformer 模型框架示意图

4.2 GCDS-Transformer 模型

本章提出了一种用于邻近空间风速序列生成的 GCDS-Transformer 模型。该模型的主要框架如图 4-1 所示。该模型主要分为两部分：生成网络 G_θ 和判别网络 D_θ 。根据上一章的 GCDS 采样方法，条件生成函数 $G(\cdot)$ 也就是图 4-1 中的生成网络 G_θ ，其输入分别是表示空间位置信息的随机向量 S 和从多元标准正态分布中采样的随机向量 $Z_L \sim (0, I_L)$ ；输出是对应于空间位置 S 的风速序列数据 $\hat{Y}_{1:T}$ 。判别网络 D_θ 主要由多层全连接神经网络组成，用以判别真实随机向量 $(S, Y_{1:T})$ 和生成网络生成的随机向量 $(S, \hat{Y}_{1:T})$ 。根据噪声外包引理， $G(Z_L, S) | S$ 与 $Y_{1:T} | S$ 的条件分布匹配等价于 $(S, G(Z_L, S))$ 与 $(S, Y_{1:T})$ 的联合分布匹配：对于随机向量 $(S, Y_{1:T})$ ，当且仅当 $P_{G(Z_L, S) | S} P_S = P_{Y_{1:T} | S} P_S$ 成立时 $P_{G(Z_L, S) | S} = P_{Y_{1:T} | S}$ 成立，也就是 $P_{S, G(Z_L, S)} = P_{S, Y_{1:T}}$ 。因此，本章生成网络和判别网络对抗训练的目标是寻找一个条件生成函数 $G(\cdot)$ 使得 $(S, G(Z_L, S))$ 与 $(S, Y_{1:T})$ 的联合分布相同。与上一章基于 GCDS 的风速采样方法不同的是，本章的 GCDS-Transformer 模型还需要生成对应空间位置的风速序列数据。这就要求生成网络 G_θ 不仅能匹配联合概率分布 $P_{S, Y_{1:T}}$ ，还要匹配条件概率分布 $P_{Y_t | S, Y_{1:(t-1)}}$ 即寻找合适的条件生成函数 $G(\cdot)$ 使得式(4-2)成立。

$$P_{G(Z_L, S) | S, Y_{1:(t-1)}} = P_{Y_t | S, Y_{1:(t-1)}} \quad (4-2)$$

本章的生成网络 G_ϕ 由空间-噪声融合编码器（Spatial Noise Encoder, SNEncoder）和因果时序解码器（Causal Temporal Decoder, CTDecoder）构成。其中 SNEncoder 用于融合和编码空间位置信息，CTDecoder 用于自回归式解码并生成风速序列数据。

空间-噪声融合编码器：

空间-噪声融合编码器的神经网络结构如图 4-2（a）所示。SNEncoder 的网络结构是在原始的 Transformer-Encoder 上改进而来。其中的多头自注意力机制被替换为本章提出的空间-噪声交叉多头自注意力机制（Spatial Noise Cross-MSA），如图 4-2（b）所示。首先将空间信息随机向量 S 映射到高维矩阵 Q_S ，随机向量 $Z_L \sim (0, I_L)$ 映射到高维矩阵 K_N 和 V_N 。映射过程详见式(4-3)，式(4-4)和式(4-5)。

$$Q_S = W_q S \quad (4-3)$$

$$K_N = W_k Z_L \quad (4-4)$$

$$V_N = W_v Z_L \quad (4-5)$$

其中 W_q, W_k, W_v 分别是参数矩阵。SN Cross-MSA 的计算过程如式(4-6)所示。通过将空间信息随机向量 S 和随机向量 $Z_L \sim (0, I_L)$ 分别映射到 Q_S, K_N, V_N 使得模型可以融合学习到空间位置信息。

$$\text{Attention}(Q_S, K_N, V_N) = \text{softmax}\left(\frac{Q_S K_N^T}{\sqrt{d_k}}\right) V_N \quad (4-6)$$




图 4-2 Spatial Noise Encoder 神经网络结构示意图

因果时序解码器:

由于风速数据是一种典型的时空数据，某一时刻风速数据 y_t 的变化不仅与空间位置 s_m 有关，还与当前时刻 t 之前的风速序列数据 $\{y_1, \dots, y_{(t-1)}\}$ 有关。但是并不受到该时刻之后的风速序列数据 $\{y_{(t+1)}, \dots\}$ 的影响，因此生成网络需要自回归式的生成给定空间位置的风速序列数据。本章的因果时序解码器核心部分是 Liang 等提出的 Causal Temporal MSA^[56] 机制，其解码器神经网络结构图如图 4-3 所示。

CTDecoder 的输入是 SNEncoder 融合编码输出的时序隐藏状态 $H_{1:T}$ 。Causal Temporal MSA 的主要创新点在于局部感受野窗口（Local Window）和时间因果关系（Temporal Causality）。局部感受野窗口是指在局部的时序窗口内进行多头自注意力机制的计算，其计算效率相较于普通 MSA 机制有较大提升。并且局部感受野窗口的大小与 CTDecoder 叠加的层数有关，如图 4-3（b）所示。从上到下第 b 层窗口大小的计算公式为 $W = T/2^{b-1}$ 。例如当 CTDecoder 叠加 3 层，时序长度为 8 时，从上到下每一层的局部感受野窗口为 8，4，2。时间因果关系是指 Causal Temporal MSA 计算过程中引入上三角掩码矩阵屏蔽掉 t 时刻之后的向量数据，从而保证时间顺序的因果性。计算过程如图 4-2（b）中的箭头所示。




图 4-3 Causal Temporal Decoder 神经网络结构示意图^[56]

4.3 目标函数和对抗训练

本章提出的 GCDS-Transformer 目标函数主要由两部分组成：生成网络和判别网络对抗训练时用于学习空间位置 S 和风速序列数据 Y 联合分布 $P_{S,Y}$ 的目标函数 $\mathcal{L}_j$ ；生成网络训练时用于学习条件概率分布 $P_{Y_i|S, Y_{1:(i-1)}}$ 自回归式生成风速序列数据 Y 的目标函数 $\mathcal{L}_c$ 。在第 3 章中基于 GCDS 的邻近空间风速分布推断方法中判别网络的损失函数是交叉熵损失函数，其模型学习联合分布 $P_{S,Y}$ 的目标函数等价于衡量两

个联合分布之间的 JS 散度。但是在本章用于生成邻近空间风速序列的训练过程较为复杂，这一目标函数容易出现梯度消失问题^[34]。因此本章模型的判别网络损失函数是最小二乘损失函数，这等价于在学习联合分布 $P_{S,Y}$ 的训练过程中衡量两个联合分布之间的 Pearson χ^2 散度。

在目标函数 $\mathcal{L}_j$ 中，空间位置和真实风速序列数据 $(S, Y_{1:T})$ 的联合概率分布 $P_{S,Y_{1:T}}$ 被标记为标签 1，空间位置和生成网络 $G(\cdot)$ 生成的风速序列数据 $(S, G(Z_L, S))$ 的联合概率分布 $P_{S,G(Z_L,S)}$ 被标记为标签 0。所以在 GCDS-Transformer 模型中判别网络 $D(\cdot)$ 的输出应接近 1 或 0，即判别网络是一个回归模型。因此目标函数 $\mathcal{L}_j$ 如式(4-7)所示。其中 $\mathcal{L}_{j-D}$ 表示判别网络的目标函数， $\mathcal{L}_{j-G}$ 表示生成网络的目标函数。

$$\begin{aligned}\mathcal{L}_{j-D} &= \frac{1}{2} \mathbb{E}_{(S,Y) \sim P_{S,Y}} \left[(D(S,Y) - 1)^2 \right] + \frac{1}{2} \mathbb{E}_{(S,Z) \sim P_S P_Z} \left[(D(S, G(S,Z)) - 0)^2 \right] \\ \mathcal{L}_{j-G} &= \frac{1}{2} \mathbb{E}_{(S,Y) \sim P_{S,Y}} \left[(D(S,Y) - 1)^2 \right] + \frac{1}{2} \mathbb{E}_{(S,Z) \sim P_S P_Z} \left[(D(S, G(S,Z)) - 1)^2 \right]\end{aligned}\quad (4-7)$$

$\mathcal{L}_{j-G}$ 等价于衡量 $P_{S,Y_{1:T}}$ 与 $P_{S,G(Z_L,S)}$ 之间的 Pearson χ^2 散度，具体推导如下：首先假设生成网络 $G(\cdot)$ 固定不变，将 $\mathcal{L}_{j-D}$ 写成积分形式如式(4-8)所示，其中 $p_{(S,Y)}(z)$ 表示分布 $P_{S,Y_{1:T}}$ 的概率密度函数， $p_{(S,G(S,Z))}(z)$ 表示分布 $P_{S,G(Z_L,S)}$ 的概率密度函数。然后对其求导得到 $G(\cdot)$ 固定时的最优判别网络函数 $D^*(\cdot)$ 即式(4-9)。

$$\mathcal{L}_{j-D} = \frac{1}{2} \left\{ \int p_{(S,Y)}(z) (D(S,Y) - 1)^2 dz + \int p_{(S,G(S,Z))}(z) (D(S, G(S,Z)))^2 dz \right\} \quad (4-8)$$

$$D^*(\cdot) = \frac{P_{(S,Y)}}{P_{(S,Y)} + P_{(S,G(S,Z))}} \quad (4-9)$$

将式(4-9)中的 $D^*(\cdot)$ 代入 $\mathcal{L}_{j-G}$ 有式(4-10)所示，使用 $v(z) = p_{(S,Y)}(z) + p_{(S,G(S,Z))}(z)$ 。

$$\begin{aligned}\mathcal{L}_{j-G} &= \frac{1}{2} \mathbb{E}_{(S,Y) \sim P_{S,Y}} \left[\left(\frac{p_{(S,Y)}(z)}{v(z)} - 1 \right)^2 \right] + \frac{1}{2} \mathbb{E}_{(S,Z) \sim P_S P_Z} \left[\left(\frac{p_{(S,Y)}(z)}{v(z)} - 1 \right)^2 \right] \\ &= \frac{1}{2} \int p_{(S,Y)}(z) \left(\frac{-p_{(S,G(S,Z))}(z)}{v(z)} \right)^2 dz + \frac{1}{2} \int p_{(S,G(S,Z))}(z) \left(\frac{-p_{(S,G(S,Z))}(z)}{v(z)} \right)^2 dz \\ &= \frac{1}{2} \int \frac{(p_{(S,G(S,Z))}(z))^2}{p_{(S,Y)}(z) + p_{(S,G(S,Z))}(z)} dz \\ &= \frac{1}{2} \chi^2(p_{(S,Y)} + p_{(S,G(S,Z))} \parallel p_{(S,Y)})\end{aligned}\quad (4-10)$$

其中 $\chi^2(p_{(s,y)} + p_{(s,G(s,Z))} \parallel p_{(s,y)})$ 表示 $p_{(s,y)} + p_{(s,G(s,Z))}$ 与 $p_{(s,y)}$ 之间的 Pearson χ^2 散度, 该目标函数可有效保持模型训练过程中的稳定性。

目标函数 $\mathcal{L}_j$ 只能学习空间位置 S 和风速序列数据 Y 联合分布 $P_{S,Y}$, 因此还需要在生成网络模型训练时增加有监督目标函数 $\mathcal{L}_c$ 用于学习条件概率分布 $P_{Y_t|S, Y_{1:t-1}}$ 。本章将均方误差损失函数作为 $\mathcal{L}_c$, 如式(4-11)所示。

$$\mathcal{L}_c = \mathbb{E} \left[\left(G(s, z)_t - y_{s,t} \right)^2 \right], s \in S, t = 1, \dots, T \quad (4-11)$$

其中 $G(s, z)_t$ 表示生成网络在位置 s 生成的 t 时刻风速数据, $y_{s,t}$ 表示位置 s 的 t 时刻真实风速数据。因此将式(4-7)中 $\mathcal{L}_{j-G}$ 和式(4-11)中 $\mathcal{L}_c$ 相结合得到本章 GCDS-Transformer 模型生成网络的目标函数如式(4-12)所示。由于在生成网络训练过程中, 判别网络的参数被固定, 因此可省略掉式(4-7) $\mathcal{L}_{j-G}$ 中的 $\mathbb{E}_{(S,Y) \sim P_{S,Y}} \left[\left(D(S, Y) - 1 \right)^2 \right]$ 项。

$$\begin{aligned} \mathcal{L}_G &= \mathcal{L}_{j-G} + \mathcal{L}_c \\ &= \mathbb{E}_{(S,Z) \sim P_S P_Z} \left[\left(D(S, G(S, Z)) - 1 \right)^2 \right] + \mathbb{E} \left[\left(G(s, z)_t - y_{s,t} \right)^2 \right] \end{aligned} \quad (4-12)$$

综上所述, GCDS-Transformer 模型的判别网络与生成网络目标函数如式(4-13)所示。

$$\begin{cases} D^* = \arg \min_D \left\{ \frac{1}{2} \mathbb{E}_{(S,Y) \sim P_{S,Y}} \left[\left(D(S, Y) - 1 \right)^2 \right] + \frac{1}{2} \mathbb{E}_{(S,Z) \sim P_S P_Z} \left[\left(D(S, G(S, Z)) - 0 \right)^2 \right] \right\} \\ G^* = \arg \min_G \left\{ \mathbb{E}_{(S,Z) \sim P_S P_Z} \left[\left(D(S, G(S, Z)) - 1 \right)^2 \right] + \mathbb{E} \left[\left(G(s, z)_t - y_{s,t} \right)^2 \right] \right\} \end{cases} \quad (4-13)$$

在实际应用场景中, 可以通过在联合分布 $P_{S,Y}$ 中随机采样 K 个空间位置的样本 $\{(s_k, y_{k,1:T}), k = 1, \dots, K\}$ 和在 P_Z 中随机采样的 K 个样本 $\{z_k, k = 1, \dots, K\}$ 来计算, 即实际对抗训练中的目标函数为式(4-14)。其中 z_k 是一个服从多元标准正态分布的多维随机向量。

$$\begin{cases} D^* = \arg \min_D \left\{ \frac{1}{2K} \left[\sum_{k=1}^K \left(D(s_k, y_{k,1:T}) - 1 \right)^2 + \sum_{k=1}^K \left(D(s_k, G(s_k, z_k)) \right)^2 \right] \right\} \\ G^* = \arg \min_G \left\{ \frac{1}{K} \left[\sum_{k=1}^K \left[\left(D(s_k, G(s_k, z_k)) - 1 \right)^2 \right] + \frac{1}{T} \sum_{k=1}^K \sum_{t=1}^T \left(G(s_k, z_k)_t - y_{k,t} \right)^2 \right] \right\} \end{cases} \quad (4-14)$$

基于式(4-14)定义的 GCDS-Transformer 模型目标函数, 本章接下来描述了在没有观测值的位置基于 GCDS-Transformer 的邻近空间风速序列生成算法, 如算法 4-1 所示。生成的风速序列数据可用于推断没有观测的位置的风速分布和风速序列变化情况。

算法 4-1: 基于 GCDS-Transformer 的邻近空间风速序列生成算法

输入: 已观测位置的位置向量 S^o ; 已观测位置的风速序列 Y^o ; 未观测位置的位置向量 S^u ; 小批量采样 K 个空间位置;

输出: 训练好的最优生成网络 G^* ; 在 S^u 中第 n 个位置采样的风速数据 $\tilde{y}_{n,1:T}^u$;

```

1  随机初始化判别网络参数  $\theta$  和生成网络参数  $\phi$ ;
2  for  $e \leftarrow 1$  to  $E$  do:
3      for  $e_D \leftarrow 1$  to  $E_D$  do:
4          从  $S^o$  和  $Y^o$  中随机采样  $\{(s_m^o, y_{m,1:T}^o)_k, m \in [1, M], k = 1, \dots, K\}$ ;
5          从正态分布  $N(0, I_l)$  中随机采样  $\{z_k, k = 1, \dots, K\}$ ;
6          更新判别网络参数  $\theta$ :
              
$$\nabla_{\theta} \left\{ \frac{1}{2K} \left[ \sum_{k=1}^K (D_{\theta}(s_k, y_{k,1:T}) - 1)^2 + \sum_{k=1}^K (D_{\theta}(s_k, G_{\phi}(s_k, z_k)))^2 \right] \right\};$$

7      end
8      for  $e_G \leftarrow 1$  to  $E_G$  do:
9          从已观测位置的位置变量  $S^o$  中采样  $\{(s_m^o)_k, m \in [1, M], k = 1, \dots, K\}$ ;
10         从正态分布  $N(0, I_l)$  中随机采样  $\{z_k, k = 1, \dots, K\}$ ;
11         更新生成网络参数  $\phi$ :
              
$$\nabla_{\phi} \left\{ \frac{1}{K} \left[ \sum_{k=1}^K [(D_{\theta}(s_k, G_{\phi}(s_k, z_k)) - 1)^2] + \frac{1}{T} \sum_{k=1}^K \sum_{t=1}^T (G_{\phi}(s_k, z_k)_t - y_{k,t})^2 \right] \right\};$$

12     end
13 end
14  $G^* \leftarrow G_{\phi}$ ;
15 从未观测位置的位置向量  $S^u$  中采样第  $n$  个未观测位置的向量  $s_m^u, m \in [1, M]$ ;
16 从正态分布  $N(0, I_l)$  中随机采样  $z$ ;
17 采样第  $n$  个未观测位置  $s_m^u$  的风速数据  $\tilde{y}_{n,1:T}^u = G^*(z_n, s_n^u), n \in [1, N]$ 

```

4.4 实验与分析

4.4.1 数据集介绍

本章使用的数据集来自于百度开源用于 KDD Cup 2022 竞赛设计的 SDWPF (空间动态风电预测) 数据集^[57]。该数据集是龙源电力集团有限公司在真实世界数据中收集获得的。数据集采集自 134 台实际运行的风力涡轮机, 覆盖连续 245 天、以 10 分钟为间隔的 SCADA 系统监测数据, 共包含 4,727,520 条多维时序记录。在

本章实验中，只使用其中的 134 台风力涡轮机的风速监测数据和涡轮机相对空间坐标数据，并且忽略了风向数据、涡轮机尾流效应等信息。134 台风力涡轮机的相对空间位置坐标以米(m)为单位的横纵坐标组成：横坐标范围是[0m, 5501.4529m]；纵坐标范围是[0m, 12121.0043m]。涡轮机的空间分布图如图 4-4 所示，图中每个点表示一台风力涡轮机，点旁边的数字表示该涡轮机的编号。




图 4-4 SDWPF 数据集风力涡轮机空间位置分布示意图

由于原始数据集中收集了连续 245 天、以 10 分钟为间隔的风速序列数据，其序列长度较长，难以用于本章模型的训练。因此本章随机选取其中的一段时长区间（128、256、512、1024 个时刻长度）内 134 台风力涡轮机的风速序列数据。每台风力涡轮机的时长区间相同。图 4-5 展示了随机选取的 6 台风力涡轮机 512 个时刻的风速序列图。




图 4-5 部分风力涡轮机 512 个时刻的风速序列图

4.4.2 实验设置

本章对于 GCDS-Transformer 在邻近空间风速序列生成应用的实验是在 PyTorch 框架下实现的。经过调参后，模型参数设置如下：SNEncoder 和 CTDecoder 中的自注意力机制头数量均设置为 4；SNEncoder 和 CTDecoder 均叠加 4 层即 $N_E = 4$ ， $N_D = 4$ 。在训练过程中参数设置如下：多元标准正态分布 $N(0, I_l)$ 设置为 512 维即 $l = 512$ ；模型训练迭代最大次数 $epochs = 15000$ ；小批量采样次数 $K = 16$ 。数据集及其预处理设置如下：134 台风力涡轮机的风速序列数据中随机选取其中 27 台作为测试集，107 台作为训练集，训练集和测试集的风力涡轮机空间位置分布图如图 4-6 所示，其中红色表示测试集的风力涡轮机，蓝色表示训练集的风力涡轮机。假设训练集数据作为已观测到的风速数据，测试集数据作为未观测到的风速数据，即需要生成或插值该空间位置的风速数据。数据集的所有风速序列数据均使用 min-max 归一化方式预处理，空间位置坐标也同样采用 min-max 归一化方式预处理。通过上述数据预处理方式避免量纲不同产生的影响。

4.4.3 评价指标

本章的研究目标是生成邻近空间未观测位置的风速序列数据，因此评价指标的目的是衡量生成的风速序列数据是否与真实的风速序列数据相一致。本章选取的评价指标有：数值均方根误差（Root Mean Squared Error, $RMSE_v$ ）、平均绝对误




图 4-6 训练集和测试集中风力涡轮机空间位置分布示意图

差 (Mean Absolute Error, MAE) 和对称平均绝对百分比误差 (Symmetric Mean Absolute Percentage Error, $SMAPE$)。 $RMSE_v$ 通过计算生成的时间序列值与真实时间序列值之间差异的平方根均值, 反映模型预测误差的总体分布特性; MAE 衡量生成的时间序列值与真实时间序列值绝对差异的平均水平; $SMAPE$ 以百分比形式呈现误差, 便于跨数据集比较模型的相对性能。上述三个评价指标的计算公式详见式。

$$RMSE_v = \sqrt{\frac{1}{K \cdot T} \sum_{k=1}^K \sum_{t=1}^T (y_{k,t} - \hat{y}_{k,t})^2} \quad (4-15)$$

$$MAE = \frac{1}{K \cdot T} \sum_{k=1}^K \sum_{t=1}^T |y_{k,t} - \hat{y}_{k,t}| \quad (4-16)$$

$$SMAPE = \frac{2}{S \cdot T} \sum_{k=1}^K \sum_{t=1}^T \frac{|y_{k,t} - \hat{y}_{k,t}|}{|y_{k,t}| + |\hat{y}_{k,t}|} \times 100\% \quad (4-17)$$

其中 $y_{k,t}$ 表示第 k 个空间位置的真实风速序列在 t 时刻的值, $\hat{y}_{k,t}$ 表示第 k 个空间位置的生成风速序列在 t 时刻的值。 K 表示测试集中共有 K 个空间位置, T 表示风速序列的时间长度。


4.4.4 结果分析

本章除了分析提出的基于 GCDS-Transformer 的邻近空间风速序列生成方法的实验结果，还对比了其它的空间插值模型。在插值拟合研究方面：本章对比了两种常用的地理空间插值方法即反距离插值（Inverse Distance Weight, IDW）和普通克里金插值（Ordinary Kriging, OK）。此外还对比了近年来提出的随机森林空间插值模型（Random Forest Spatial Interpolation, RFSI）^[58]，该模型是将相邻观测值及其到插值位置的距离作为协变量。


本章对比了各种模型在不同时序长度上的邻近空间风速序列插值或生成的表现，时序长度分别为： $T = 128, 256, 512, 1024$ 。各模型的对比结果如表 4-1 所示，其中加粗字体表示最优结果。 $RMSE_v$ 、 MAE 和 $SMAPE$ 三个指标数值越小说明模型生成或插值的风速序列数据越准确。由表 4-1 可知，本章提出的 GCDS-Transformer 模型在所有的时序长度下生成的风速序列数据的准确度最高，优于其它空间插值模型。

表 4-1 基于 GCDS-Transformer 的邻近空间风速序列生成方法与其它模型在数据集上的实验结果对比


生成时 序长度	模型	$RMSE_v$	MAE	$SMAPE$
128	IDW	1.22495	0.87120	34.954%
	Kriging	1.39617	0.82896	32.841%
	RFSI	0.75372	0.51889	21.529%
	GCDS-Transformer	0.56032	0.40153	16.467%
256	IDW	1.29963	0.95295	32.289%
	Kriging	1.28078	0.79669	27.790%
	RFSI	0.98339	0.66610	21.809%
	GCDS-Transformer	0.73044	0.52281	17.639%
512	IDW	1.33061	0.95563	27.085%
	Kriging	1.26403	0.77580	22.323%
	RFSI	1.06559	0.69579	19.823%
	GCDS-Transformer	0.80066	0.56739	16.383%
1024	IDW	1.47946	1.05305	27.372%
	Kriging	1.27168	0.78161	21.188%
	RFSI	1.08281	0.69058	18.168%
	GCDS-Transformer	0.80375	0.54718	14.349%



(a) 编号 38 风力涡轮机



(b) 编号 72 风力涡轮机



(c) 编号 97 风力涡轮机

图 4-7 各个模型在测试集中选取的三台风力涡轮机风速序列拟合图

为进一步对比各个模型在插值或生成的风速序列上的细节，本章在测试数据集里选取了其中三台风力涡轮机 512 个时刻的风速序列，并绘制了各个模型的风速序列拟合图，如图 4-7 所示：蓝色曲线表示选中风力涡轮机收集到的真实风速序列数据，红色曲线表示 GCDS-Transformer 模型生成的风速序列，绿色、紫色和黄色

色曲线分别表示 IDW、Kriging 和 RFSI 模型插值的风速数据。从图 4-7 中可以看出，本章提出的 GCDS-Transformer 模型在选取的三台风力涡轮机上的生成风速序列拟合效果优于其他三个空间插值模型。尤其是在风速序列剧烈变化的尖峰位置，IDW 和 RFSI 插值的数据不能实现很好的拟合。而 GCDS-Transformer 生成的数据则相对较好地拟合了风速序列中的尖峰位置。此外，GCDS-Transformer 生成的数据可以与真实的风速序列数据在不同时间区间内的波动趋势保持一致。但是 Kriging 和 RFSI 插值的数据在某些时间区间内会产生非常明显的异常现象，例如 Kriging 插值的数据会出现小于 0 的负值，而风速数据永远是大于等于 0 的；RFSI 插值的数据也会出现较多等于或接近于 0 的值。这就导致 Kriging 和 RFSI 插值的数据在部分时间区间内不能与真实风速数据的波动趋势保持一致。




图 4-8 各个模型在测试集中随机选取的三个风力涡轮机风速序列数据核密度对比图

本章还绘制了选取的三台风力涡轮机 512 个时刻的风速序列数据核密度图与各个模型生成或插值的风速序列数据核密度图对比，如图 4-8 所示。从图 4-8 中可

以看出, GCDS-Transformer 模型在三台风力涡轮机上都可以较好的拟合风速数据分布。而 IDW、Kriging 和 RFSI 模型插值的数据都与真实风速数据的分布存在一定偏差。

本章将第 3 章提出的基于 GCDS 的邻近空间风速分布推断方法应用于本章的 SDWPF 数据集, 并和本章的 GCDS-Transformer 模型进行了对比。由于第 3 章的 GCDS 模型只能对邻近空间风速数据进行采样, 无法生成具有时间维度信息的序列数据。因此这里只对比了两种方法对于邻近空间风速数据的分布拟合情况。拟合优度指标与 3.4.3 节保持一致, 结果如表 4-2 所示。通过表 4-2 可知, 虽然 GCDS 模型在本章使用的测试集上分布拟合优度仍保持了不错的结果, 但是 GCDS-Transformer 的结果要略优于 GCDS 模型。这说明在生成网络中引入有监督目标函数会使得模型能够更加准确的生成接近于真实序列的风速数据。

表 4-2 基于 GCDS 的邻近空间风速分布推断方法与基于 GCDS-Transformer 的邻近空间风速序列生成方法在 SDWPF 数据集上的实验结果对比

	$K-S$	$RMSE_d$	R^2
GCDS	0.10279	0.05309	0.96112
GCDS-Transformer	0.08760	0.04511	0.96661

为进一步说明本章模型的优越性, 本章选取了测试集中四台风力涡轮机的风速序列数据, 并分别绘制了基于 GCDS 的邻近空间风速分布推断方法与基于 GCDS-Transformer 的邻近空间风速序列生成方法在这四台风力涡轮机上的风速数据核密度对比图, 如图 4-9 所示。从图 4-9 中可以看出, 在这四台风力涡轮机上, 本章的 GCDS-Transformer 模型在风速数据分布拟合上要优于第 3 章的 GCDS 模型。




图 4-9 基于 GCDS 的邻近空间风速分布推断方法与基于 GCDS-Transformer 的邻近空间风速序列生成方法在测试集中四个风力涡轮机上的风速数据核密度对比图

4.5 本章小结

本章提出了一种基于 GCDS-Transformer 模型的邻近空间风速序列生成方法。该方法无需假设长期时间序列的平稳性和同分布特征，能够生成具有时空关联性的邻近区域风速序列数据。GCDS-Transformer 模型从概率密度估计视角构建时空序列生成机制，通过引入有监督目标函数，显著提升了模型生成具有时序信息的风速数据的准确性。在模型架构层面，该模型融合了空间噪声编码器与因果时序解码器模块，并设计了无监督学习和有监督学习相结合的多任务联合优化的目标函数，从而确保生成数据的时空一致性。在实际数据集上的实验表明，本章方法在生成风速序列数据上的准确性优于传统的空间插值模型。

第5章 结论

本文针对收集到的风速数据空间分布稀疏问题，从邻近空间风速分布推断和风速序列生成两个角度展开研究，并提出了相应的创新模型或方法。

在第 3 章中，本文提出了基于 GCDS 的邻近空间风速分布推断模型，有效解决了无观测数据位置的风速分布推断问题。该模型是一种非参数的生成式神经网络模型，无需预先假设风速分布的函数形式。而且不需要考虑位置、高度等因素影响下风速分布函数形式不同的问题。与传统的统计分布模型相比，该模型具有更好的拟合效果，能够显著减少传统插值方法在未观测邻近空间位置分布推断中的累积误差。然而，该模型基于长期风速序列为平稳时间序列的假设，将不同时刻的风速数据视为服从于同一概率分布，因此无法生成具有时序维度的风速数据。

为进一步生成邻近空间位置的风速序列数据，本文第 4 章提出了一种基于 GCDS-Transformer 的邻近空间风速序列生成模型。该模型由生成网络和判别网络两部分构成：生成网络采用融合空间噪声编码器与因果时序解码器模块的改进 Transformer 模型，负责生成给定空间位置的风速序列数据；判别网络由多层全连接层构成，用于判别生成数据与真实数据的联合概率分布是否一致。通过设计无监督学习与有监督学习相结合的多任务联合优化目标函数，确保了生成数据的时空一致性。与传统插值模型相比，该模型能够生成更准确的风速序列数据。

本文的研究不仅提高了风能评估的准确性，还为风电场选址、布局优化以及风速、风能发电量预测提供了更加可靠的数据支撑，推动了风能发电行业的发展。然而，本文的研究仍存在以下不足：

- 1、本文提出的模型本质上是非参数条件概率密度估计模型，但是本文仅研究了条件变量是空间位置信息的低维变量。后续应进一步引入其它影响风速变化的因素例如温度、压强以及周围地形等。

- 2、本文第 4 章提出的基于 GCDS-Transformer 的邻近空间风速序列生成模型在训练时会占用较多的内存空间，因此目前只能生成相对较短（如 1024 个时刻）的风速序列数据。未来研究应着重改进模型中的注意力机制，降低算法复杂度，使其能够建模更长时刻的风速序列数据。

致 谢

时光匆匆，三年的求学之路如同一场精彩纷呈的旅程，每一步都铭刻着温暖与感激。借此机会，我愿将心中的感恩化作真挚文字，献给一路陪伴我成长的人们。

首先，我要感谢我的导师——郑海涛老师，郑老师不仅在学术上给予我无私指导，更在生活中成为我灵魂的引路人。郑老师宽广的学识与严谨的治学精神，如同灯塔般在黑夜中为我指引方向，使我在迷茫中找到了前行的路。每一次耐心细致的指点、每一次充满智慧的讨论，都深深激励着我不断突破自我、追求卓越。在我的学术道路上，郑老师不仅传授知识，更教会我如何思考和坚持，这份恩情将伴我终生。

其次，感谢与我携手同行的同门师兄、师姐、师弟、师妹们。在风雨同舟的日日夜夜中，你们的鼓励与陪伴让求学的旅程充满温馨与力量。你们的真诚、勤奋和热情，让我在遇到挫折时从未感到孤单。正是这种并肩作战的精神，使我们的青春绽放出最灿烂的光芒，成为我心中永不褪色的记忆。

最后，我衷心感谢学院和学校为我提供的广阔平台和优越环境。在这里，我不仅获得了丰富的知识储备，更感受到了浓厚的人文关怀和严谨的学术氛围。让我在这片沃土上自由生长、不断追梦。无论是课堂上的指点，还是生活中的点滴关怀，都让我心存感激，铭记于心。

再次向所有在我求学旅程中给予我支持、鼓励与关怀的师长、同学和朋友们致以最真挚的谢意，愿这份感恩化作未来不断前行的动力，继续在人生道路上探索无限可能。

参考文献

- [1] Xie Y, Li C, Li M, et al. An overview of deterministic and probabilistic forecasting methods of wind energy[J]. *iScience*, 2023, 26(1): 105804.
- [2] Hu J, Li H, Liu Z. A novel scenario generation framework based on the knowledge of existing wind power plants [J]. *IEEE Transactions on Sustainable Energy*, 2021: 1229-1241.
- [3] Chen X, Ye X, Xiong X, et al. Improving the accuracy of wind speed spatial interpolation: A pre-processing algorithm for wind speed dynamic time warping interpolation[J]. *Energy*, 2024, 295: 130876.
- [4] Petković D, Pavlović N T, Čojbašić Ž. Wind farm efficiency by adaptive neuro-fuzzy strategy[J]. *International Journal of Electrical Power & Energy Systems*, 2016: 215-221.
- [5] Lee C. Long-term wind speed interpolation using anisotropic regression kriging with regional heterogeneous terrain and solar insolation in the United States[J]. *Energy Reports*, 2022, 8: 12-23.
- [6] Safari B. Modeling wind speed and wind power distributions in Rwanda[J]. *Renewable and Sustainable Energy Reviews*, 2011, 15(2): 925-935.
- [7] Singh S, Bhatti T S, Kothari D P. Wind power estimation using artificial neural network[J]. *Journal of Energy Engineering*, 2007: 46-52.
- [8] Safari B, Gasore J. A statistical investigation of wind characteristics and wind energy potential based on the Weibull and Rayleigh models in Rwanda[J]. *Renewable Energy*, 2010: 2874-2880.
- [9] Serban A, Paraschiv L S, Paraschiv S. Assessment of wind energy potential based on Weibull and Rayleigh distribution models[J]. *Energy Reports*, 2020: 250-267.
- [10] Zheng H, Huang W, Zhao J, et al. A novel falling model for wind speed probability distribution of wind farms[J]. *Renewable Energy*, 2022, 184: 91-99.
- [11] Jia J, Yan Z, Peng X, et al. A new distribution for modeling the wind speed data in Inner Mongolia of China[J]. *Renewable Energy*, 2020: 1979-1991.
- [12] Jung C, Schindler D. Global comparison of the goodness-of-fit of wind speed distributions[J]. *Energy Conversion and Management*, 2017, 133: 216-234.
- [13] Zhang S, Solari G, Yang Q, et al. Extreme wind speed distribution in a mixed wind climate[J]. *Journal of Wind Engineering and Industrial Aerodynamics*, 2018: 239-253.

- [14] Khaled Khamees A, Abdelaziz A Y, Ali Z M, et al. Mixture probability distribution functions using novel metaheuristic method in wind speed modeling[J]. Ain Shams Engineering Journal, 2022, 13(3): 101613.
- [15] Wang Y, Li Y, Zou R, et al. Bayesian infinite mixture models for wind speed distribution estimation[J]. Energy Conversion and Management, 2021: 113946.
- [16] Miao S, Xie K, Yang H, et al. A mixture kernel density model for wind speed probability distribution estimation[J]. Energy Conversion and Management, 2016, 126: 1066-1083.
- [17] 郑贵洲. 空间统计理论与方法[M]. 电子工业出版社, 2022.
- [18] Li L, Losser T, Yorke C, et al. Fast Inverse Distance Weighting-Based Spatiotemporal Interpolation: A Web-Based Application of Interpolating Daily Fine Particulate Matter PM2.5 in the Contiguous U.S. Using Parallel Programming and k-d Tree[J]. International Journal of Environmental Research and Public Health, 2014, 11(9): 9101-9141.
- [19] Losser T, Li L, Piltner R. A Spatiotemporal Interpolation Method Using Radial Basis Functions for Geospatiotemporal Big Data[C]. 2014 Fifth International Conference on Computing for Geospatial Research and Application, Washington, DC, USA: 2014: 17-24.
- [20] 李莎, 舒红, 董林. 基于时空变异函数的 Kriging 插值及实现[J]. 计算机工程与应用, 2011, 47(23): 25-26+38.
- [21] 徐爱萍, 圣文顺, 舒红. 时空积和模型的数据插值与交叉验证[J]. 武汉大学学报(信息科学版), 2012, 37(07): 766-769+754.
- [22] 许美玲, 邢通, 韩敏. 基于时空 Kriging 方法的时空数据插值研究[J]. 自动化学报, 2018, 46(08): 1681-1688.
- [23] Hu D gui, Shu H. Spatiotemporal interpolation of precipitation across Xinjiang, China using space-time CoKriging[J]. Journal of Central South University, 2019, 26(3): 684-694.
- [24] Hsieh H P, Lin S D, Zheng Y. Inferring Air Quality for Station Location Recommendation Based on Urban Big Data[C]. Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, Sydney NSW Australia: 2015: 437-446.
- [25] Qi Z, Wang T, Song G, Hu W, et al. Deep Air Learning: Interpolation, Prediction, and Feature Analysis of Fine-Grained Air Quality[J]. IEEE Transactions on Knowledge and Data Engineering, 2018, 30(12): 2285-2297.
- [26] Ma J, Ding Y, Gan V J L, et al. Spatiotemporal Prediction of PM2.5 Concentrations at Different Time Granularities Using IDW-BLSTM[J]. IEEE Access, 2019, 7: 107897-107907.

- [27] Ma J, Ding Y, Cheng J C P, et al. A temporal-spatial interpolation and extrapolation method based on geographic Long Short-Term Memory neural network for PM_{2.5}[J]. Journal of Cleaner Production, 2019, 237: 117729.
- [28] Appleby G, Liu L, Liu L P. Kriging Convolutional Networks[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(04): 3187-3194.
- [29] Wu Y, Zhuang D, Labbe A, et al. Inductive Graph Neural Networks for Spatiotemporal Kriging[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2021, 35(5): 4478-4485.
- [30] Zheng C, Fan X, Wang C, et al. INCREASE: Inductive Graph Representation Learning for Spatio-Temporal Kriging[C]. Proceedings of the ACM Web Conference 2023, Austin TX USA: 2023: 673-683.
- [31] Jakub M Tomczak. Deep Generative Modeling[M]. Springer International Publishing, 2022.
- [32] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[C]. Proceedings of the 28th International Conference on Neural Information Processing Systems, Montreal, Canada, 2014: 2672–2680.
- [33] Nowozin S, Cseke B, Tomioka R. f-GAN: training generative neural samplers using variational divergence minimization[C]. Proceedings of the 30th International Conference on Neural Information Processing Systems, Barcelona, Spain, 2016: 271–279.
- [34] Mao X, Li Q, Xie H, et al. Least Squares Generative Adversarial Networks[C]. 2017 IEEE International Conference on Computer Vision (ICCV). Venice: 2017: 2813-2821.
- [35] Arjovsky M, Chintala S, Bottou L. Wasserstein generative adversarial networks[C]. Proceedings of the 34th International Conference on Machine Learning, Sydney, NSW, Australia, 2017: 214–223.
- [36] Chen X, Duan Y, Houthoofd R, et al. InfoGAN: interpretable representation learning by information maximizing generative adversarial nets[C]. Proceedings of the 30th International Conference on Neural Information Processing Systems, Barcelona, Spain, 2016: 2180–2188.
- [37] Mirza M, Osindero S. Conditional Generative Adversarial Nets[J/OL]. arXiv, 2014.
- [38] Lin X, Li J, Zeng H, et al. Font generation based on least squares conditional generative adversarial nets[J]. Multimedia Tools and Applications, 2019, 78(1): 783-797.
- [39] Yan Y, Shen G, Zhang S, et al. Sequence generative adversarial nets with a conditional discriminator[J]. Neurocomputing, 2021, 429: 69-76.

- [40] Othberdout N, Daoudi M, Kacem A, et al. Dynamic Facial Expression Generation on Hilbert Hypersphere With Conditional Wasserstein Generative Adversarial Nets[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(2): 848-863.
- [41] Zhou X, Jiao Y, Liu J, et al. A Deep Generative Approach to Conditional Sampling[J]. Journal of the American Statistical Association, 2023, 118(543): 1837-1848.
- [42] Esteban C, Hyland S L, Rätsch G. Real-valued (Medical) Time Series Generation with Recurrent Conditional GANs[J/OL]. arXiv, 2017.
- [43] Yoon J, Jarrett D, Van der Schaar M. Time-series generative adversarial networks[C]. Proceedings of the 33rd International Conference on Neural Information Processing Systems, Vancouver BC Canada, 2019: 11-22.
- [44] Liao S, Ni H, Sabate - Vidales M, et al. Sig - Wasserstein GANs for conditional time series generation[J]. Mathematical Finance, 2024, 34(2): 622-670.
- [45] Jeha P, Bohlke-Schneider M, Mercado P, et al. PSA-GAN: Progressive self attention GANs for synthetic time series[C]. The Tenth International Conference on Learning Representations, 2022.
- [46] Qin C, Gao X. Spatio - Temporal Generative Adversarial Networks[J]. Chinese Journal of Electronics, 2020, 29(4): 623-631.
- [47] Zhou Y, Shi C, Li L, et al. Testing for the Markov property in time series via deep conditional generative learning[J]. Journal of the Royal Statistical Society Series B: Statistical Methodology, 2023, 85(4): 1204-1222.
- [48] Zhu D, Cheng X, Zhang F, et al. Spatial interpolation using conditional generative adversarial neural networks[J]. International Journal of Geographical Information Science, 2020, 34(4): 735-758.
- [49] Xu Z, Kang Y, Cao Y. Emission stations location selection based on conditional measurement GAN data[J]. Neurocomputing, 2020, 388: 170-180.
- [50] Zhou X, Liu X, Lan G, et al. Federated conditional generative adversarial nets imputation method for air quality missing data[J]. Knowledge-Based Systems, 2021, 228: 107261.
- [51] 邱锡鹏. 神经网络与深度学习[M]. 机械工业出版社, 2020.
- [52] Austin T. Exchangeable random measures[J]. Annales de l'Institut Henri Poincaré, Probabilités et Statistiques, 2015, 51(3): 842-861.
- [53] Nguyen X, Wainwright M J, Jordan M I. Estimating Divergence Functionals and the Likelihood Ratio by Convex Risk Minimization[J]. IEEE Transactions on Information Theory, 2010, 56(11): 5847-5861.

- [54] Ashish V, Noam S, Niki P, et al. Attention is All You Need[C]. Proceedings of the 31rd International Conference on Neural Information Processing Systems, Long Beach CA USA, 2017: 5998-6008.
- [55] Brockwell P J, Davis R A. Introduction to Time Series and Forecasting[M]. Springer International Publishing, 2016.
- [56] Liang Y, Xia Y, Ke S, et al. AirFormer: Predicting Nationwide Air Quality in China with Transformers[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(12): 14329-14337.
- [57] Jingbo Zhou, Xinjiang Lu, Yixiong Xiao, et al. SDWPF: A Dataset for Spatial Dynamic Wind Power Forecasting Challenge at KDD Cup 2022[J/OL]. arXiv preprint arXiv:2208.04360, 2022.
- [58] Sekulić A, Kilibarda M, Heuvelink G B M, et al. Random Forest Spatial Interpolation[J]. Remote Sensing, 2020, 12(10): 1687.

攻读硕士学位期间取得的研究成果

一、攻读硕士学位期间发表的论文：

[1] Li X, Huang G, Yu W, Yin R, Zheng H. Distribution inference of wind speed at adjacent spaces using generative conditional distribution sampler[J]. Computers and Electrical Engineering, 2025, 123: 110-123.